

BioSpecInfo

Accuratezza scientifica e provenienza dei dati — BioSpecInfo

Samuele Pio Provenzano

Versione **bsi-v192** · commit `f9fa127`

Generato il 2026-10-07

Documento generato automaticamente dal sorgente Markdown versionato nel repository. La versione e il commit stampati in ogni piè di pagina identificano esattamente lo stato del software descritto.

Accuratezza scientifica e provenienza dei dati — BioSpecInfo

Campo	Valore
Software	BioSpecInfo
Autore	Samuele Pio Provenzano
Versione descritta	bsi-v192
Scopo	Documentare come vengono generati i dati scientifici mostrati dall'applicazione, con quale metodo sono verificati, e quali sono i limiti dichiarati.

Perché questo documento esiste. Un'applicazione didattica di chimica può essere ineccepibile dal punto di vista informatico e sbagliata dal punto di vista scientifico, e l'utente non ha modo di accorgersene: un peso molecolare plausibile, uno spettro dall'aspetto convincente e una struttura sbagliata si presentano tutti allo stesso modo. Questo documento descrive i controlli che rendono quell'errore **visibile e automatico**, e dichiara ciò che resta fuori dalla loro portata.

1. Principio: ogni dato scientifico deve poter essere contraddetto

Il criterio adottato in tutta l'applicazione è che un dato scientifico non si consideri verificato perché *sembra* giusto, ma perché **esiste un secondo dato indipendente che lo confermerebbe o lo smentirebbe**. Dove questo secondo dato non esiste, il limite viene dichiarato invece di essere colmato con una stima presentata come misura.

Tre applicazioni concrete di questo principio:

Ambito	Prima affermazione	Seconda affermazione indipendente	Controllo
Banca dati farmaci	struttura (SMILES)	peso molecolare di letteratura	il peso ricalcolato dalla struttura deve coincidere
Spettri IR / NMR	gruppi funzionali riconosciuti	struttura molecolare via RDKit	i gruppi si cercano sul grafo, non sul testo dello SMILES
Costanti fisiche	valore tabulato	simbolo e unità di misura	la ricerca rifiuta le corrispondenze ambigue invece di sceglierne una

2. Banca dati farmacologica — 263 voci

2.1 Il metodo di verifica

Ogni voce dichiara **due** proprietà della stessa molecola: la struttura, in notazione SMILES, e il peso molecolare. Sono affermazioni indipendenti — la prima descrive la connettività atomica, la seconda è un numero preso dalla letteratura — e quindi confrontabili:

peso calcolato da RDKit sulla struttura ↔ peso dichiarato in tabella

Uno scarto superiore a **0,6 u** (tolleranza che copre gli arrotondamenti e le piccole differenze fra tabelle di masse atomiche, ma non un errore reale, che vale decine di unità) indica che almeno una delle due affermazioni è sbagliata.

Il controllo è automatizzato (`tools/verifica-farmaci.js` , eseguibile da chiunque disponga del repository) e non richiede giudizio umano: non chiede di fidarsi di nessuna fonte, confronta due numeri.

2.2 Cosa ha trovato

Applicato alle 143 voci preesistenti, il controllo ha individuato **89 errori**. La distribuzione è significativa: i **pesi molecolari erano corretti** — presi dalla letteratura — mentre le **strutture erano sbagliate**.

Farmaco	Struttura dichiarata
Ketamina	un pirrolidinone non correlato
Morfina	struttura non corrispondente (in due voci distinte)
Lorazepam	privo dell'ossidril in posizione 3, che ne definisce l'identità
Atorvastatina	privo del gruppo anilidico
Testosterone	privo del doppio legame Δ^4 dell'anello A

Più **7 farmaci duplicati** in categorie diverse, con dati talvolta divergenti fra le due copie.

2.3 Lo scarto come strumento diagnostico

Il valore numerico della differenza non è solo un allarme: indica **quale** frammento manca o è di troppo.

Δ (u)	Interpretazione	Caso reale
28,05	C_2H_4	ketamina, fentanil, morfina
16,00	un atomo di ossigeno	tetraciclina (un ossidril in più)
14,02	un gruppo CH_2	doxiciclina
2,02	un doppio legame mancante	testosterone (Δ^4)
0,98	citosina ↔ uracile	sofosbuvir

L'ultimo caso merita una nota: lo scarto di 0,98 u corrisponde esattamente alla sostituzione di un gruppo –NH con un atomo di ossigeno, cioè alla differenza fra citosina e uracile. Il sofosbuvir è un analogo dell'**uridina**, e la struttura proposta conteneva la base sbagliata. Il numero ha indicato dove guardare.

2.4 Stato attuale e limiti dichiarati

Farmaci in banca dati	263 (erano 233)
Con struttura leggibile	242
Con provenienza esterna verificata	36
Difetti	0
Voci senza struttura, con ragione dichiarata	21

La verifica è **conforme**: nessuna voce presenta una struttura che contraddica il proprio peso molecolare. Le 21 deviazioni sono voci **prive di struttura**, ciascuna registrata con il proprio motivo in [evidence/deviazioni-note.json](#) e riportata nel rapporto di verifica.

Difetto contro deviazione. Il controllo distingue due situazioni che non vanno confuse:

- una struttura che **contraddice** il proprio peso è un difetto, e fa fallire

la verifica;

- una struttura **assente** può essere una deviazione accettabile — ma solo se

registrata esplicitamente, con il motivo. Una voce priva di struttura e **non** registrata fa fallire la verifica come qualunque altro difetto.

Registrare una deviazione è quindi una decisione consapevole, tracciata in git e visibile nel rapporto, non un modo per silenziare un controllo.

E va anche **revocata** quando non serve più. Dalla versione [bsi-v188](#) il banco fallisce anche nel caso opposto: una voce elencata nel registro che **ha** una struttura verificata è un permesso rimasto acceso a vuoto, e domani coprirebbe in silenzio una struttura sbagliata messa al suo posto.

2.4-bis Quattro voci uscite dal registro

Delle sei voci senza struttura, quattro sono state chiuse riprendendo la struttura da **ChEMBL** — una fonte indipendente da questo progetto — e verificandola con lo stesso confronto struttura ↔ peso molecolare che vale per tutte le altre.

Voce	ChEMBL	Formula	Peso dichiarato	Peso calcolato
Digossina	CHEMBL1751	C ₄₁ H ₆₄ O ₁₄	780,94	780,95
Vincristina	CHEMBL90555	C ₄₆ H ₅₆ N ₄ O ₁₀	824,96	824,97
Tacrolimus topico (Protopic)	CHEMBL269732	C ₄₄ H ₆₉ NO ₁₂	804,02	804,03
Tacrolimus sistemico (Prograf)	CHEMBL269732	C ₄₄ H ₆₉ NO ₁₂	804,02	804,03

Il motivo registrato per la digossina diceva «ogni struttura provata si discosta di 14-30 u dal peso di letteratura»: il peso dichiarato era giusto, erano le strutture provate a essere sbagliate. Che il confronto sia reale e non compiacente si vede aggiungendo un solo carbonio alla struttura corretta — il banco segnala **Δ 14,04** e fallisce.

Le due che restano non sono molecole singole, e nessuna notazione SMILES le rappresenta:

- **Ivermectina** è una miscela di omologhi: almeno 80 % di B1a (C₄₈H₇₄O₁₄) e non più del 20 % di B1b (C₄₇H₇₂O₁₄). Il peso dichiarato, 875,10, è quello del solo componente B1a. Mostrarne la struttura farebbe passare l'omologo maggioritario per l'intero farmaco.

- **Artemetere/Lumefantrina (Coartem)** è l'associazione di due principi attivi distinti.

In entrambi i casi non manca una struttura: non ce n'è una sola da mostrare.

2.4-ter Trentasei voci con la provenienza scritta nel dato (bsi-v188)

Il confronto struttura ↔ peso è necessario ma non sufficiente, e si è visto dove cede. Le trentasei voci aggiunte in `bsi-v188` portano nel dato stesso l'identificativo ChEMBL e la formula del record (`chembl:` , `formula:`), e per ognuna la formula viene **ricostruita contando gli atomi del grafo** che RDKit legge dallo SMILES — idrogeni impliciti compresi — e confrontata con quella dichiarata da ChEMBL: **36 su 36 coincidono**. I dati grezzi stanno in `tools/dati/farmaci_v187.json`.

Dove il peso non vedeva. Sei di quelle voci esistevano già, scritte prima che la provenienza esterna fosse un requisito. Confrontando le due versioni con la **chiave InChI** che ChEMBL dichiara, tre si sono rivelate una molecola diversa:

Voce	chiave della versione precedente	chiave dichiarata da ChEMBL
Lenalidomide	XKAYAFBLGLCSY	GOTYRUGSSMKFNF
Palbociclib	PSRAOXPOEYRNJN	AHJRHEGDXXFFBM
Aripiprazolo	ZGXTVHHDFTYTL	CEUORZQYGODEFX

Erano **isomeri**: stessa formula bruta, stesso peso molecolare, posizione diversa di un azoto o di un carbonile. Il controllo struttura ↔ peso — che esisteva, girava a ogni rilascio e passava — non poteva vederlo, perché un isomero pesa esattamente uguale. Serviva un testimone che guardasse la **connettività**, non la massa. Le tre voci sono state rimosse e sostituite da quelle verificate; le altre tre differivano solo nella scrittura canonica dello SMILES e descrivevano la stessa molecola.

Due strutture rifiutate. Nella stessa raccolta, l'**ivermectina** ha `structure_type NONE` nel proprio record ChEMBL — conferma esterna del limite già dichiarato in §2.4-bis — e la **semaglutide** è registrata come proteina, `structure_type SEQ`. Entrambe si sarebbero potute scrivere a memoria. È esattamente ciò che non si fa: una struttura senza fonte entra nel sito indistinguibile da una verificata, e da lì in poi nessun controllo le distingue.

Due nomi tenuti con il nome del record. La ricerca per nome di ChEMBL è a corrispondenza parziale: «morphine» ha restituito l'**apomorfina** e «levothyroxine» la **liotironina** (T3), trovata fra i sinonimi. Le voci sono state tenute con il nome che il record porta, non con quello della domanda: il contrario avrebbe messo una scheda clinica sbagliata sopra una struttura giusta — l'errore più difficile da trovare, perché ogni controllo automatico sulla struttura continuerebbe a passare.

Gruppo	Voci	Natura
D-01 — non sono molecole singole	2	ivermectina (miscela di omologhi B1a/B1b) e artemetere/lumefantrina (associazione di due principi attivi). Erano sei: le altre quattro sono state chiuse con la struttura da ChEMBL, vedi §2.4-bis.
D-02 — non rappresentabili in SMILES	19	anticorpi monoclonali, proteine e peptidi (trastuzumab, pembrolizumab, insulina, semaglutide, ciclosporina A...). L'assenza è corretta, non una lacuna.

La scelta è deliberata: un dato sbagliato sostituito da un altro dato sbagliato non è un progresso, e l'assenza dichiarata è preferibile a una presenza non verificata.

3. Predizione spettrale

3.1 Riconoscimento strutturale, non testuale

I gruppi funzionali sono individuati con **pattern SMARTS applicati al grafo molecolare** tramite RDKit (`bsi-spettri.js`), non con espressioni regolari applicate alla stringa SMILES.

La differenza non è stilistica. Il metodo testuale precedente presentava due difetti strutturali:

1. **Esclusività.** I controlli erano organizzati in catene `else if`, per cui veniva riconosciuto **un solo gruppo funzionale per molecola**.

1. **Cecità alla struttura.** Una regex legge caratteri, non legami.

Il caso emblematico è l'**acido acetilsalilico** (`CC(=O)Oc1ccccc1C(=O)O`), che contiene sia un estere sia un acido carbossilico. Il riconoscimento testuale identificava solo l'estere; lo spettro IR risultante era privo della banda O-H allargata a $\sim 3000\text{ cm}^{-1}$ e del C=O acido a $\sim 1690\text{ cm}^{-1}$ — le due bande che identificano la molecola — e lo spettro ^1H NMR era privo del segnale del protone carbossilico a 11,6 ppm.

Il riconoscimento su grafo è **additivo per costruzione**: una molecola può presentare tutti i gruppi che possiede.

3.2 Convenzioni di rappresentazione

Le convenzioni degli assi non sono uniformi fra le tecniche, e sono verificate automaticamente (`test_assi.js`, `test_assi_canvas.js`) estraendo le etichette delle tacche dal disegno prodotto:

Tecnica	Ascissa	Verso	Ordinata
IR	numero d'onda (cm^{-1})	decrescente, 4000 $\rightarrow$ 400	trasmissione %, bande verso il basso
^1H NMR	δ (ppm)	decrescente, 14 $\rightarrow$ 0	intensità, riferimento TMS a 0
UV-Vis	λ (nm)	crescente, 200 $\rightarrow$ 400	assorbanza
MS	m/z	crescente	abbondanza relativa

3.3 Determinismo

Nessuno spettro contiene componenti casuali. Le versioni precedenti aggiungevano rumore pseudo-casuale alla traccia a ogni ridisegno, con la conseguenza che la stessa molecola produceva ogni volta uno spettro diverso e due spettri non erano confrontabili. Un profilo calcolato deve essere **riproducibile**: dove serve un fondo realistico si usa una funzione deterministica del numero d'onda.

Analogamente, nel predittore NMR le altezze dei picchi erano generate casualmente. In uno spettro ^1H l'altezza è l'informazione quantitativa — l'integrazione — e inventarla è peggio che ometterla. Attualmente:

- dove il numero di protoni è noto, l'altezza è l'integrazione reale e

l'etichetta la riporta (es. 7,26 (4H));

- dove la predizione è un **intervallo** (es. «6,5-8,5 ppm»), si disegna la

fascia dell'intervallo con un segno sul valore tipico e altezza uniforme: il grafico indica *dove* cade il segnale senza affermare quanto sia intenso.

3.4 Effetti chimici modellati

Effetto	Implementazione
Coniugazione del carbonile	abbassamento di $\sim 25 \text{ cm}^{-1}$ applicato al singolo carbonile , non globalmente
Estere fenolico	innalzamento a $\sim 1760 \text{ cm}^{-1}$
Intensità C-H	proporzionale al numero di gruppi CH_2/CH_3 presenti
Sostituzione dell'anello aromatico	bande "fuori dal piano" $900\text{-}690 \text{ cm}^{-1}$ distinte per orto/meta/para/mono
Doppietto di Fermi delle aldeidi	bande a 2820 e 2720 cm^{-1}
Bande ammidiche I e II	1655 e 1550 cm^{-1}

Verifica: l'acido acetilsalicilico produce estere arilico a 1760 cm^{-1} e acido coniugato a 1690 cm^{-1} — i due valori che lo identificano — mentre acetofenone (chetone coniugato, 1690) e acetato di etile (estere non coniugato, 1735) confermano che l'effetto è applicato in modo selettivo e non indiscriminato.

3.5 Limiti dichiarati

Gli spettri prodotti sono **predizioni basate su tabelle di gruppi funzionali**, non spettri misurati né simulazioni quantomeccaniche. Indicano dove cadono le bande dei gruppi presenti, con posizioni e intensità tabulate. **Non sostituiscono un database sperimentale** (SDBS, NIST) né una misura strumentale, e il grafico lo dichiara.

In particolare non sono modellati: accoppiamenti spin-spin del secondo ordine, effetti di solvente e concentrazione, bande di combinazione e sovratoni, polimorfismo allo stato solido.

3-bis. Chemioinformatica e modelli QSAR

3-bis.1 Da dove vengono i metodi

Nessuno dei metodi della sezione **Chemioinformatica** è inventato per l'occasione. Sono quelli in uso, con i riferimenti che li definiscono.

Metodo	Riferimento	Come è implementato qui
Coefficiente di Tanimoto	Rogers & Tanimoto, 1960	Bit in comune su bit in unione, con la convenzione 0/0 = 1 dichiarata nel codice
Impronte di Morgan / ECFP	Rogers & Hahn, <i>J. Chem. Inf. Model.</i> 50 (2010) 742	Da RDKit MinimalLib, raggio 2, 2048 bit
Chiavi MACCS	Durant <i>et al.</i> , <i>J. Chem. Inf. Comput. Sci.</i> 42 (2002) 1273	Da RDKit MinimalLib, 166 chiavi
Regola dei 5	Lipinski <i>et al.</i> , <i>Adv. Drug Deliv. Rev.</i> 23 (1997) 3	Sui descrittori RDKit, con il conteggio delle violazioni
Filtro di Veber	Veber <i>et al.</i> , <i>J. Med. Chem.</i> 45 (2002) 2615	Legami ruotabili ≤ 10 , TPSA $\leq 140 \text{ \AA}^2$
QED	Bickerton <i>et al.</i> , <i>Nat. Chem.</i> 4 (2012) 90	Ricalcolato: MinimalLib espone 43 descrittori ma non il QED. I parametri delle funzioni desiderabilità sono quelli dell'articolo
Raggruppamento di Butina	Butina, <i>J. Chem. Inf. Comput. Sci.</i> 39 (1999) 747	Soglia sulla distanza di Tanimoto, capifila scelti per numero di vicini
Scheletri di Bemis-Murcko	Bemis & Murcko, <i>J. Med. Chem.</i> 39 (1996) 2887	Sistemi ad anello più i legami che li collegano
PAINS	Baell & Holloway, <i>J. Med. Chem.</i> 53 (2010) 2719	Sottoinsieme dei pattern SMARTS, con il motivo della segnalazione
Allarmi di Brenk	Brenk <i>et al.</i> , <i>ChemMedChem</i> 3 (2008) 435	Idem
SALI	Guha & Van Drie, <i>J. Chem. Inf. Model.</i> 48 (2008) 646	Δ attività / (1 – Tanimoto), sulle coppie sopra la soglia di similarità

3-bis.2 Le quattro cose che rendono un QSAR onesto

Un modello QSAR è facilissimo da far sembrare buono. Le quattro precauzioni qui sotto sono quelle che distinguono un numero da una misura, e sono tutte verificate dal banco

`test_cheminfo`.

Divisione per scheletro. Con una divisione casuale, analoghi stretti della stessa serie finiscono da entrambe le parti: il modello ritrova ciò che ha già visto. La divisione per scheletro raggruppa le molecole per scheletro di Bemis-Murcko e assegna **scheletri interi** a una sola parte. L' R^2 che ne esce è più basso — ed è quello che sopravvive alla molecola nuova.

Modello nullo per rimescolamento. Lo stesso modello viene riaddestrato otto volte su etichette mescolate. Se il punteggio vero non supera il migliore dei sosia, il modello non ha imparato nulla di trasferibile, e il pannello lo dichiara con quelle parole. È il controllo che manca più spesso: senza di esso, un R^2 di 0,4 su trenta molecole è indistinguibile dal caso.

Dominio di applicabilità. Una predizione su una molecola lontana da tutto ciò che il modello ha visto è un'estrapolazione, non una predizione. La distanza dal vicino più prossimo nell'insieme di addestramento è mostrata accanto a ogni valore predetto.

Validazione incrociata raggruppata per scheletro. Una divisione sola, su un insieme piccolo, è un numero rumoroso: su 28 molecole al 25 % l'insieme di prova ne contiene sette, e spostarne una muove l' R^2 di decimi. Le pieghe raggruppano per scheletro — nessuno scheletro sta in due pieghe — e il risultato viene dato come **media $\pm$ deviazione**, non come cifra singola.

Quanto conti, misurato sull'esempio dei 28 inibitori. La divisione singola dà R^2 **0,861**. La validazione a cinque pieghe dà **0,605 $\pm$ 0,452**, con le singole pieghe a 0,861 · 0,538 · 0,795 · **-0,150** · 0,980. La divisione singola aveva pescato la piega fortunata. Le due cifre insieme dicono quello che nessuna delle due dice da sola: il modello funziona, ma dipende sensibilmente da quali molecole gli capitano in addestramento — e su un insieme di ventotto molecole è esattamente ciò che ci si deve aspettare.

3-bis.3 Limiti dichiarati

Limite	Conseguenza
Gli insiemi di esempio sono piccoli (28 e 40 molecole)	Servono a mostrare il metodo, non a produrre un modello utilizzabile. Su insiemi così, il modello nullo è la sola difesa seria — ed è il motivo per cui c'è
Il modello è lineare nel kernel (kernel ridge, kernel di Tanimoto) o logistico	Nessuna rete neurale, nessun gradient boosting: sono metodi che su poche centinaia di molecole non danno un vantaggio dimostrabile, e il costo sarebbe un modello che non si può ispezionare
I PAINS non sono una condanna	Un pattern PAINS segnala che il composto è stato spesso un falso positivo in saggi di fluorescenza, non che sia inattivo. Il pannello lo scrive accanto a ogni segnalazione
La PCA è sui descrittori , non sulle impronte	Sulle impronte binarie la PCA è poco informativa; i carichi sui descrittori si leggono, e sono mostrati

Limite	Conseguenza
Non c'è ricerca di sottostruttura su larga scala	Il banco di lavoro è dimensionato per gli insiemi che si incollano a mano, non per una libreria da milioni di composti

3-bis.4 Due superfici, due ruoli — e un numero che era falso

L'applicazione ha **due** luoghi in cui si fa chemioinformatica, e servono a cose diverse. La distinzione è scritta qui perché un valutatore che apra prima la pagina sbagliata si farebbe l'idea sbagliata.

	rdkit_lab.html — «RDKit Lab»	Sezione Chemioinformatica
A chi serve	Chi studia: una molecola alla volta, per vedere cosa RDKit sa dirne	Chi lavora: un insieme di molecole, per ricavarne un modello difendibile
Ingresso	Uno SMILES	Un insieme incollato, con l'attività misurata
QSAR	Stime empiriche dai descrittori, dichiarate tali nel pannello	Modello addestrato sui dati forniti, con divisione per scheletro, validazione incrociata e controllo nullo
Uscita	Quello che si vede a schermo	CSV e rapporto di metodo

Un numero che era falso, e come se n'è accorto il banco. Il pannello «Pharma Pro» del laboratorio confrontava la molecola con otto farmaci di riferimento e mostrava una percentuale di similarità. Quella percentuale non veniva da un fingerprint: veniva da **otto bit di descrittori a soglia** — «ha anelli aromatici», «HBA > 4», «peso fra 200 e 500» — di cui si calcolava il Tanimoto. Misurato: **caffaina contro metformina dava 0,75**, mentre su fingerprint di Morgan vale **0,024**. Due molecole senza frammenti in comune, mostrate al 75 %, su una pagina che si chiama «RDKit Lab» e dove RDKit era già caricato. Accanto a quello, tre delle otto impronte di riferimento erano **scritte a mano** e avevano il bit «aromatico» sbagliato (caffaina, che ha due anelli aromatici, morfina e amoxicillina che ne hanno uno), e lo **SMILES dell'omeprazolo non era omeprazolo**:
C0c1ccc2[nH]c(=S)cc2c1O è una struttura che RDKit rifiuta.

Corretto tutto: il confronto usa il fingerprint di Morgan con il Tanimoto del motore condiviso, le impronte si calcolano invece di essere battute a tastiera, e l'omeprazolo è l'omeprazolo (massa monoisotopica 345,11, tre anelli aromatici — verificate). Le due funzioni della similarità finta sono state **rimosse**, non scavalcate: lasciarle in giro le avrebbe rimesse in uso alla prima modifica, e il banco controlla che non esistano più.

Una sola implementazione di Tanimoto. Il laboratorio ne aveva una propria, che concordava con quella del motore sui casi normali ma rispondeva 0 dove il motore risponde 1 (il caso di due impronte vuote). Ora la pagina carica `bsi-cheminfo.js` e chiama quello: `test_cheminfo` confronta le due strade su tutte e 28 le coppie di riferimento e pretende scarto **esattamente zero**.

3-ter. Il testo alternativo delle figure non si inventa

La guida di biochimica porta **98 figure**. Sostituendola, il banco di accessibilità l'ha bocciata: nessuna aveva un attributo `alt`.

La via comoda era `alt=""`, e il banco l'avrebbe accettata — il commento nel suo codice dice, correttamente, che per un'immagine **decorativa** è la cosa giusta: dice allo screen reader di saltarla. Ma queste sono figure di biochimica, cioè informazione. Marcarle come decorative avrebbe fatto passare il controllo dicendo a chi usa uno screen reader di ignorare 98 diagrammi: un verde vuoto, della stessa famiglia del «contrasto 0» che non copriva i pannelli nuovi (§3-bis) e del 100 % di copertura che sommava gli intervalli sbagliati.

La via onesta era a disposizione: ogni immagine sta dentro un `<figure>` con la sua `<figcaption>`, e **le didascalie le ha scritte l'autore del documento**.

Figure	62, per 98 immagini
Figure con una sola immagine	26 — l'alt è la didascalia, meno l'etichetta «Figura N.»
Figure con due pannelli	36
Didascalie di coppia divise fra i due pannelli	33 su 36
Coppie con didascalia condivisa	3 — non si dividono in modo inequivocabile

Le 36 didascalie di coppia distinguono tutte i due pannelli con «a sinistra» e «a destra»: dove la divisione è inequivocabile, ogni immagine riceve la propria metà della frase. Dove non lo è, le due immagini condividono la didascalia intera — verboso da ascoltare, ma **non può essere sbagliato**, e una descrizione sbagliata di una figura è peggio di una verbosa.

Perché non tentare una divisione più aggressiva. Si potevano spremere anche le 3 restanti con espressioni regolari più elastiche. Una divisione che sbaglia produce la frase «questa immagine mostra X» accanto a un'immagine che mostra Y, e lo screen reader la legge con la stessa sicurezza di quelle giuste. Il ripiego è rumoroso; l'errore è invisibile.

Misurato dopo l'intervento: **98 su 98 con testo alternativo, nessuno vuoto**, contrasto **0** su 1 897 elementi di testo.

3-quater. Da prototipo a strumento di lavoro

Le funzioni descritte in §3-bis bastavano a dire qualcosa di difendibile su un insieme di molecole. Non bastavano a **lavorarci**: un gruppo di chemioinformatica, il primo giorno, chiede di cercare una sottostruttura su tutto l'insieme, di vedere la tabella SAR, e di sapere che cosa succede all'attività se sostituisce un cloro con un metile.

3-quater.1 Che cosa la libreria aveva, e che cosa non ha

Prima di progettare si è **sondata** MinimalLib 2025.03.4 all'esecuzione, invece di assumere. Sondare per primo ha cambiato il progetto: tre delle capacità qui sotto non erano state usate perché non si sapeva che ci fossero.

C'è	A cosa serve
<code>SubstructLibrary</code>	Ricerca per sottostruttura con pattern fingerprint: scarta in blocco le molecole che non possono corrispondere, invece di provare l'isomorfismo su ognuna
<code>get_rxn</code> · <code>Reaction.run_reactants</code>	Trasformazioni chimiche. È ciò che permette di tagliare un legame, e da lì vengono coppie corrispondenti e tabella SAR
<code>generate_aligned_coords</code>	Allineare le molecole a un nucleo comune
<code>get_molblock</code> · <code>get_v3Kmolblock</code>	Esportazione SDF , il formato con cui si scambiano insiemi fra gruppi e programmi

Non c'è	Conseguenza dichiarata
<code>cleanup</code> , <code>neutralize</code>	La standardizzazione si ferma al frammento maggiore e allo SMILES canonico: le cariche non vengono neutralizzate
<code>canonical_tautomer</code>	Due tautomeri scritti in modo diverso restano due voci distinte
<code>FragmentOnBonds</code> , <code>RWMol</code>	Nessuna modifica diretta delle molecole: il taglio passa per una reazione
Sottostruttura massima comune (MCS)	Il nucleo di una tabella SAR va fornito , non viene dedotto. Il pannello offre otto nuclei pronti e il campo libero

3-quater.2 Il taglio, e perché ne servono due regole

Una reazione SMARTS spezza un legame e marca i due capi con un atomo fittizio. Verificato all'esecuzione: `CC0c1ccccc1` dà tre tagli con la regola fine ($\text{CH}_3\text{-CH}_2$, $\text{CH}_2\text{-O}$, O-arile) e due con quella grossa; il benzene e il metano non ne danno nessuno.

Regola	Taglia	Quando serve
fine (predefinita)	Qualunque legame singolo aciclico, compresi i sostituenti terminali Cl, CH_3 , OH, F	Tabella SAR e trasformazioni fini ($\text{Cl} \rightarrow \text{CH}_3$)
grossa (stile BRICS)	Esclude gli atomi terminali	Insiemi grandi, dove i tagli fini sono troppi; produce parti variabili più grandi («clorofenile $\rightarrow$ fenile»)

La regola fine è nata da un difetto. La prima stesura usava solo quella grossa, e la tabella SAR della serie di prova **perdeva il cloro sull'anello**: trovava il sostituito sull'azoto e mancava proprio la colonna che interessa, perché il cloro è terminale. La regola fine è un soprainsieme della grossa: ogni taglio che la grossa trova, lo trova anche la fine.

3-quater.3 Coppie molecolari corrispondenti

Due molecole formano una coppia quando, tagliando un legame in ciascuna, restano con lo **stesso contesto** e due parti variabili diverse. La differenza di attività è attribuita a quella sostituzione e a nient'altro — ed è il motivo per cui questa lettura batte una correlazione su tutto l'insieme, che media su molecole diverse per dieci cose.

Verificata su una serie **costruita con effetti noti**: se l'analisi non li ritrova non è utilizzabile su dati veri.

Trasformazione	Attesa	Trovata	Coppie concordanti
clorofenile → fenile	-1,0	-1,0	2 su 2
metilfenile → fenile	-0,5	-0,5	2 su 2
metile → cloro	+0,5	+0,5	2 su 2
etilammide → propilammide	+0,2	+0,2	3 su 3

Sui 28 inibitori dell'esempio, presi da ChEMBL: **449 coppie, 98 trasformazioni** viste almeno due volte, 199 viste una sola, in 133 ms. In cima alla lista **CF₃ → SO₂NH₂ con Δ mediano -2,65** su due coppie concordanti.

Due scelte dichiarate:

- la **direzione è normalizzata** sull'ordine alfabetico delle due parti.

Senza di essa lo stesso effetto comparirebbe due volte, con mediane opposte, e nessuna delle due avrebbe il numero di coppie giusto;

- le trasformazioni viste **meno di due volte** sono escluse dalla tabella e

contate a parte. Una trasformazione vista una volta con $\Delta = +3$ non è una scoperta: è un aneddoto, e metterla in cima farebbe prendere decisioni su di essa.

La colonna «concordi» è quella che decide se fidarsi. Una mediana di +1,0 su tre coppie di cui una a -2,0 non è la stessa cosa di +1,0 su tre coppie tutte positive, e la mediana da sola non lo dice.

3-quater.4 La tabella SAR, e come si trova la posizione

Il punto difficile non è trovare i sostituenti: è sapere in quale **posizione** sta ognuno. Senza MCS e senza modifica delle molecole, la soluzione sfrutta una proprietà del taglio: **il frammento che contiene il nucleo porta l'atomo fittizio esattamente nel punto di attacco**. Facendo corrispondere il nucleo a quel frammento si scopre su quale suo atomo è appeso il fittizio, e quindi quale posizione occupa il sostituito.

Ne viene anche un filtro necessario e gratuito: se il fittizio **non** è attaccato a un atomo del nucleo, il taglio è avvenuto dentro un sostituito e quel pezzo non è il sostituito intero. Si scarta.

Sui 28 inibitori, con nucleo benzamidico: **20 molecole con il nucleo, 2 posizioni, 8 escluse**. Le escluse non compaiono in tabella: metterle con le celle vuote le farebbe sembrare parte della serie con sostituenti non trovati.

Un difetto di denominazione, e come si è manifestato. `scaffoldMurcko()` restituiva il suo risultato in un campo chiamato `smiles`, ma quel valore **non è uno SMILES**: è un'impronta canonica dello scheletro, costruita perché due molecole con lo stesso scheletro producano la stessa stringa. Serve a raggruppare — pieghe, divisione per scaffold — non a interrogare. Il pannello SAR lo ha preso per uno SMILES e proponeva 6,6,6,6,7,...|0-13:1,... come nucleo; la decomposizione rispondeva «nucleo non interpretabile».

Il campo si chiama ora `chiave` e dichiara `eUnoSmiles: false`; `smiles` resta come alias. Il banco fissa che due scheletri uguali diano la stessa chiave, che scheletri diversi diano chiavi diverse, e che la chiave **non si rilegga come SMILES**. Il nome sbagliato di un campo è un difetto come un altro.

3-quater.5 Il rigore che un valutatore pretende

Cinque cose che un gruppo di modellistica mette in ogni rapporto, e la cui assenza è la prima obiezione in riunione.

	Metodo	Perché
Confronto fra modelli	Riferimento banale (predire la media), kNN su Tanimoto, regressione kernel — tutti sulle stesse pieghe raggruppate per scheletro	Confrontare un modello valutato su una divisione con un altro valutato su un'altra non è un confronto. E il riferimento banale sta in cima all'elenco, perché è il numero che ogni altro deve battere
Validazione annidata	Gli iperparametri (k, lambda) si scelgono su pieghe interne all'addestramento	Provarne dieci sull'insieme di prova e riportare il migliore gonfia il punteggio: quel numero non è una predizione, è il massimo di dieci tentativi
Intervalli conformi	Split-conformal, quantile $[(n+1)(1-\alpha)]$ dei residui assoluti su una porzione di calibrazione divisa per scaffold	«7,2» e «7,2 ± 0,3» sono due informazioni diverse, e solo la seconda dice se vale la pena sintetizzare. Una calibrazione su analoghi dell'addestramento darebbe intervalli troppo stretti proprio sulle molecole nuove
Arricchimento	EF a 1 %, 5 %, 10 % con il massimo possibile accanto; BEDROC (Truchon & Bayly, <i>J. Chem. Inf. Model.</i> 47 (2007) 488)	In uno screening non si guarda tutta la lista. Un ROC-AUC di 0,80 può nascondere una testa di lista senza un solo attivo, perché l'AUC premia anche l'ordine nella coda, che nessuno comprerà
Curva di apprendimento	Punteggio al variare della dimensione dell'addestramento, con l'insieme di prova intero a ogni punto	Risponde alla sola domanda che conta quando il modello è mediocre: serve più chimica o più dati?

Il verdetto del confronto è provato nei due versi, come il modello nullo. Su un segnale vero — attività proporzionale al numero di alogeni, su dieci nuclei distinti — la regressione kernel arriva a R^2 0,943 con margine 0,943 contro una dispersione di 0,035, e il verdetto è *supera*. Sulle **stesse molecole con etichette casuali** il migliore si ferma a $-0,265$, margine $-0,034$, e il verdetto è *non supera*. Una guardia che non scatta mai e una che scatta sempre sono lo stesso difetto.

L'arricchimento è verificato sui tre casi in cui il valore giusto si calcola a mano:

Ordinamento (2 attivi su 10)	AUC	EF@20 %	BEDROC
Perfetto: i due attivi in testa	1	5 — ed è il massimo possibile	1
Pessimo: i due attivi in coda	0	0	0, non un negativo
Attivi ai ranghi 2 e 5	0,75 = 12/16	2,5 = 1/0,4	0,119

Il caso pessimo è quello che conta: senza di esso non si saprebbe se BEDROC tocca lo zero o scende sotto, e un BEDROC negativo è il segno che manca il termine additivo della formula.

3-quater.6 Limiti di questo blocco

Limite	Conseguenza
Le coppie crescono col quadrato delle molecole	Misurato: 6 molecole 45 ms, 40 molecole 227 ms con 1 255 coppie. Oltre 300 molecole il pannello rifiuta di partire e lo dice, invece di bloccare la pagina
Il taglio è singolo	Una coppia che differisce per due sostituzioni insieme non viene trovata. È il limite dello schema a taglio singolo, condiviso con gli strumenti standard
La stessa trasformazione compare in più forme	Tagli in posizioni diverse danno contesti diversi per la stessa modifica chimica (<code>*CC>>*CCC</code> , <code>*NCC>>*NCCC</code> , <code>*C(=O)NCC>>*C(=O)NCCC</code>). È ridondanza attesa nello schema a taglio singolo, non un errore
Le cariche non sono neutralizzate e i tautomeri non canonizzati	MinimalLib non lo permette (§3-quater.1). Un insieme che mescola forme neutre e ioniche della stessa molecola le conta come voci distinte
Il nucleo della tabella SAR va fornito	Nessun MCS disponibile. Il pannello non propone nulla automaticamente, perché una proposta sbagliata è peggio di nessuna proposta

3.6 Predizione NMR per atomo: la fonte e lo scarto misurato

Il predittore $^1\text{H}/^{13}\text{C}$ che assegna ogni segnale a un ATOMO (`bsi-nmr.js`) non contiene numeri. Le tabelle di stima stanno in `bsi-prettsch.js` , trascritte riga per riga da:

E. Pretsch, P. Bühlmann, M. Badertscher, *Structure Determination of Organic Compounds — Tables of Spectral Data*, 4^a ed., Springer. §4.1 pp. 82-84 · §4.5 pp. 100-102 · §5.1 p. 170 · §5.2 pp. 178-179 · §5.3 p. 182 · §5.5 pp. 188-189

Stanno in un file separato perché si possano **controllare contro la pagina stampata** senza leggere il codice che le usa, e perché una riga sbagliata si corregga in un posto solo.

schema	formula	righe
benzeni monosostituiti, ^{13}C	$\delta = 128,5 + \sum Z_i$	91
benzeni monosostituiti, ^1H	$\delta = 7,34 + \sum Z_i$	66
etileni sostituiti, ^1H	$\delta = 5,25 + Z_{\text{gem}} + Z_{\text{cis}} + Z_{\text{trans}}$	42
alcani sostituiti, ^1H	$\delta = \text{base}(\text{CH}_3/\text{CH}_2/\text{CH}) + \sum Z_\alpha + \sum Z_\beta$	31
alchini terminali, ^1H	valore diretto per sostituyente	30
alifatici, ^{13}C	$\delta = -2,3 + \sum Z_i + \sum S_j$	24
correzioni steriche S_j	per grado del C osservato e dell'atomo α	4×4

Lo scarto è misurato, su molecole che non hanno scelto i parametri. Le molecole di prova sono divise in due insiemi: *taratura*, usate per scegliere valori e regole, e *validazione*, mai usate per quello. Il numero dichiarato nel pannello dell'applicazione è quello della validazione.

	scarto medio misurato
^{13}C , taratura (9 molecole)	0,71 ppm
^{13}C, validazione (22 molecole)	0,92 ppm
^{13}C , caso peggiore	4,9 ppm (cicloesanone)
^1H (14 molecole)	0,06 ppm
^1H , soli aromatici	0,03 ppm

Il banco (`test_nmr` , 56 controlli) pretende anche che la validazione resti **peggiore** della taratura: se diventassero uguali vorrebbe dire che una molecola è stata spostata da un insieme all'altro, e il numero non direbbe più niente.

Quello che resta sbagliato non è stato corretto a posteriori. Il difenile sbaglia il carbonio ipso di 4,6 ppm, perché l'incremento del fenile della tabella ($Z_1 = 8,1$) non lo descrive. Quel numero **non è stato ritoccato**: cambiare un valore trascritto perché una molecola di validazione non torna è esattamente il modo di rendere falso lo 0,92 ppm dichiarato sopra.

Limiti dichiarati. Non è un calcolo quantistico: non prevede gli effetti del solvente, non distingue conformeri (le correzioni conformazionali K della fonte sono trascritte ma valgono 0, perché la conformazione da uno SMILES non si ricava) e non fa NMR bidimensionale. Le costanti di accoppiamento vengono da una tabella di valori **tipici** per relazione geometrica, non calcolate. Gli **eteroaromatici sostituiti** non hanno, in questa fonte, una tabella di incrementi per posizione come l'hanno i benzeni: restano la previsione meno affidabile del modulo, e lo strumento di elucidazione lo dichiara abbassando la fiducia quando ne incontra uno.

3.7 NMR bidimensionale: COSY, HSQC, HMBC

`bsi-nmr2d.js` non contiene spostamenti: li chiede al predittore per atomo e costruisce le correlazioni **camminando il grafo**. È per questo che si poteva fare solo dopo l'arrivo delle tabelle di Pretsch: servono lo spostamento di *ogni* protone e di *ogni* carbonio, più l'indice dell'atomo che li porta.

mappa	regola topologica
HSQC	protone e carbonio a un legame (1J); segno invertito sui CH_2
COSY	due protoni a tre legami (H-C-C-H), escluso fra equivalenti
HMBC	protone e carboni a due o tre legami (2J , 3J)

Gli idrogeni **scambiabili** (O-H, N-H) non danno macchie fuori diagonale: si scambiano col solvente troppo in fretta perché l'accoppiamento si veda. Sulla diagonale del COSY ci sono, perché sono protoni come gli altri.

Verificato contando i cammini (`test_nmr2d` , 40 controlli), nei due versi: l'esafluorobenzene non dà macchie HSQC, il benzene non ne dà fuori diagonale nel COSY, il metano non ne dà in HMBC.

Limiti dichiarati. Non è una simulazione dell'esperimento: non ci sono intensità calcolate, artefatti, accoppiamento residuo né dipendenza dal tempo di miscelamento. In un HMBC vero alcune correlazioni a due legami non si vedono; qui ci sono tutte. Gli spostamenti ereditano l'incertezza misurata del predittore (0,9 ppm sul ^{13}C , 0,06 sul ^1H).

3.8 Geometria 3D: costruita dal grafo, non scaricata

`bsi-geom3d.js` costruisce le coordinate con la **geometria delle distanze**: una matrice di limiti da legami, angoli di valenza, diagonal di anello e contatti di van der Waals; posizioni iniziali casuali ma **riproducibili**, perché il generatore è seminato dallo SMILES; correzione iterativa delle violazioni. I sistemi aromatici si proiettano sul loro piano e le terne lineari si raddrizzano ruotando i rami come corpi rigidi, perché quelle due cose una distanza da sola non le impone.

Gli indici sono quelli del predittore NMR, e gli idrogeni si aggiungono in coda: è la condizione senza la quale il collegamento picco↔atomo↔3D illuminerebbe l'atomo sbagliato. Il visore 3D che pesca da PubChem non poteva essere usato per questo — la numerazione di un SDF non ha nessun rapporto con quella di RDKit.

Misurato contro i valori noti (`test_geom3d` , 29 controlli): C-C 1,54 Å, C=C 1,34, C≡C 1,20, aromatico 1,39, C-H 1,09; angolo tetraedrico 109,5°, aromatico 120,0°, alchino 180,0°. **Nei due versi**: benzene piano (0,00 Å), cicloesano **non** piano (0,34). Su molecole vere il residuo resta sotto 0,03 Å fino a una trentina di atomi e arriva a 0,31 Å su una molecola di 76.

Limiti dichiarati. Non è un campo di forze e non minimizza un'energia: minimizza violazioni geometriche. Non sceglie il conformero più stabile e non tratta la stereochimica — un centro R e il suo enantiomero escono uguali.

3.9 Dal documento allo svolgimento: che cosa è dedotto e che cosa è letto

`bsi-documento.js` apre il file; `bsi-quesito.js` riconosce i dati nel testo; `bsi-elucida.js` svolge. Sono tre passi separati **di proposito**, perché sbagliano in modi diversi e confonderli nasconde l'errore: se il riconoscimento legge «1715» come banda IR quando era una massa, lo svolgimento che segue è impeccabile e la conclusione è sbagliata. Per questo il pannello mostra **la tabella dei dati letti sopra lo svolgimento**, con scritto accanto a ognuno da dove viene.

Il riconoscimento è per sezione, non per numero. Una banda IR a 1738 e una massa a 150 sono entrambe numeri: distinguerli dal solo valore è impossibile. Si cerca l'etichetta della tecnica (IR, MS, ¹H NMR, ¹³C NMR) e si legge quello che viene dopo, fino alla fine del capoverso o all'etichetta successiva.

Quello che non fa. Non c'è nessun modello linguistico: ci sono espressioni regolari e un motore di regole spettroscopiche. Se il testo scrive i dati in una forma non prevista, i dati **non** vengono letti — e il modulo lo dichiara invece di svolgere a metà. Lo svolgimento arriva fino a dove arrivano le regole: gruppi funzionali compatibili, frammenti, conteggi. **La struttura finale non viene proposta**, perché proporla vorrebbe dire indovinare; una struttura la si può scrivere e il programma la **confronta** con i dati, dicendo quali segnali tornano e quali no.

Non c'è riconoscimento ottico dei caratteri. Una pagina scansionata contiene pixel, non lettere: il testo non si legge, e il modulo lo dichiara invece di restituire una stringa vuota come se il documento fosse vuoto. Le pagine restano visibili, e da lì passa l'estrazione della traccia dai pixel.

4. Costanti fisiche e dati tabulati

La ricerca delle costanti fisiche procede per livelli di specificità decrescente (corrispondenza esatta → simbolo → parole significative → sottostringa di almeno 4 caratteri) e **raccoglie tutte le candidate**: se ne restano più d'una, la richiesta viene rifiutata con l'elenco delle possibilità anziché restituire arbitrariamente la prima. Un valore fisico sbagliato restituito con sicurezza è peggio di una domanda di chiarimento.

Le molecole d'esame (`MOLECOLE_ESAME`) sono tabulate con valori verificati; il riconoscimento dei gruppi da SMILES usa un campo `consuma`, così che ogni gruppo rimuova la porzione di struttura che ha spiegato e non si producano conteggi sovrapposti.

5. Automazione della verifica

Tutti i controlli descritti sono eseguibili e ripetibili. Al momento della stesura la batteria comprende, fra gli altri:

Banco	Oggetto	Controlli
<code>audit_farmaci</code>	struttura ↔ peso, duplicati, formula ricostruita contro ChEMBL, deviazioni registrate con la loro ragione	263 voci

Banco	Oggetto	Controlli
test_spettri	riconoscimento gruppi su molecole di riferimento	36
test_assi / test_assi_canvas	convenzioni degli assi (SVG e canvas)	19
test_costanti	ricerca delle costanti fisiche e rifiuto delle ambiguità	45
audit_dati	coerenza dei dati tabulati	29
verifica_guida	corrispondenza fra ciò che la documentazione promette e ciò che il codice fa	71

L'ultimo banco merita una menzione: verifica che le affermazioni contenute nella documentazione utente corrispondano al comportamento reale del codice. Una promessa non mantenuta dalla documentazione è un difetto al pari di un errore di calcolo, e viene trattata come tale.

6. Dichiarazione di trasparenza

Questo documento descrive controlli **effettivamente implementati ed eseguibili**, con i risultati realmente ottenuti e i limiti dei predittori. Alla versione bsi-v188 gli errori residui sulla banca dati farmaci sono **zero**: le 21 deviazioni che restano sono voci senza struttura, ciascuna con il proprio motivo registrato, non errori taciuti. Le percentuali di copertura e i conteggi riportati sono prodotti dagli strumenti citati e riproducibili eseguendoli.

Dove un dato non è verificabile con gli strumenti a disposizione, lo si dichiara anziché presentarlo come verificato.

Documento aggiornato alla versione bsi-v192.