

Architettura dell'Agente AI "Spectra" — BioSpecInfo

Campo	Valore
Progetto	BioSpecInfo — componente Spectra (copilota AI agentico)
Autore	Samuele Pio Provenzano
Relatore tesi	Prof. Savino Longo — Università degli Studi di Bari Aldo Moro
Componente	<code>bsi-ai-hub.js</code> — 5.537 righe, nessuna dipendenza runtime
Tipo	Agente conversazionale multi-provider con esecuzione di strumenti lato client
Repository	<code>samupropiol-ship-it/BioSpecInfo-v11</code>
Versione documentata	Service Worker <code>bsi-v139</code>

1. Sintesi esecutiva

Spectra è un **agente** — non un semplice wrapper su un modello linguistico. La differenza è misurabile: il modello non risponde a memoria sui dati quantitativi, ma **invoca strumenti deterministici** che calcolano il risultato, e il ciclo di controllo gli permette di **concatenare fino a 10 chiamate** verificando ogni passaggio prima di rispondere.

L'architettura affronta tre problemi che distinguono un agente utilizzabile da una demo:

- Fondatezza (*grounding*)** — un dato chimico inventato può essere pericoloso. 32 strumenti coprono calcolo, banche dati pubbliche e i dataset interni dell'applicazione; il prompt di sistema vieta esplicitamente di citare valori numerici a memoria.
- Trasparenza** — il ragionamento del modello è mostrato in tempo reale e conservato accanto alla risposta, insieme all'elenco degli strumenti effettivamente invocati. L'operato dell'agente è verificabile a posteriori.
- Portabilità fra fornitori** — un unico registro di strumenti viene tradotto nei tre formati di *function calling* oggi in uso (OpenAI-compatibile, Anthropic, Gemini), così l'agente funziona identico su undici configurazioni di modello, sei delle quali gratuite.

2. Architettura

2.1 Vista d'insieme



Non esiste un backend. Le chiavi API restano nel `localStorage` del browser e viaggiano solo verso il fornitore scelto: nessun dato transita da server di BioSpecInfo, che non esistono.

2.2 Ciclo agentico

Ad ogni giro il ciclo: invia la cronologia (ultimi 40 turni) più il prompt di sistema e lo schema dei 32 strumenti → riceve la risposta in *streaming* → se contiene chiamate a strumenti le esegue **tutte** → ricostruisce il turno assistente nel formato nativo del fornitore → ripete.

Tre condizioni di uscita: nessuna chiamata a strumenti (risposta finale), `MAX_ROUNDS = 10` esaurito, o interruzione dell'utente.

2.3 Registro strumenti neutrale rispetto al fornitore

Gli strumenti sono definiti una sola volta in JSON-Schema e tradotti a runtime:

Famiglia	Formato richiesto
Anthropic	<code>{name, description, input_schema}</code>
Gemini	<code>[{functionDeclarations: [...]}]</code>
OpenAI-compatibile	<code>{type:"function", function:{...}}</code>

Lo stesso vale per i messaggi: i turni con chiamate a strumenti vengono serializzati nella forma nativa di ciascun fornitore e conservati in un campo `_native`, così una conversazione resta

coerente anche cambiando modello.

2.4 Nessun nome di modello cablato

Un nome di modello scritto nel codice è una bomba a orologeria: funziona finché il fornitore non ritira quel modello, e allora l'applicazione si ferma con un 404 che l'utente non può risolvere. È successo due volte in questo progetto:

Fornitore	Errore	Quando
Google	<code>models/gemini-1.5-flash is not found for API version v1beta</code>	ritiro da <code>v1beta</code>
Groq	<code>The model llama-3.3-70b-versatile does not exist or you do not have access to it</code>	deprecato il 17/06/2026

Su OpenRouter il problema è strutturale: gli id dei modelli gratuiti cambiano di continuo, per costruzione.

La correzione non è scrivere il nome nuovo — sarebbe la stessa bomba con la miccia più lunga — ma **togliere il nome** e chiederlo all'API, che sa quali modelli esistono *per quella chiave*. Il che risolve anche l'ambiguità del messaggio di Groq: «non esiste» **oppure** «non ci hai accesso» sono casi diversi, e un elenco per chiave li distingue.

Ogni configurazione con `modelliCandidati` parte da `model: null` e viene risolta a runtime. Le due famiglie hanno strategie diverse perché i loro nomi lo sono:

Gemini — punteggio per versione. I nomi seguono uno schema regolare (`gemini-<major>.<minor>-<famiglia>`), quindi si può ordinare: versione più recente, famiglia `flash`, con penalità per varianti sperimentali, `preview` e `-lite`; scartati i modelli senza `streamGenerateContent` e quelli non conversazionali (embedding, immagini, audio nativo, Live API). Quando uscirà Gemini 3.0 verrà scelto da solo.

Famiglia OpenAI — i candidati in ordine di preferenza. Qui i nomi non sono confrontabili fra loro (`openai/gpt-oss-120b` contro `qwen/qwen3.6-27b`), e un punteggio automatico sceglierebbe male. Si interroga `GET /models` e si prende **il primo candidato ancora esistente**: l'ordine della lista è la preferenza, e l'elenco serve a saltare quelli spariti. Solo se nessun candidato sopravvive si ricorre a un punteggio generico sui modelli disponibili — che scarta trascrizione, sintesi vocale, embedding e classificatori, e a parità d'altro preferisce il modello più grande.

Tre livelli di riserva in entrambi i casi: elenco dei modelli → sonda dei candidati → primo candidato, lasciando parlare l'errore vero della chiamata di generazione invece di inventarne uno.

La scelta resta in cache sette giorni per fornitore, legata a un'impronta FNV-1a a 32 bit della chiave (chiavi diverse vedono cataloghi diversi; la chiave in chiaro non viene mai duplicata). Se il modello viene ritirato *mentre* è in cache, il 404 — o un 400 il cui testo parla di modello, come fa OpenRouter — invalida la cache, ririsolve e ritenta **una volta sola**: un flag impedisce il ciclo infinito quando anche il modello nuovo fallisce.

Anthropic resta l'eccezione voluta: i suoi modelli sono a pagamento, scelti esplicitamente dall'utente e con deprecazioni annunciate con largo anticipo.

I sei servizi gratuiti

La qualità gratuita non è tutta uguale, e la differenza conta: un modello da 8 miliardi di parametri non regge un problema di chimica fisica in più passaggi.

Servizio	Modelli	Il compromesso
GitHub Models	GPT-4.1, o4-mini, DeepSeek, Llama 4	Il più capace fra i gratuiti, e non richiede un account nuovo: basta un token del proprio GitHub. In cambio 10 richieste/minuto e 50 al giorno
NVIDIA NIM	DeepSeek R1, Qwen3 235B, Llama 4	Modelli enormi, compresi quelli che ragionano. Crediti a esaurimento, non si rinnovano
Mistral	Large, Medium	~1 miliardo di token al mese. Richiede verifica telefonica e consenso all'uso dei dati per l'addestramento
Groq	GPT-OSS 120B, Qwen3	Il più veloce, generoso sui volumi
Google Gemini	Gemini Flash	Buon contesto, generoso
OpenRouter	instradatore automatico	Sceglie da solo fra i gratuiti che sanno usare gli strumenti

Nessuno di questi eguaglia un modello di frontiera a pagamento sui problemi più difficili; GitHub Models e NVIDIA NIM ci vanno vicino, al prezzo di tetti di richieste bassi. Per questo l'elenco resta e la scelta è dell'utente, invece di imporre un solo servizio.

2.5 Il proxy opzionale — Spectra senza chiave

La chiave API vive nel browser dell'utente: senza backend non c'è alternativa, ed è il limite dichiarato apertamente in fondo a questo documento. Ogni visitatore deve procurarsi la propria chiave gratuita e incollarla.

[proxy/spectra-proxy.js](#) è la via d'uscita, e sta **fuori** dalla pagina: un Worker Cloudflare (piano gratuito) che tiene le chiavi come segreti lato server. Quando è configurato, il browser non contiene nessuna chiave e chi apre BioSpecInfo usa Spectra senza inserire niente.

Non è un semplice inoltrare:

- **Il percorso passa tale e quale.** La rotta è `/<fornitore>/<percorso>`, e il resto viene inoltrato come arriva: il proxy non conosce i formati delle API e continua a funzionare quando Spectra cambia modello o parametri.
- **Più chiavi per fornitore, con subentro automatico.** Ogni segreto è una lista separata da virgole; su [429](#) (quota) o [401/403](#) (chiave revocata) si passa alla successiva nella stessa richiesta. Su [400](#) no: è un errore nella richiesta e si ripeterebbe identico.
- **Lo streaming non viene bufferizzato:** il corpo della risposta passa direttamente, altrimenti le risposte comparirebbero tutte insieme alla fine.
- **Non è un relay aperto.** Credenziali che arrivano dal client (`Authorization`, `x-api-key`, `?key=`) vengono scartate e sostituite: nessuno può usare il proxy per far viaggiare una chiave

propria.

- **Tre freni** contro l'abuso: elenco di origini ammesse, limite per IP e tetto giornaliero.

Lato Spectra l'innesto e' in un punto solo. `GET /stato` dice quali fornitori il proxy copre davvero, cosi' non viene offerto come "senza chiave" un modello per cui manca il segreto; `buildRequest` instrada al proxy **e omette del tutto l'autenticazione**; `chiaveDaUsare()` restituisce un segnaposto perche' i controlli "manca la chiave" non blocchino l'invio — segnaposto che non lascia mai il browser.

Le due strade convivono: senza `PROXY_URL` tutto funziona come prima, e per i fornitori non coperti dal proxy Spectra continua a usare la chiave locale.

2.6 Ricominciare da capo

Tutto ciò che Spectra ricorda vive in `localStorage`: chat, cronologia, chiavi API, memoria persistente, schede di ripasso. Un pulsante "cancella cronologia" che togliesse solo le conversazioni non farebbe ripartire da capo — alla riapertura si ritroverebbe lo stesso stato.

Il punto delicato è che le chiavi hanno **due formati**: la mappa attuale (`bsi_api_keys`, una chiave per fornitore) e il formato singolo delle versioni precedenti (`bsi_api_key`). `getKeysMap()` migra automaticamente il secondo nel primo, quindi cancellare solo la mappa **fa riapparire la chiave vecchia** al primo accesso successivo. Vanno tolti entrambi — e con loro le cache dei modelli risolti, che senza chiave non hanno più significato.

Per questo l'elenco di ciò che l'applicazione scrive sta in un punto solo, `DATI_CANCELLABILI`, diviso in cinque gruppi con etichetta e descrizione. Il pannello di conferma si costruisce da lì: mostra quante voci esistono davvero per ciascun gruppo, disattiva quelli già vuoti e richiede un secondo clic esplicito. Spuntati di partenza solo chat e chiavi; memoria, ripasso e progressi del resto dell'app restano da scegliere a mano, perché cancellano lavoro che non c'entra con il ripartire da capo della conversazione.

Restano fuori di proposito la licenza PRO, il periodo di prova e l'identità del dispositivo: sono dati che l'utente non si aspetta di perdere svuotando una chat, e una licenza non si cancella per sbaglio. Il pannello lo dichiara.

Dopo la cancellazione viene azzerato anche lo stato in memoria del processo — elenco dei fornitori coperti dal proxy, modello risolto per ciascun provider — altrimenti resterebbe valido fino al ricaricamento della pagina, e Spectra continuerebbe a usare un modello scelto con una chiave che non esiste più.

3. I 32 strumenti

Area	Strumenti
Calcolo generale	calcola, risolvi_equazione, analisi_dati
Chimica generale	bilancia_equazione, stechiometria, massa_molecolare, converti_unita, costante_fisica
Chimica fisica	termodinamica, equilibrio_acido_base, cinetica, gas_e_soluzioni, elettrochimica
Struttura e spettri	spettroscopia, quantistica_e_spettroscopia, cristallografia
Scienze della vita	biochimica, farmacocinetica, valuta_druglikeness
Fisica	astrofisica, nucleare, statistica_inferenziale
Banche dati esterne	cerca_pubchem (NIH), cerca_letteratura (PubMed), ricerca web
Dati interni	cerca_nel_database (9 dataset), cerca_molecola
Controllo app	naviga_sezione (84 sezioni), apri_strumento (12 laboratori), stato_app
Memoria	ricorda, ricordi
Animazioni	apri_animazione (6 meccanismi di reazione)

3.1 Dataset interni esposti

297 reazioni di sintesi · 118 elementi · 67 amminoacidi · 143 farmaci · 63 patologie · 39 strategie retrosintetiche · 36 interazioni farmacologiche · 29 vie metaboliche · 29 potenziali redox.

Sono i dati curati dall'autore per l'applicazione: l'agente li consulta come fonte primaria e ha istruzione di **segnalare le discrepanze** fra database e propria memoria invece di appianarle silenziosamente.

4. Decisioni ingegneristiche rilevanti

Questa sezione documenta le scelte non ovvie e il motivo per cui sono state prese. È la parte del documento che descrive il ragionamento progettuale.

4.1 Motore di calcolo senza `eval()`

Problema. Servire calcoli arbitrari di chimica fisica richiede un valutatore di espressioni. `eval()` lo risolverebbe in poche righe.

Perché è stato escluso. L'agente legge contenuti esterni non fidati (risultati PubChem, abstract PubMed, pagine web). Un'iniezione in quei contenuti potrebbe indurre il modello a emettere un'espressione ostile; con `eval()` quella stringa verrebbe eseguita nel contesto della pagina, **dove risiede la chiave API dell'utente**.

Soluzione. Parser a discesa ricorsiva con insieme *chiuso* di 27 funzioni e costanti. Non ha accesso all'ambito globale: può solo fare aritmetica. Verificato con 10 tentativi di evasione (`window.localStorage`, `constructor`, `this`, `fetch(...)`, chiamate a funzioni non in whitelist), tutti respinti, anche eseguendo il test in un browser reale.

4.2 Conservazione dei blocchi di ragionamento

Sui modelli con ragionamento adattivo i blocchi `thinking` fanno parte del turno assistente e devono essere **rimandati indietro identici, firma crittografica inclusa**, nel giro successivo di *tool use*. Scartarli fa rifiutare la richiesta.

L'implementazione accumula `thinking_delta` e `signature_delta` dallo stream e li reinserisce **in testa** al turno ricostruito. Verificato in test d'integrazione: firma preservata, ordine corretto.

4.3 Ripresa dei turni sospesi (`pause_turn`)

La ricerca web è uno strumento eseguito sui server del fornitore. Quando il suo ciclo interno esaurisce le iterazioni disponibili, la risposta termina con `stop_reason: "pause_turn"`.

Il turno va ripreso **rimandando indietro il turno assistente così com'è, senza aggiungere alcun messaggio utente**: è il server a riconoscere il blocco `server_tool_use` in coda e a riprendere da lì. Aggiungere un "continua" spezzerebbe il meccanismo.

4.4 Configurazione per modello, non globale

I quattro livelli Claude non accettano gli stessi parametri:

Modello	effort	Ricerca web	Note
Fable 5.1	<code>xhigh</code>	sì (8)	fallback su rifiuto; ragionamento sempre attivo
Opus 5	<code>high</code>	sì (6)	predefinito
Sonnet 5	<code>high</code>	sì (5)	
Haiku 4.5	non supportato	non supportata	inviarli produce HTTP 400

Su tutti i modelli recenti `temperature`, `top_p` e `budget_tokens` sono stati rimossi dall'API e la loro presenza causa un errore: nessuno dei quattro li invia. Ogni parametro è quindi condizionato al fornitore, non impostato globalmente.

4.5 Ingresso multimodale e lettura dei materiali

L'agente accetta immagini, PDF e file di testo, anche molti insieme, trattati come pagine consecutive di un unico documento. Tre vincoli hanno guidato l'implementazione:

- **Le immagini vengono ridimensionate a 2000 px** e ricomprese in JPEG prima dell'invio. Una foto da telefono passa da circa 1 MB a 440 KB: senza questo passaggio una singola immagine avvicinerebbe il tetto di richiesta e moltiplicherebbe il costo in token. 2000 px sono il minimo per leggere una grafia minuta — a 1600 px la scrittura piccola diventava illeggibile.
- **Il tetto di pagine dei PDF dipende dal modello**, non è una costante: 600 pagine per i modelli con finestra da 1M, 100 per quelli da 200K. Il conteggio avviene leggendo gli

oggetti `/Type` `/Page` nei byte del file, senza librerie.

- **Nella cronologia va una miniatura da 160 px**, non l'immagine inviata. Salvare quella grande (440 KB l'una) riempiva `localStorage` in una decina di foto, e a quota piena ogni scrittura successiva fallisce in silenzio.

Sei azioni rapide trasformano il materiale in un prodotto di studio (riassunto, mappa concettuale, schema, flashcard, domande d'esame, trascrizione) e due lo traducono. Per le trascrizioni l'agente ha istruzione di scrivere `[illeggibile]` invece di indovinare: un termine chimico inventato è peggio di una lacuna dichiarata.

4.6 Renderer di grafi proprio, senza CDN

Le mappe concettuali sono prodotte dal modello come diagrammi Mermaid e disegnate da un renderer scritto nell'applicazione (~190 righe): livelli per cammino più lungo dalle radici con interruzione dei cicli, riordino per baricentro dei predecessori su tre passate per ridurre gli incroci, output SVG con archi di Bézier.

La scelta di non caricare Mermaid da CDN nasce dalla natura offline-first dell'app: una mappa deve potersi disegnare anche senza rete. Le sintassi non coperte vengono riconosciute e lasciate come blocco di codice leggibile, invece di essere disegnate male.

4.7 Comando vocale con parola di attivazione

Ascolto continuo attivabile dall'utente: la frase «Hey Spectra» seguita dal comando lo invia automaticamente. Due dettagli non ovvi:

- il riconoscimento vocale del browser **termina da solo** dopo qualche secondo di silenzio e va riavviato, altrimenti l'ascolto muore alla prima pausa;
- vengono esaminate **tutte le alternative di trascrizione**, non solo la prima, e sono accettate le varianti fonetiche più comuni: il riconoscimento italiano rende "Spectra" in molti modi diversi.

Il rifiuto del permesso al microfono interrompe il ciclo invece di ritentare all'infinito. Il termine "spettroscopia", frequentissimo in questo dominio, è stato verificato come non attivante.

4.8 Guardia sui risultati non finiti

Un audit sistematico ha rivelato che, con input degeneri legittimi (lunghezza d'onda nulla, volume nullo, emivita nulla, transizione fra livelli identici), otto risolutori restituivano `ok: true` con `Infinity` o `NaN` fra i campi.

È il guasto più insidioso in questo contesto: un'eccezione si nota, un valore formalmente valido ma privo di senso viene riportato all'utente come corretto. La correzione è un controllo unico nel punto in cui transitano tutti i risultati: se un campo numerico non è finito, il risultato diventa un errore esplicito che nomina i campi e indica la causa probabile. Vale anche per gli strumenti aggiunti in futuro.

4.9 Degradazione controllata

- **Modelli senza *function calling* affidabile** (alcuni gratuiti): al primo errore riconducibile agli strumenti, la richiesta viene ripetuta una volta in modalità solo testo, invece di fallire.

- **Timeout di inattività (45 s)**, azzerato ad ogni byte ricevuto: una risposta lunga non viene troncata, ma una connessione morta viene segnalata subito con un messaggio esplicito.
- **Quota di `localStorage`**: lo storico è limitato (30 conversazioni, 100 messaggi) con potatura progressiva. Senza questo limite il superamento della quota faceva fallire *in silenzio* ogni scrittura successiva, **compreso il salvataggio della chiave API**.
- **Rifiuto dei classificatori** (`stop_reason`: `"refusal"`, HTTP 200): rilevato e comunicato, invece di presentarsi come risposta vuota.

5. Verifica

La verifica è stata condotta su tre livelli, con esiti registrati.

5.1 Correttezza numerica — confronto con valori di riferimento

Ambito	Caso	Atteso	Ottenuto
Bilanciamento	$\text{KMnO}_4 + \text{HCl} \rightarrow \dots$	2:16:2:2:8:5	✓ esatto
Massa molecolare	$\text{K}_4[\text{Fe}(\text{CN})_6]$ (annidata)	368,35	368,345
Massa molecolare	$\text{CuSO}_4 \cdot 5\text{H}_2\text{O}$ (idrato)	249,68	249,677
Equilibrio	acido acetico 0,1 M, K_a $1,8 \cdot 10^{-5}$	pH 2,874	2,875
Termodinamica	ΔG ($\text{N}_2\text{O}_4/\text{NO}_2$) a 298 K	+4,79 kJ/mol	✓
Cinetica	E_a da $k(300\text{ K})$ e $k(320\text{ K})$	55,3 kJ/mol	55,33
Gas reali	van der Waals CO_2	scostamento −10 %	−10,13 %
Spettroscopia	M+2 del bromo	97,3 %	✓
Biochimica	glicilglicina	132,12 Da	✓
Farmacocinetica	$t_{1/2}$ da V_d 50 L, Cl 5 L/h	6,93 h	✓
Astrofisica	picco di emissione solare (Wien)	501,5 nm	501,52
Astrofisica	velocità di fuga terrestre	11,19 km/s	11,186
Nucleare	energia di legame ^{56}Fe	8,79 MeV/nucleone	8,790
Statistica	t critico, 95 %, $df = 4$	2,7764	✓
Cristallografia	densità del rame (fcc)	8,96 g/cm ³	8,935

I p-value non sono tabulati: sono calcolati con la funzione beta incompleta regolarizzata (frazione continua di Lentz) e la gamma incompleta.

5.2 Robustezza — casi che devono fallire

Verificato che vengano **respinti**: equazioni non bilanciabili, formule con parentesi non bilanciate o elementi inesistenti, specie assenti dall'equazione, tipi di database non validi, e i 10 tentativi di iniezione nel motore di calcolo.

5.3 Integrazione — browser reale

Test automatizzati con Chromium *headless* su tutte le 14 pagine dell'applicazione: nessun errore JavaScript, nessuna risorsa mancante. Percorse una per una le 84 sezioni di [index.html](#) e i 18 tab della sezione Astrochimica. Ispezionato il corpo delle richieste per i quattro livelli Claude, e simulato un ciclo completo con ricerca web, sospensione e ripresa del turno.

6. Riepilogo quantitativo

Metrica	Valore
Righe del componente	5.537
Strumenti	32
Configurazioni di modello	11 (6 gratuite)
Aree scientifiche coperte	13
Record nei dataset interni esposti	oltre 800
Giri massimi del ciclo agentico	10
Cronologia inviata al modello	40 turni
Dipendenze runtime	nessuna

7. Limiti dichiarati

Documentati per onestà tecnica; sono scelte consapevoli, non omissioni.

- **La chiave API risiede nel browser** — a meno di pubblicare il proxy. Nella configurazione predefinita la chiave non lascia il dispositivo, ma è accessibile a chi ha accesso a quel browser, e ogni utente deve procurarsi la propria. Il Worker della sezione 2.5 toglie questo limite spostando le chiavi su un server, al prezzo di un componente da mantenere fuori dalla pagina: è una scelta di distribuzione, non un requisito.
- **Gli strumenti di rete dipendono dalla disponibilità dei servizi.** PubChem e PubMed sono interrogati direttamente dal browser; in caso di irraggiungibilità lo strumento restituisce un errore esplicito e l'agente ha istruzione di dichiararlo, non di sostituirlo con una stima.
- **I risolutori applicano modelli semplificati** dove la letteratura ne prevede di più raffinati (per esempio Woodward-Fieser per l'UV, o le rese in ATP con rapporti P/O medi). Ogni strumento dichiara il metodo usato nel proprio risultato.
- **La verifica è funzionale e numerica**, non formale: non esiste prova di correttezza dei risolutori, ma un insieme di casi di riferimento tratti dalla letteratura didattica.

