

# BioSpecInfo

Accuratezza scientifica e provenienza dei dati — BioSpecInfo

---

Samuele Pio Provenzano

Versione **bsi-v185** · commit `15799c2`

Generato il 2026-10-03

Documento generato automaticamente dal sorgente Markdown versionato nel repository. La versione e il commit stampati in ogni piè di pagina identificano esattamente lo stato del software descritto.

# Accuratezza scientifica e provenienza dei dati — BioSpecInfo

| Campo              | Valore                                                                                                                                               |
|--------------------|------------------------------------------------------------------------------------------------------------------------------------------------------|
| Software           | BioSpecInfo                                                                                                                                          |
| Autore             | Samuele Pio Provenzano                                                                                                                               |
| Versione descritta | bsi-v185                                                                                                                                             |
| Scopo              | Documentare come vengono generati i dati scientifici mostrati dall'applicazione, con quale metodo sono verificati, e quali sono i limiti dichiarati. |

**Perché questo documento esiste.** Un'applicazione didattica di chimica può essere ineccepibile dal punto di vista informatico e sbagliata dal punto di vista scientifico, e l'utente non ha modo di accorgersene: un peso molecolare plausibile, uno spettro dall'aspetto convincente e una struttura sbagliata si presentano tutti allo stesso modo. Questo documento descrive i controlli che rendono quell'errore **visibile e automatico**, e dichiara ciò che resta fuori dalla loro portata.

## 1. Principio: ogni dato scientifico deve poter essere contraddetto

Il criterio adottato in tutta l'applicazione è che un dato scientifico non si consideri verificato perché *sembra* giusto, ma perché **esiste un secondo dato indipendente che lo confermerebbe o lo smentirebbe**. Dove questo secondo dato non esiste, il limite viene dichiarato invece di essere colmato con una stima presentata come misura.

Tre applicazioni concrete di questo principio:

| Ambito             | Prima affermazione             | Seconda affermazione indipendente | Controllo                                                             |
|--------------------|--------------------------------|-----------------------------------|-----------------------------------------------------------------------|
| Banca dati farmaci | struttura (SMILES)             | peso molecolare di letteratura    | il peso ricalcolato dalla struttura deve coincidere                   |
| Spettri IR / NMR   | gruppi funzionali riconosciuti | struttura molecolare via RDKit    | i gruppi si cercano sul grafo, non sul testo dello SMILES             |
| Costanti fisiche   | valore tabulato                | simbolo e unità di misura         | la ricerca rifiuta le corrispondenze ambigue invece di sceglierne una |

## 2. Banca dati farmacologica — 233 voci

### 2.1 Il metodo di verifica

Ogni voce dichiara **due** proprietà della stessa molecola: la struttura, in notazione SMILES, e il peso molecolare. Sono affermazioni indipendenti — la prima descrive la connettività atomica, la seconda è un numero preso dalla letteratura — e quindi confrontabili:

peso calcolato da RDKit sulla struttura ↔ peso dichiarato in tabella

Uno scarto superiore a **0,6 u** (tolleranza che copre gli arrotondamenti e le piccole differenze fra tabelle di masse atomiche, ma non un errore reale, che vale decine di unità) indica che almeno una delle due affermazioni è sbagliata.

Il controllo è automatizzato ( `tools/verifica-farmaci.js` , eseguibile da chiunque disponga del repository) e non richiede giudizio umano: non chiede di fidarsi di nessuna fonte, confronta due numeri.

### 2.2 Cosa ha trovato

Applicato alle 143 voci preesistenti, il controllo ha individuato **89 errori**. La distribuzione è significativa: i **pesi molecolari erano corretti** — presi dalla letteratura — mentre le **strutture erano sbagliate**.

| Farmaco       | Struttura dichiarata                                            |
|---------------|-----------------------------------------------------------------|
| Ketamina      | un pirrolidinone non correlato                                  |
| Morfina       | struttura non corrispondente (in due voci distinte)             |
| Lorazepam     | privo dell'ossidril in posizione 3, che ne definisce l'identità |
| Atorvastatina | privo del gruppo anilidico                                      |
| Testosterone  | privo del doppio legame $\Delta^4$ dell'anello A                |

Più **7 farmaci duplicati** in categorie diverse, con dati talvolta divergenti fra le due copie.

### 2.3 Lo scarto come strumento diagnostico

Il valore numerico della differenza non è solo un allarme: indica **quale** frammento manca o è di troppo.

| $\Delta$ (u) | Interpretazione           | Caso reale                        |
|--------------|---------------------------|-----------------------------------|
| 28,05        | $C_2H_4$                  | ketamina, fentanil, morfina       |
| 16,00        | un atomo di ossigeno      | tetraciclina (un ossidril in più) |
| 14,02        | un gruppo $CH_2$          | doxiciclina                       |
| 2,02         | un doppio legame mancante | testosterone ( $\Delta^4$ )       |
| 0,98         | citosina ↔ uracile        | <b>sofosbuvir</b>                 |

L'ultimo caso merita una nota: lo scarto di 0,98 u corrisponde esattamente alla sostituzione di un gruppo –NH con un atomo di ossigeno, cioè alla differenza fra citosina e uracile. Il sofosbuvir è un analogo dell'**uridina**, e la struttura proposta conteneva la base sbagliata. Il numero ha indicato dove guardare.

## 2.4 Stato attuale e limiti dichiarati

|                                   |                        |
|-----------------------------------|------------------------|
| Farmaci in banca dati             | <b>178</b> (erano 143) |
| Con struttura verificata          | <b>157</b> (erano 153) |
| Difetti                           | <b>0</b>               |
| Deviazioni dichiarate e accettate | <b>21</b> (erano 25)   |

La verifica è **conforme**: nessuna voce presenta una struttura che contraddica il proprio peso molecolare. Le 21 deviazioni sono voci **prive di struttura**, ciascuna registrata con il proprio motivo in [evidence/deviazioni-note.json](#) e riportata nel rapporto di verifica.

**Difetto contro deviazione.** Il controllo distingue due situazioni che non vanno confuse:

- una struttura che **contraddice** il proprio peso è un difetto, e fa fallire

la verifica;

- una struttura **assente** può essere una deviazione accettabile — ma solo se

registrata esplicitamente, con il motivo. Una voce priva di struttura e **non** registrata fa fallire la verifica come qualunque altro difetto.

Registrare una deviazione è quindi una decisione consapevole, tracciata in git e visibile nel rapporto, non un modo per silenziare un controllo.

E va anche **revocata** quando non serve più. Dalla versione [bsi-v185](#) il banco fallisce anche nel caso opposto: una voce elencata nel registro che **ha** una struttura verificata è un permesso rimasto acceso a vuoto, e domani coprirebbe in silenzio una struttura sbagliata messa al suo posto.

## 2.4-bis Quattro voci uscite dal registro

Delle sei voci senza struttura, quattro sono state chiuse riprendendo la struttura da **ChEMBL** — una fonte indipendente da questo progetto — e verificandola con lo stesso confronto struttura ↔ peso molecolare che vale per tutte le altre.

| Voce                           | ChEMBL                       | Formula                                                        | Peso dichiarato | Peso calcolato |
|--------------------------------|------------------------------|----------------------------------------------------------------|-----------------|----------------|
| Digossina                      | <a href="#">CHEMBL1751</a>   | C <sub>41</sub> H <sub>64</sub> O <sub>14</sub>                | 780,94          | 780,95         |
| Vincristina                    | <a href="#">CHEMBL90555</a>  | C <sub>46</sub> H <sub>56</sub> N <sub>4</sub> O <sub>10</sub> | 824,96          | 824,97         |
| Tacrolimus topico (Protopic)   | <a href="#">CHEMBL269732</a> | C <sub>44</sub> H <sub>69</sub> NO <sub>12</sub>               | 804,02          | 804,03         |
| Tacrolimus sistemico (Prograf) | <a href="#">CHEMBL269732</a> | C <sub>44</sub> H <sub>69</sub> NO <sub>12</sub>               | 804,02          | 804,03         |

Il motivo registrato per la digossina diceva «ogni struttura provata si discosta di 14-30 u dal peso di letteratura»: il peso dichiarato era giusto, erano le strutture provate a essere sbagliate. Che il confronto sia reale e non compiacente si vede aggiungendo un solo carbonio alla struttura corretta — il banco segnala **Δ 14,04** e fallisce.

**Le due che restano non sono molecole singole**, e nessuna notazione SMILES le rappresenta:

- **Ivermectina** è una miscela di omologhi: almeno 80 % di B1a (C<sub>48</sub>H<sub>74</sub>O<sub>14</sub>) e non più del 20 % di B1b (C<sub>47</sub>H<sub>72</sub>O<sub>14</sub>). Il peso dichiarato, 875,10, è quello del solo componente B1a. Mostrarne la struttura farebbe passare l'omologo maggioritario per l'intero farmaco.

- **Artemetere/Lumefantrina (Coartem)** è l'associazione di due principi attivi distinti.

In entrambi i casi non manca una struttura: non ce n'è una sola da mostrare.

| Gruppo                                      | Voci | Natura                                                                                                                                                                                              |
|---------------------------------------------|------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>D-01</b> — non sono molecole singole     | 2    | ivermectina (miscela di omologhi B1a/B1b) e artemetere/lumefantrina (associazione di due principi attivi). Erano sei: le altre quattro sono state chiuse con la struttura da ChEMBL, vedi §2.4-bis. |
| <b>D-02</b> — non rappresentabili in SMILES | 19   | anticorpi monoclonali, proteine e peptidi (trastuzumab, pembrolizumab, insulina, semaglutide, ciclosporina A...). L'assenza è corretta, non una lacuna.                                             |

La scelta è deliberata: un dato sbagliato sostituito da un altro dato sbagliato non è un progresso, e l'assenza dichiarata è preferibile a una presenza non verificata.

## 3. Predizione spettrale

### 3.1 Riconoscimento strutturale, non testuale

I gruppi funzionali sono individuati con **pattern SMARTS applicati al grafo molecolare** tramite RDKit (`bsi-spettri.js`), non con espressioni regolari applicate alla stringa SMILES.

La differenza non è stilistica. Il metodo testuale precedente presentava due difetti strutturali:

1. **Esclusività.** I controlli erano organizzati in catene `else if`, per cui veniva riconosciuto **un solo gruppo funzionale per molecola**.

1. **Cecità alla struttura.** Una regex legge caratteri, non legami.

Il caso emblematico è l'**acido acetilsalilico** (`CC(=O)Oc1ccccc1C(=O)O`), che contiene sia un estere sia un acido carbossilico. Il riconoscimento testuale identificava solo l'estere; lo spettro IR risultante era privo della banda O-H allargata a ~3000 cm<sup>-1</sup> e del C=O acido a ~1690 cm<sup>-1</sup> — le due bande che identificano la molecola — e lo spettro <sup>1</sup>H NMR era privo del segnale del protone carbossilico a 11,6 ppm.

Il riconoscimento su grafo è **additivo per costruzione**: una molecola può presentare tutti i gruppi che possiede.

### 3.2 Convenzioni di rappresentazione

Le convenzioni degli assi non sono uniformi fra le tecniche, e sono verificate automaticamente ( `test_assi.js` , `test_assi_canvas.js` ) estraendo le etichette delle tacche dal disegno prodotto:

| Tecnica          | Ascissa                            | Verso                               | Ordinata                                     |
|------------------|------------------------------------|-------------------------------------|----------------------------------------------|
| IR               | numero d'onda ( $\text{cm}^{-1}$ ) | decrescente, $4000 \rightarrow 400$ | <b>trasmissione %</b> , bande verso il basso |
| $^1\text{H}$ NMR | $\delta$ (ppm)                     | decrescente, $14 \rightarrow 0$     | intensità, riferimento TMS a 0               |
| UV-Vis           | $\lambda$ (nm)                     | crescente, $200 \rightarrow 400$    | assorbanza                                   |
| MS               | m/z                                | crescente                           | abbondanza relativa                          |

### 3.3 Determinismo

Nessuno spettro contiene componenti casuali. Le versioni precedenti aggiungevano rumore pseudo-casuale alla traccia a ogni ridisegno, con la conseguenza che la stessa molecola produceva ogni volta uno spettro diverso e due spettri non erano confrontabili. Un profilo calcolato deve essere **riproducibile**: dove serve un fondo realistico si usa una funzione deterministica del numero d'onda.

Analogamente, nel predittore NMR le altezze dei picchi erano generate casualmente. In uno spettro  $^1\text{H}$  l'altezza è l'informazione quantitativa — l'integrazione — e inventarla è peggio che ometterla. Attualmente:

- dove il numero di protoni è noto, l'altezza è l'integrazione reale e

l'etichetta la riporta (es. `7,26 (4H)` );

- dove la predizione è un **intervallo** (es. «6,5–8,5 ppm»), si disegna la

fascia dell'intervallo con un segno sul valore tipico e altezza uniforme: il grafico indica *dove* cade il segnale senza affermare quanto sia intenso.

### 3.4 Effetti chimici modellati

| Effetto                            | Implementazione                                                                                   |
|------------------------------------|---------------------------------------------------------------------------------------------------|
| Coniugazione del carbonile         | abbassamento di $\sim 25 \text{ cm}^{-1}$ applicato <b>al singolo carbonile</b> , non globalmente |
| Estere fenolico                    | innalzamento a $\sim 1760 \text{ cm}^{-1}$                                                        |
| Intensità C-H                      | proporzionale al numero di gruppi $\text{CH}_2/\text{CH}_3$ presenti                              |
| Sostituzione dell'anello aromatico | bande "fuori dal piano" $900\text{--}690 \text{ cm}^{-1}$ distinte per orto/meta/para/mono        |
| Doppietto di Fermi delle aldeidi   | bande a $2820$ e $2720 \text{ cm}^{-1}$                                                           |
| Bande ammidiche I e II             | $1655$ e $1550 \text{ cm}^{-1}$                                                                   |

Verifica: l'acido acetilsalicilico produce estere arilico a  $1760\text{ cm}^{-1}$  e acido coniugato a  $1690\text{ cm}^{-1}$  — i due valori che lo identificano — mentre acetofenone (chetone coniugato,  $1690$ ) e acetato di etile (estere non coniugato,  $1735$ ) confermano che l'effetto è applicato in modo selettivo e non indiscriminato.

### 3.5 Limiti dichiarati

Gli spettri prodotti sono **predizioni basate su tabelle di gruppi funzionali**, non spettri misurati né simulazioni quantomeccaniche. Indicano dove cadono le bande dei gruppi presenti, con posizioni e intensità tabulate. **Non sostituiscono un database sperimentale** (SDBS, NIST) né una misura strumentale, e il grafico lo dichiara.

In particolare non sono modellati: accoppiamenti spin-spin del secondo ordine, effetti di solvente e concentrazione, bande di combinazione e sovratoni, polimorfismo allo stato solido.

## 3-bis. Chemioinformatica e modelli QSAR

### 3-bis.1 Da dove vengono i metodi

Nessuno dei metodi della sezione **Chemioinformatica** è inventato per l'occasione. Sono quelli in uso, con i riferimenti che li definiscono.

| Metodo                           | Riferimento                                                             | Come è implementato qui                                                                                                                 |
|----------------------------------|-------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------|
| <b>Coefficiente di Tanimoto</b>  | Rogers & Tanimoto, 1960                                                 | Bit in comune su bit in unione, con la convenzione $0/0 = 1$ dichiarata nel codice                                                      |
| <b>Impronte di Morgan / ECFP</b> | Rogers & Hahn, <i>J. Chem. Inf. Model.</i> 50 (2010) 742                | Da RDKit MinimalLib, raggio 2, 2048 bit                                                                                                 |
| <b>Chiavi MACCS</b>              | Durant <i>et al.</i> , <i>J. Chem. Inf. Comput. Sci.</i> 42 (2002) 1273 | Da RDKit MinimalLib, 166 chiavi                                                                                                         |
| <b>Regola dei 5</b>              | Lipinski <i>et al.</i> , <i>Adv. Drug Deliv. Rev.</i> 23 (1997) 3       | Sui descrittori RDKit, con il conteggio delle violazioni                                                                                |
| <b>Filtro di Veber</b>           | Veber <i>et al.</i> , <i>J. Med. Chem.</i> 45 (2002) 2615               | Legami ruotabili $\leq 10$ , TPSA $\leq 140\text{ Å}^2$                                                                                 |
| <b>QED</b>                       | Bickerton <i>et al.</i> , <i>Nat. Chem.</i> 4 (2012) 90                 | <b>Ricalcolato:</b> MinimalLib espone 43 descrittori ma non il QED. I parametri delle funzioni desiderabilità sono quelli dell'articolo |
| <b>Raggruppamento di Butina</b>  | Butina, <i>J. Chem. Inf. Comput. Sci.</i> 39 (1999) 747                 | Soglia sulla distanza di Tanimoto, capifila scelti per numero di vicini                                                                 |
| <b>Scheletri di Bemis-Murcko</b> | Bemis & Murcko, <i>J. Med. Chem.</i> 39 (1996) 2887                     | Sistemi ad anello più i legami che li collegano                                                                                         |
| <b>PAINS</b>                     | Baell & Holloway, <i>J. Med. Chem.</i> 53 (2010) 2719                   | Sottoinsieme dei pattern SMARTS, con il motivo della segnalazione                                                                       |

| Metodo           | Riferimento                                                | Come è implementato qui                                                        |
|------------------|------------------------------------------------------------|--------------------------------------------------------------------------------|
| Allarmi di Brenk | Brenk <i>et al.</i> , <i>ChemMedChem</i> 3 (2008) 435      | Idem                                                                           |
| SALI             | Guha & Van Drie, <i>J. Chem. Inf. Model.</i> 48 (2008) 646 | $\Delta$ attività / (1 – Tanimoto), sulle coppie sopra la soglia di similarità |

### 3-bis.2 Le quattro cose che rendono un QSAR onesto

Un modello QSAR è facilissimo da far sembrare buono. Le quattro precauzioni qui sotto sono quelle che distinguono un numero da una misura, e sono tutte verificate dal banco

`test_cheminfo`.

**Divisione per scheletro.** Con una divisione casuale, analoghi stretti della stessa serie finiscono da entrambe le parti: il modello ritrova ciò che ha già visto. La divisione per scheletro raggruppa le molecole per scheletro di Bemis-Murcko e assegna **scheletri interi** a una sola parte. L' $R^2$  che ne esce è più basso — ed è quello che sopravvive alla molecola nuova.

**Modello nullo per rimescolamento.** Lo stesso modello viene riaddestrato otto volte su etichette mescolate. Se il punteggio vero non supera il migliore dei sosia, il modello non ha imparato nulla di trasferibile, e il pannello lo dichiara con quelle parole. È il controllo che manca più spesso: senza di esso, un  $R^2$  di 0,4 su trenta molecole è indistinguibile dal caso.

**Dominio di applicabilità.** Una predizione su una molecola lontana da tutto ciò che il modello ha visto è un'estrapolazione, non una predizione. La distanza dal vicino più prossimo nell'insieme di addestramento è mostrata accanto a ogni valore predetto.

**Validazione incrociata raggruppata per scheletro.** Una divisione sola, su un insieme piccolo, è un numero rumoroso: su 28 molecole al 25 % l'insieme di prova ne contiene sette, e spostarne una muove l' $R^2$  di decimi. Le pieghe raggruppano per scheletro — nessuno scheletro sta in due pieghe — e il risultato viene dato come **media  $\pm$  deviazione**, non come cifra singola.

**Quanto conti, misurato sull'esempio dei 28 inibitori.** La divisione singola dà  $R^2$  **0,861**. La validazione a cinque pieghe dà **0,605  $\pm$  0,452**, con le singole pieghe a 0,861 · 0,538 · 0,795 · **-0,150** · 0,980. La divisione singola aveva pescato la piega fortunata. Le due cifre insieme dicono quello che nessuna delle due dice da sola: il modello funziona, ma dipende sensibilmente da quali molecole gli capitano in addestramento — e su un insieme di ventotto molecole è esattamente ciò che ci si deve aspettare.

### 3-bis.3 Limiti dichiarati

| Limite                                                        | Conseguenza                                                                                                                                                 |
|---------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Gli insiemi di esempio sono <b>piccoli</b> (28 e 40 molecole) | Servono a mostrare il metodo, non a produrre un modello utilizzabile. Su insiemi così, il modello nullo è la sola difesa seria — ed è il motivo per cui c'è |

| Limite                                                                                | Conseguenza                                                                                                                                                                                  |
|---------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Il modello è <b>lineare nel kernel</b> (kernel ridge, kernel di Tanimoto) o logistico | Nessuna rete neurale, nessun gradient boosting: sono metodi che su poche centinaia di molecole non danno un vantaggio dimostrabile, e il costo sarebbe un modello che non si può ispezionare |
| <b>I PAINS non sono una condanna</b>                                                  | Un pattern PAINS segnala che il composto è stato spesso un falso positivo in saggi di fluorescenza, non che sia inattivo. Il pannello lo scrive accanto a ogni segnalazione                  |
| La <b>PCA è sui descrittori</b> , non sulle impronte                                  | Sulle impronte binarie la PCA è poco informativa; i carichi sui descrittori si leggono, e sono mostrati                                                                                      |
| Non c'è <b>ricerca di sottostruttura su larga scala</b>                               | Il banco di lavoro è dimensionato per gli insiemi che si incollano a mano, non per una libreria da milioni di composti                                                                       |

### 3-bis.4 Due superfici, due ruoli — e un numero che era falso

L'applicazione ha **due** luoghi in cui si fa chemioinformatica, e servono a cose diverse. La distinzione è scritta qui perché un valutatore che apra prima la pagina sbagliata si farebbe l'idea sbagliata.

|                    | rdkit_lab.html — «RDKit Lab»                                         | Sezione Chemioinformatica                                                                                         |
|--------------------|----------------------------------------------------------------------|-------------------------------------------------------------------------------------------------------------------|
| <b>A chi serve</b> | Chi studia: una molecola alla volta, per vedere cosa RDKit sa dirne  | Chi lavora: un insieme di molecole, per ricavarne un modello difendibile                                          |
| <b>Ingresso</b>    | Uno SMILES                                                           | Un insieme incollato, con l'attività misurata                                                                     |
| <b>QSAR</b>        | Stime <b>empiriche</b> dai descrittori, dichiarate tali nel pannello | Modello <b>addestrato</b> sui dati forniti, con divisione per scheletro, validazione incrociata e controllo nullo |
| <b>Uscita</b>      | Quello che si vede a schermo                                         | CSV e rapporto di metodo                                                                                          |

**Un numero che era falso, e come se n'è accorto il banco.** Il pannello «Pharma Pro» del laboratorio confrontava la molecola con otto farmaci di riferimento e mostrava una percentuale di similarità. Quella percentuale non veniva da un fingerprint: veniva da **otto bit di descrittori a soglia** — «ha anelli aromatici», «HBA > 4», «peso fra 200 e 500» — di cui si calcolava il Tanimoto. Misurato: **caffeina contro metformina dava 0,75**, mentre su fingerprint di Morgan vale **0,024**. Due molecole senza frammenti in comune, mostrate al 75 %, su una pagina che si chiama «RDKit Lab» e dove RDKit era già caricato. Accanto a quello, tre delle otto impronte di riferimento erano **scritte a mano** e avevano il bit «aromatico» sbagliato (caffeina, che ha due anelli aromatici, morfina e amoxicillina che ne hanno uno), e lo **SMILES dell'omeprazolo non era omeprazolo**:

C0c1ccc2[nH]c(=S)cc2c1O è una struttura che RDKit rifiuta.

Corretto tutto: il confronto usa il fingerprint di Morgan con il Tanimoto del motore condiviso, le impronte si calcolano invece di essere battute a tastiera, e l'omeprazolo è l'omeprazolo (massa monoisotopica 345,11, tre anelli aromatici — verificate). Le due funzioni della similarità finta sono state **rimosse**, non scavalcate: lasciarle in giro le avrebbe rimesse in uso alla prima modifica, e il banco controlla che non esistano più.

**Una sola implementazione di Tanimoto.** Il laboratorio ne aveva una propria, che concordava con quella del motore sui casi normali ma rispondeva 0 dove il motore risponde 1 (il caso di due impronte vuote). Ora la pagina carica `bsi-cheminfo.js` e chiama quello: `test_cheminfo` confronta le due strade su tutte e 28 le coppie di riferimento e pretende scarto **esattamente zero**.

### 3-ter. Il testo alternativo delle figure non si inventa

La guida di biochimica porta **98 figure**. Sostituendola, il banco di accessibilità l'ha bocciata: nessuna aveva un attributo `alt`.

La via comoda era `alt=""`, e il banco l'avrebbe accettata — il commento nel suo codice dice, correttamente, che per un'immagine **decorativa** è la cosa giusta: dice allo screen reader di saltarla. Ma queste sono figure di biochimica, cioè informazione. Marcarle come decorative avrebbe fatto passare il controllo dicendo a chi usa uno screen reader di ignorare 98 diagrammi: un verde vuoto, della stessa famiglia del «contrasto 0» che non copriva i pannelli nuovi (§3-bis) e del 100 % di copertura che sommava gli intervalli sbagliati.

La via onesta era a disposizione: ogni immagine sta dentro un `<figure>` con la sua `<figcaption>`, e **le didascalie le ha scritte l'autore del documento**.

|                                                |                                                          |
|------------------------------------------------|----------------------------------------------------------|
| Figure                                         | 62, per 98 immagini                                      |
| Figure con una sola immagine                   | 26 — l'alt è la didascalia, meno l'etichetta «Figura N.» |
| Figure con due pannelli                        | 36                                                       |
| Didascalie di coppia divise fra i due pannelli | <b>33 su 36</b>                                          |
| Coppie con didascalia condivisa                | 3 — non si dividono in modo inequivocabile               |

Le 36 didascalie di coppia distinguono tutte i due pannelli con «a sinistra» e «a destra»: dove la divisione è inequivocabile, ogni immagine riceve la propria metà della frase. Dove non lo è, le due immagini condividono la didascalia intera — verboso da ascoltare, ma **non può essere sbagliato**, e una descrizione sbagliata di una figura è peggio di una verbosa.

**Perché non tentare una divisione più aggressiva.** Si potevano spremere anche le 3 restanti con espressioni regolari più elastiche. Una divisione che sbaglia produce la frase «questa immagine mostra X» accanto a un'immagine che mostra Y, e lo screen reader la legge con la stessa sicurezza di quelle giuste. Il ripiego è rumoroso; l'errore è invisibile.

Misurato dopo l'intervento: **98 su 98 con testo alternativo, nessuno vuoto**, contrasto **0** su 1 897 elementi di testo.

## 3-quater. Da prototipo a strumento di lavoro

Le funzioni descritte in §3-bis bastavano a dire qualcosa di difendibile su un insieme di molecole. Non bastavano a **lavorarci**: un gruppo di chemioinformatica, il primo giorno, chiede di cercare una sottostruttura su tutto l'insieme, di vedere la tabella SAR, e di sapere che cosa succede all'attività se sostituisce un cloro con un metile.

### 3-quater.1 Che cosa la libreria aveva, e che cosa non ha

Prima di progettare si è **sondata** MinimalLib 2025.03.4 all'esecuzione, invece di assumere. Sondare per primo ha cambiato il progetto: tre delle capacità qui sotto non erano state usate perché non si sapeva che ci fossero.

| C'è                                                        | A cosa serve                                                                                                                                              |
|------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| <code>SubstructLibrary</code>                              | Ricerca per sottostruttura con pattern fingerprint: scarta in blocco le molecole che non possono corrispondere, invece di provare l'isomorfismo su ognuna |
| <code>get_rxn</code> · <code>Reaction.run_reactants</code> | Trasformazioni chimiche. È ciò che permette di <b>tagliare</b> un legame, e da lì vengono coppie corrispondenti e tabella SAR                             |
| <code>generate_aligned_coords</code>                       | Allineare le molecole a un nucleo comune                                                                                                                  |
| <code>get_molblock</code> · <code>get_v3Kmolblock</code>   | Esportazione <b>SDF</b> , il formato con cui si scambiano insiemi fra gruppi e programmi                                                                  |

| Non c'è                                           | Conseguenza dichiarata                                                                                                     |
|---------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------|
| <code>cleanup</code> , <code>neutralize</code>    | La standardizzazione si ferma al frammento maggiore e allo SMILES canonico: <b>le cariche non vengono neutralizzate</b>    |
| <code>canonical_tautomer</code>                   | Due tautomeri scritti in modo diverso restano due voci distinte                                                            |
| <code>FragmentOnBonds</code> , <code>RWMol</code> | Nessuna modifica diretta delle molecole: il taglio passa per una reazione                                                  |
| Sottostruttura massima comune (MCS)               | Il nucleo di una tabella SAR va <b>fornito</b> , non viene dedotto. Il pannello offre otto nuclei pronti e il campo libero |

### 3-quater.2 Il taglio, e perché ne servono due regole

Una reazione SMARTS spezza un legame e marca i due capi con un atomo fittizio. Verificato all'esecuzione: `CC0c1cccc1` dà tre tagli con la regola fine ( $\text{CH}_3\text{-CH}_2$ ,  $\text{CH}_2\text{-O}$ ,  $\text{O-arile}$ ) e due con quella grossa; il benzene e il metano non ne danno nessuno.

| Regola                       | Taglia                                                                                                 | Quando serve                                                                                               |
|------------------------------|--------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------|
| <b>fine</b><br>(predefinita) | Qualunque legame singolo aciclico, <b>compresi i sostituenti terminali</b> Cl, CH <sub>3</sub> , OH, F | Tabella SAR e trasformazioni fini (Cl → CH <sub>3</sub> )                                                  |
| <b>grossa</b> (stile BRICS)  | Esclude gli atomi terminali                                                                            | Insiemi grandi, dove i tagli fini sono troppi; produce parti variabili più grandi («clorofenile → fenile») |

**La regola fine è nata da un difetto.** La prima stesura usava solo quella grossa, e la tabella SAR della serie di prova **perdeva il cloro sull'anello**: trovava il sostituito sull'azoto e mancava proprio la colonna che interessa, perché il cloro è terminale. La regola fine è un soprainsieme della grossa: ogni taglio che la grossa trova, lo trova anche la fine.

### 3-quater.3 Coppie molecolari corrispondenti

Due molecole formano una coppia quando, tagliando un legame in ciascuna, restano con lo **stesso contesto** e due parti variabili diverse. La differenza di attività è attribuita a quella sostituzione e a nient'altro — ed è il motivo per cui questa lettura batte una correlazione su tutto l'insieme, che media su molecole diverse per dieci cose.

Verificata su una serie **costruita con effetti noti**: se l'analisi non li ritrova non è utilizzabile su dati veri.

| Trasformazione            | Attesa | Trovata     | Coppie concordanti |
|---------------------------|--------|-------------|--------------------|
| clorofenile → fenile      | -1,0   | <b>-1,0</b> | 2 su 2             |
| metilfenile → fenile      | -0,5   | <b>-0,5</b> | 2 su 2             |
| metile → cloro            | +0,5   | <b>+0,5</b> | 2 su 2             |
| etilammide → propilammide | +0,2   | <b>+0,2</b> | 3 su 3             |

Sui 28 inibitori dell'esempio, presi da ChEMBL: **449 coppie, 98 trasformazioni** viste almeno due volte, 199 viste una sola, in 133 ms. In cima alla lista **CF<sub>3</sub> → SO<sub>2</sub>NH<sub>2</sub> con Δ mediano -2,65** su due coppie concordanti.

Due scelte dichiarate:

- la **direzione è normalizzata** sull'ordine alfabetico delle due parti.

Senza di essa lo stesso effetto comparirebbe due volte, con mediane opposte, e nessuna delle due avrebbe il numero di coppie giusto;

- le trasformazioni viste **meno di due volte** sono escluse dalla tabella e

contate a parte. Una trasformazione vista una volta con  $\Delta = +3$  non è una scoperta: è un aneddoto, e metterla in cima farebbe prendere decisioni su di essa.

**La colonna «concordi» è quella che decide se fidarsi.** Una mediana di +1,0 su tre coppie di cui una a -2,0 non è la stessa cosa di +1,0 su tre coppie tutte positive, e la mediana da sola non lo dice.

### 3-quater.4 La tabella SAR, e come si trova la posizione

Il punto difficile non è trovare i sostituenti: è sapere in quale **posizione** sta ognuno. Senza MCS e senza modifica delle molecole, la soluzione sfrutta una proprietà del taglio: **il frammento che contiene il nucleo porta l'atomo fittizio esattamente nel punto di**

**attacco.** Facendo corrispondere il nucleo a quel frammento si scopre su quale suo atomo è appeso il fittizio, e quindi quale posizione occupa il sostituyente.

Ne viene anche un filtro necessario e gratuito: se il fittizio **non** è attaccato a un atomo del nucleo, il taglio è avvenuto dentro un sostituyente e quel pezzo non è il sostituyente intero. Si scarta.

Sui 28 inibitori, con nucleo benzamidico: **20 molecole con il nucleo, 2 posizioni, 8 escluse.** Le escluse non compaiono in tabella: metterle con le celle vuote le farebbe sembrare parte della serie con sostituyenti non trovati.

**Un difetto di denominazione, e come si è manifestato.** `scaffoldMurcko()` restituiva il suo risultato in un campo chiamato `smiles`, ma quel valore **non è uno SMILES**: è un'impronta canonica dello scheletro, costruita perché due molecole con lo stesso scheletro producano la stessa stringa. Serve a raggruppare — pieghe, divisione per scaffold — non a interrogare. Il pannello SAR lo ha preso per uno SMILES e proponeva `6,6,6,6,7,...|0-13:1,...` come nucleo; la decomposizione rispondeva «nucleo non interpretabile».

Il campo si chiama ora `chiave` e dichiara `eUnoSmiles: false`; `smiles` resta come alias. Il banco fissa che due scheletri uguali diano la stessa chiave, che scheletri diversi diano chiavi diverse, e che la chiave **non si rilegga come SMILES**. Il nome sbagliato di un campo è un difetto come un altro.

### 3-quater.5 Il rigore che un valutatore pretende

Cinque cose che un gruppo di modellistica mette in ogni rapporto, e la cui assenza è la prima obiezione in riunione.

|                              | Metodo                                                                                                                                  | Perché                                                                                                                                                                                                                     |
|------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>Confronto fra modelli</b> | Riferimento banale (predire la media), kNN su Tanimoto, regressione kernel — tutti sulle <b>stesse pieghe</b> raggruppate per scheletro | Confrontare un modello valutato su una divisione con un altro valutato su un'altra non è un confronto. E il riferimento banale sta in cima all'elenco, perché è il numero che ogni altro deve battere                      |
| <b>Validazione annidata</b>  | Gli iperparametri ( $k$ , $\lambda$ ) si scelgono su pieghe <b>interne all'addestramento</b>                                            | Provarne dieci sull'insieme di prova e riportare il migliore gonfia il punteggio: quel numero non è una predizione, è il massimo di dieci tentativi                                                                        |
| <b>Intervalli conformi</b>   | Split-conformal, quantile $[(n+1)(1-\alpha)]$ dei residui assoluti su una porzione di calibrazione <b>divisa per scaffold</b>           | «7,2» e «7,2 $\pm$ 0,3» sono due informazioni diverse, e solo la seconda dice se vale la pena sintetizzare. Una calibrazione su analoghi dell'addestramento darebbe intervalli troppo stretti proprio sulle molecole nuove |
| <b>Arricchimento</b>         | EF a 1 %, 5 %, 10 % con il <b>massimo possibile</b> accanto; BEDROC (Truchon & Bayly, <i>J. Chem. Inf. Model.</i> 47 (2007) 488)        | In uno screening non si guarda tutta la lista. Un ROC-AUC di 0,80 può nascondere una testa di lista senza un solo attivo, perché l'AUC premia anche l'ordine nella coda, che nessuno comprerà                              |

|                               | Metodo                                                                                                      | Perché                                                                                           |
|-------------------------------|-------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------|
| <b>Curva di apprendimento</b> | Punteggio al variare della dimensione dell'addestramento, con l'insieme di prova <b>intero</b> a ogni punto | Risponde alla sola domanda che conta quando il modello è mediocre: serve più chimica o più dati? |

**Il verdetto del confronto è provato nei due versi**, come il modello nullo. Su un segnale vero — attività proporzionale al numero di alogeni, su dieci nuclei distinti — la regressione kernel arriva a  $R^2$  0,943 con margine 0,943 contro una dispersione di 0,035, e il verdetto è *supera*. Sulle **stesse molecole con etichette casuali** il migliore si ferma a -0,265, margine -0,034, e il verdetto è *non supera*. Una guardia che non scatta mai e una che scatta sempre sono lo stesso difetto.

L'arricchimento è verificato sui tre casi in cui il valore giusto si calcola a mano:

| Ordinamento (2 attivi su 10)    | AUC                 | EF@20 %                              | BEDROC                     |
|---------------------------------|---------------------|--------------------------------------|----------------------------|
| Perfetto: i due attivi in testa | 1                   | <b>5</b> — ed è il massimo possibile | <b>1</b>                   |
| Pessimo: i due attivi in coda   | 0                   | 0                                    | <b>0</b> , non un negativo |
| Attivi ai ranghi 2 e 5          | <b>0,75</b> = 12/16 | <b>2,5</b> = 1/0,4                   | 0,119                      |

Il caso pessimo è quello che conta: senza di esso non si saprebbe se BEDROC tocca lo zero o scende sotto, e un BEDROC negativo è il segno che manca il termine additivo della formula.

### 3-quater.6 Limiti di questo blocco

| Limite                                                                 | Conseguenza                                                                                                                                                                                                                                                     |
|------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Le coppie crescono col <b>quadrato</b> delle molecole                  | Misurato: 6 molecole 45 ms, 40 molecole 227 ms con 1 255 coppie. Oltre 300 molecole il pannello rifiuta di partire e lo dice, invece di bloccare la pagina                                                                                                      |
| Il taglio è <b>singolo</b>                                             | Una coppia che differisce per due sostituzioni insieme non viene trovata. È il limite dello schema a taglio singolo, condiviso con gli strumenti standard                                                                                                       |
| La stessa trasformazione compare in <b>più forme</b>                   | Tagli in posizioni diverse danno contesti diversi per la stessa modifica chimica ( <code>*CC&gt;&gt;*CCC</code> , <code>*NCC&gt;&gt;*NCCC</code> , <code>*C(=O)NCC&gt;&gt;*C(=O)NCCC</code> ). È ridondanza attesa nello schema a taglio singolo, non un errore |
| Le cariche <b>non</b> sono neutralizzate e i tautomeri non canonizzati | MinimalLib non lo permette (§3-quater.1). Un insieme che mescola forme neutre e ioniche della stessa molecola le conta come voci distinte                                                                                                                       |
| Il nucleo della tabella SAR va <b>fornito</b>                          | Nessun MCS disponibile. Il pannello non propone nulla automaticamente, perché una proposta sbagliata è peggio di nessuna proposta                                                                                                                               |

## 4. Costanti fisiche e dati tabulati

La ricerca delle costanti fisiche procede per livelli di specificità decrescente (corrispondenza esatta → simbolo → parole significative → sottostringa di almeno 4 caratteri) e **raccoglie tutte le candidate**: se ne restano più d'una, la richiesta viene rifiutata con l'elenco delle

possibilità anziché restituire arbitrariamente la prima. Un valore fisico sbagliato restituito con sicurezza è peggio di una domanda di chiarimento.

Le molecole d'esame ( `MOLECOLE_ESAME` ) sono tabulate con valori verificati; il riconoscimento dei gruppi da SMILES usa un campo `consume` , così che ogni gruppo rimuova la porzione di struttura che ha spiegato e non si producano conteggi sovrapposti.

---

## 5. Automazione della verifica

---

Tutti i controlli descritti sono eseguibili e ripetibili. Al momento della stesura la batteria comprende, fra gli altri:

| Banco                                                     | Oggetto                                                                      | Controlli |
|-----------------------------------------------------------|------------------------------------------------------------------------------|-----------|
| <code>tools/verifica-farmaci.js</code>                    | struttura ↔ peso molecolare, duplicati, deviazioni registrate                | 233 voci  |
| <code>test_spettri</code>                                 | riconoscimento gruppi su molecole di riferimento                             | 36        |
| <code>test_assi /</code><br><code>test_assi_canvas</code> | convenzioni degli assi (SVG e canvas)                                        | 19        |
| <code>test_costanti</code>                                | ricerca delle costanti fisiche e rifiuto delle ambiguità                     | 45        |
| <code>audit_dati</code>                                   | coerenza dei dati tabulati                                                   | 29        |
| <code>verifica_guida</code>                               | corrispondenza fra ciò che la documentazione promette e ciò che il codice fa | 71        |

L'ultimo banco merita una menzione: verifica che le affermazioni contenute nella documentazione utente corrispondano al comportamento reale del codice. Una promessa non mantenuta dalla documentazione è un difetto al pari di un errore di calcolo, e viene trattata come tale.

---

## 6. Dichiarazione di trasparenza

---

Questo documento descrive controlli **effettivamente implementati ed eseguibili**, con i risultati realmente ottenuti e i limiti dei predittori. Alla versione `bsi-v185` gli errori residui sulla banca dati farmaci sono **zero**: le 21 deviazioni che restano sono voci senza struttura, ciascuna con il proprio motivo registrato, non errori taciuti. Le percentuali di copertura e i conteggi riportati sono prodotti dagli strumenti citati e riproducibili eseguendoli.

Dove un dato non è verificabile con gli strumenti a disposizione, lo si dichiara anziché presentarlo come verificato.

---

\_Documento aggiornato alla versione `bsi-v185`.\_