

BioSpecInfo

Accuratezza scientifica e provenienza dei dati — BioSpecInfo

Samuele Pio Provenzano

Versione **bsi-v175** · commit `a5a24cc`

Generato il 2026-09-30

Documento generato automaticamente dal sorgente Markdown versionato nel repository. La versione e il commit stampati in ogni piè di pagina identificano esattamente lo stato del software descritto.

Accuratezza scientifica e provenienza dei dati — BioSpecInfo

Campo	Valore
Software	BioSpecInfo
Autore	Samuele Pio Provenzano
Versione descritta	bsi-v175
Scopo	Documentare come vengono generati i dati scientifici mostrati dall'applicazione, con quale metodo sono verificati, e quali sono i limiti dichiarati.

Perché questo documento esiste. Un'applicazione didattica di chimica può essere ineccepibile dal punto di vista informatico e sbagliata dal punto di vista scientifico, e l'utente non ha modo di accorgersene: un peso molecolare plausibile, uno spettro dall'aspetto convincente e una struttura sbagliata si presentano tutti allo stesso modo. Questo documento descrive i controlli che rendono quell'errore **visibile e automatico**, e dichiara ciò che resta fuori dalla loro portata.

1. Principio: ogni dato scientifico deve poter essere contraddetto

Il criterio adottato in tutta l'applicazione è che un dato scientifico non si consideri verificato perché *sembra* giusto, ma perché **esiste un secondo dato indipendente che lo confermerebbe o lo smentirebbe**. Dove questo secondo dato non esiste, il limite viene dichiarato invece di essere colmato con una stima presentata come misura.

Tre applicazioni concrete di questo principio:

Ambito	Prima affermazione	Seconda affermazione indipendente	Controllo
Banca dati farmaci	struttura (SMILES)	peso molecolare di letteratura	il peso ricalcolato dalla struttura deve coincidere
Spettri IR / NMR	gruppi funzionali riconosciuti	struttura molecolare via RDKit	i gruppi si cercano sul grafo, non sul testo dello SMILES
Costanti fisiche	valore tabulato	simbolo e unità di misura	la ricerca rifiuta le corrispondenze ambigue invece di sceglierne una

2. Banca dati farmacologica — 178 voci

2.1 Il metodo di verifica

Ogni voce dichiara **due** proprietà della stessa molecola: la struttura, in notazione SMILES, e il peso molecolare. Sono affermazioni indipendenti — la prima descrive la connettività atomica, la seconda è un numero preso dalla letteratura — e quindi confrontabili:

peso calcolato da RDKit sulla struttura ↔ peso dichiarato in tabella

Uno scarto superiore a **0,6 u** (tolleranza che copre gli arrotondamenti e le piccole differenze fra tabelle di masse atomiche, ma non un errore reale, che vale decine di unità) indica che almeno una delle due affermazioni è sbagliata.

Il controllo è automatizzato (`tools/verifica-farmaci.js` , eseguibile da chiunque disponga del repository) e non richiede giudizio umano: non chiede di fidarsi di nessuna fonte, confronta due numeri.

2.2 Cosa ha trovato

Applicato alle 143 voci preesistenti, il controllo ha individuato **89 errori**. La distribuzione è significativa: i **pesi molecolari erano corretti** — presi dalla letteratura — mentre le **strutture erano sbagliate**.

Farmaco	Struttura dichiarata
Ketamina	un pirrolidinone non correlato
Morfina	struttura non corrispondente (in due voci distinte)
Lorazepam	privo dell'ossidril in posizione 3, che ne definisce l'identità
Atorvastatina	privo del gruppo anilidico
Testosterone	privo del doppio legame Δ^4 dell'anello A

Più **7 farmaci duplicati** in categorie diverse, con dati talvolta divergenti fra le due copie.

2.3 Lo scarto come strumento diagnostico

Il valore numerico della differenza non è solo un allarme: indica **quale** frammento manca o è di troppo.

Δ (u)	Interpretazione	Caso reale
28,05	C_2H_4	ketamina, fentanil, morfina
16,00	un atomo di ossigeno	tetraciclina (un ossidril in più)
14,02	un gruppo CH_2	doxiciclina
2,02	un doppio legame mancante	testosterone (Δ^4)
0,98	citosina ↔ uracile	sofosbuvir

L'ultimo caso merita una nota: lo scarto di 0,98 u corrisponde esattamente alla sostituzione di un gruppo –NH con un atomo di ossigeno, cioè alla differenza fra citosina e uracile. Il sofosbuvir è un analogo dell'**uridina**, e la struttura proposta conteneva la base sbagliata. Il numero ha indicato dove guardare.

2.4 Stato attuale e limiti dichiarati

Farmaci in banca dati	178 (erano 143)
Con struttura verificata	157 (erano 153)
Difetti	0
Deviazioni dichiarate e accettate	21 (erano 25)

La verifica è **conforme**: nessuna voce presenta una struttura che contraddica il proprio peso molecolare. Le 21 deviazioni sono voci **prive di struttura**, ciascuna registrata con il proprio motivo in [evidence/deviazioni-note.json](#) e riportata nel rapporto di verifica.

Difetto contro deviazione. Il controllo distingue due situazioni che non vanno confuse:

- una struttura che **contraddice** il proprio peso è un difetto, e fa fallire

la verifica;

- una struttura **assente** può essere una deviazione accettabile — ma solo se

registrata esplicitamente, con il motivo. Una voce priva di struttura e **non** registrata fa fallire la verifica come qualunque altro difetto.

Registrare una deviazione è quindi una decisione consapevole, tracciata in git e visibile nel rapporto, non un modo per silenziare un controllo.

E va anche **revocata** quando non serve più. Dalla versione [bsi-v175](#) il banco fallisce anche nel caso opposto: una voce elencata nel registro che **ha** una struttura verificata è un permesso rimasto acceso a vuoto, e domani coprirebbe in silenzio una struttura sbagliata messa al suo posto.

2.4-bis Quattro voci uscite dal registro

Delle sei voci senza struttura, quattro sono state chiuse riprendendo la struttura da **ChEMBL** — una fonte indipendente da questo progetto — e verificandola con lo stesso confronto struttura ↔ peso molecolare che vale per tutte le altre.

Voce	ChEMBL	Formula	Peso dichiarato	Peso calcolato
Digossina	CHEMBL1751	C ₄₁ H ₆₄ O ₁₄	780,94	780,95
Vincristina	CHEMBL90555	C ₄₆ H ₅₆ N ₄ O ₁₀	824,96	824,97
Tacrolimus topico (Protopic)	CHEMBL269732	C ₄₄ H ₆₉ NO ₁₂	804,02	804,03
Tacrolimus sistemico (Prograf)	CHEMBL269732	C ₄₄ H ₆₉ NO ₁₂	804,02	804,03

Il motivo registrato per la digossina diceva «ogni struttura provata si discosta di 14-30 u dal peso di letteratura»: il peso dichiarato era giusto, erano le strutture provate a essere sbagliate. Che il confronto sia reale e non compiacente si vede aggiungendo un solo carbonio alla struttura corretta — il banco segnala **Δ 14,04** e fallisce.

Le due che restano non sono molecole singole, e nessuna notazione SMILES le rappresenta:

- **Ivermectina** è una miscela di omologhi: almeno 80 % di B1a (C₄₈H₇₄O₁₄) e non più del 20 % di B1b (C₄₇H₇₂O₁₄). Il peso dichiarato, 875,10, è quello del solo componente B1a. Mostrarne la struttura farebbe passare l'omologo maggioritario per l'intero farmaco.

- **Artemetere/Lumefantrina (Coartem)** è l'associazione di due principi attivi distinti.

In entrambi i casi non manca una struttura: non ce n'è una sola da mostrare.

Gruppo	Voci	Natura
D-01 — non sono molecole singole	2	ivermectina (miscela di omologhi B1a/B1b) e artemetere/lumefantrina (associazione di due principi attivi). Erano sei: le altre quattro sono state chiuse con la struttura da ChEMBL, vedi §2.4-bis.
D-02 — non rappresentabili in SMILES	19	anticorpi monoclonali, proteine e peptidi (trastuzumab, pembrolizumab, insulina, semaglutide, ciclosporina A...). L'assenza è corretta, non una lacuna.

La scelta è deliberata: un dato sbagliato sostituito da un altro dato sbagliato non è un progresso, e l'assenza dichiarata è preferibile a una presenza non verificata.

3. Predizione spettrale

3.1 Riconoscimento strutturale, non testuale

I gruppi funzionali sono individuati con **pattern SMARTS applicati al grafo molecolare** tramite RDKit (`bsi-spettri.js`), non con espressioni regolari applicate alla stringa SMILES.

La differenza non è stilistica. Il metodo testuale precedente presentava due difetti strutturali:

1. **Esclusività.** I controlli erano organizzati in catene `else if`, per cui veniva riconosciuto **un solo gruppo funzionale per molecola**.

1. **Cecità alla struttura.** Una regex legge caratteri, non legami.

Il caso emblematico è l'**acido acetilsalilico** (`CC(=O)Oc1ccccc1C(=O)O`), che contiene sia un estere sia un acido carbossilico. Il riconoscimento testuale identificava solo l'estere; lo spettro IR risultante era privo della banda O-H allargata a ~3000 cm⁻¹ e del C=O acido a ~1690 cm⁻¹ — le due bande che identificano la molecola — e lo spettro ¹H NMR era privo del segnale del protone carbossilico a 11,6 ppm.

Il riconoscimento su grafo è **additivo per costruzione**: una molecola può presentare tutti i gruppi che possiede.

3.2 Convenzioni di rappresentazione

Le convenzioni degli assi non sono uniformi fra le tecniche, e sono verificate automaticamente (`test_assi.js` , `test_assi_canvas.js`) estraendo le etichette delle tacche dal disegno prodotto:

Tecnica	Ascissa	Verso	Ordinata
IR	numero d'onda (cm^{-1})	decescente, $4000 \rightarrow 400$	trasmissione % , bande verso il basso
^1H NMR	δ (ppm)	decescente, $14 \rightarrow 0$	intensità, riferimento TMS a 0
UV-Vis	λ (nm)	crescente, $200 \rightarrow 400$	assorbanza
MS	m/z	crescente	abbondanza relativa

3.3 Determinismo

Nessuno spettro contiene componenti casuali. Le versioni precedenti aggiungevano rumore pseudo-casuale alla traccia a ogni ridisegno, con la conseguenza che la stessa molecola produceva ogni volta uno spettro diverso e due spettri non erano confrontabili. Un profilo calcolato deve essere **riproducibile**: dove serve un fondo realistico si usa una funzione deterministica del numero d'onda.

Analogamente, nel predittore NMR le altezze dei picchi erano generate casualmente. In uno spettro ^1H l'altezza è l'informazione quantitativa — l'integrazione — e inventarla è peggio che ometterla. Attualmente:

- dove il numero di protoni è noto, l'altezza è l'integrazione reale e

l'etichetta la riporta (es. `7,26 (4H)`);

- dove la predizione è un **intervallo** (es. `<6,5-8,5 ppm`), si disegna la

fascia dell'intervallo con un segno sul valore tipico e altezza uniforme: il grafico indica *dove* cade il segnale senza affermare quanto sia intenso.

3.4 Effetti chimici modellati

Effetto	Implementazione
Coniugazione del carbonile	abbassamento di $\sim 25 \text{ cm}^{-1}$ applicato al singolo carbonile , non globalmente
Estere fenolico	innalzamento a $\sim 1760 \text{ cm}^{-1}$
Intensità C-H	proporzionale al numero di gruppi CH_2/CH_3 presenti
Sostituzione dell'anello aromatico	bande "fuori dal piano" $900\text{--}690 \text{ cm}^{-1}$ distinte per orto/meta/para/mono
Doppio di Fermi delle aldeidi	bande a 2820 e 2720 cm^{-1}
Bande ammidiche I e II	1655 e 1550 cm^{-1}

Verifica: l'acido acetilsalicilico produce estere arilico a 1760 cm^{-1} e acido coniugato a 1690 cm^{-1} — i due valori che lo identificano — mentre acetofenone (chetone coniugato, 1690) e acetato di etile (estere non coniugato, 1735) confermano che l'effetto è applicato in modo selettivo e non indiscriminato.

3.5 Limiti dichiarati

Gli spettri prodotti sono **predizioni basate su tabelle di gruppi funzionali**, non spettri misurati né simulazioni quantomeccaniche. Indicano dove cadono le bande dei gruppi presenti, con posizioni e intensità tabulate. **Non sostituiscono un database sperimentale** (SDBS, NIST) né una misura strumentale, e il grafico lo dichiara.

In particolare non sono modellati: accoppiamenti spin-spin del secondo ordine, effetti di solvente e concentrazione, bande di combinazione e sovratoni, polimorfismo allo stato solido.

3-bis. Chemioinformatica e modelli QSAR

3-bis.1 Da dove vengono i metodi

Nessuno dei metodi della sezione **Chemioinformatica** è inventato per l'occasione. Sono quelli in uso, con i riferimenti che li definiscono.

Metodo	Riferimento	Come è implementato qui
Coefficiente di Tanimoto	Rogers & Tanimoto, 1960	Bit in comune su bit in unione, con la convenzione $0/0 = 1$ dichiarata nel codice
Impronte di Morgan / ECFP	Rogers & Hahn, <i>J. Chem. Inf. Model.</i> 50 (2010) 742	Da RDKit MinimalLib, raggio 2, 2048 bit
Chiavi MACCS	Durant <i>et al.</i> , <i>J. Chem. Inf. Comput. Sci.</i> 42 (2002) 1273	Da RDKit MinimalLib, 166 chiavi
Regola dei 5	Lipinski <i>et al.</i> , <i>Adv. Drug Deliv. Rev.</i> 23 (1997) 3	Sui descrittori RDKit, con il conteggio delle violazioni
Filtro di Veber	Veber <i>et al.</i> , <i>J. Med. Chem.</i> 45 (2002) 2615	Legami ruotabili ≤ 10 , TPSA $\leq 140\text{ Å}^2$
QED	Bickerton <i>et al.</i> , <i>Nat. Chem.</i> 4 (2012) 90	Ricalcolato: MinimalLib espone 43 descrittori ma non il QED. I parametri delle funzioni desiderabilità sono quelli dell'articolo
Raggruppamento di Butina	Butina, <i>J. Chem. Inf. Comput. Sci.</i> 39 (1999) 747	Soglia sulla distanza di Tanimoto, capifila scelti per numero di vicini
Scheletri di Bemis-Murcko	Bemis & Murcko, <i>J. Med. Chem.</i> 39 (1996) 2887	Sistemi ad anello più i legami che li collegano
PAINS	Baell & Holloway, <i>J. Med. Chem.</i> 53 (2010) 2719	Sottoinsieme dei pattern SMARTS, con il motivo della segnalazione

Metodo	Riferimento	Come è implementato qui
Allarmi di Brenk	Brenk <i>et al.</i> , <i>ChemMedChem</i> 3 (2008) 435	Idem
SALI	Guha & Van Drie, <i>J. Chem. Inf. Model.</i> 48 (2008) 646	Δ attività / (1 – Tanimoto), sulle coppie sopra la soglia di similarità

3-bis.2 Le quattro cose che rendono un QSAR onesto

Un modello QSAR è facilissimo da far sembrare buono. Le quattro precauzioni qui sotto sono quelle che distinguono un numero da una misura, e sono tutte verificate dal banco

`test_cheminfo`.

Divisione per scheletro. Con una divisione casuale, analoghi stretti della stessa serie finiscono da entrambe le parti: il modello ritrova ciò che ha già visto. La divisione per scheletro raggruppa le molecole per scheletro di Bemis-Murcko e assegna **scheletri interi** a una sola parte. L' R^2 che ne esce è più basso — ed è quello che sopravvive alla molecola nuova.

Modello nullo per rimescolamento. Lo stesso modello viene riaddestrato otto volte su etichette mescolate. Se il punteggio vero non supera il migliore dei sosia, il modello non ha imparato nulla di trasferibile, e il pannello lo dichiara con quelle parole. È il controllo che manca più spesso: senza di esso, un R^2 di 0,4 su trenta molecole è indistinguibile dal caso.

Dominio di applicabilità. Una predizione su una molecola lontana da tutto ciò che il modello ha visto è un'estrapolazione, non una predizione. La distanza dal vicino più prossimo nell'insieme di addestramento è mostrata accanto a ogni valore predetto.

Validazione incrociata raggruppata per scheletro. Una divisione sola, su un insieme piccolo, è un numero rumoroso: su 28 molecole al 25 % l'insieme di prova ne contiene sette, e spostarne una muove l' R^2 di decimi. Le pieghe raggruppano per scheletro — nessuno scheletro sta in due pieghe — e il risultato viene dato come **media $\pm$ deviazione**, non come cifra singola.

Quanto conti, misurato sull'esempio dei 28 inibitori. La divisione singola dà R^2 **0,861**. La validazione a cinque pieghe dà **0,605 $\pm$ 0,452**, con le singole pieghe a 0,861 · 0,538 · 0,795 · **-0,150** · 0,980. La divisione singola aveva pescato la piega fortunata. Le due cifre insieme dicono quello che nessuna delle due dice da sola: il modello funziona, ma dipende sensibilmente da quali molecole gli capitano in addestramento — e su un insieme di ventotto molecole è esattamente ciò che ci si deve aspettare.

3-bis.3 Limiti dichiarati

Limite	Conseguenza
Gli insiemi di esempio sono piccoli (28 e 40 molecole)	Servono a mostrare il metodo, non a produrre un modello utilizzabile. Su insiemi così, il modello nullo è la sola difesa seria — ed è il motivo per cui c'è

Limite	Conseguenza
Il modello è lineare nel kernel (kernel ridge, kernel di Tanimoto) o logistico	Nessuna rete neurale, nessun gradient boosting: sono metodi che su poche centinaia di molecole non danno un vantaggio dimostrabile, e il costo sarebbe un modello che non si può ispezionare
I PAINS non sono una condanna	Un pattern PAINS segnala che il composto è stato spesso un falso positivo in saggi di fluorescenza, non che sia inattivo. Il pannello lo scrive accanto a ogni segnalazione
La PCA è sui descrittori , non sulle impronte	Sulle impronte binarie la PCA è poco informativa; i carichi sui descrittori si leggono, e sono mostrati
Non c'è ricerca di sottostruttura su larga scala	Il banco di lavoro è dimensionato per gli insiemi che si incollano a mano, non per una libreria da milioni di composti

3-bis.4 Due superfici, due ruoli — e un numero che era falso

L'applicazione ha **due** luoghi in cui si fa chemioinformatica, e servono a cose diverse. La distinzione è scritta qui perché un valutatore che apra prima la pagina sbagliata si farebbe l'idea sbagliata.

	rdkit_lab.html — «RDKit Lab»	Sezione Chemioinformatica
A chi serve	Chi studia: una molecola alla volta, per vedere cosa RDKit sa dirne	Chi lavora: un insieme di molecole, per ricavarne un modello difendibile
Ingresso	Uno SMILES	Un insieme incollato, con l'attività misurata
QSAR	Stime empiriche dai descrittori, dichiarate tali nel pannello	Modello addestrato sui dati forniti, con divisione per scheletro, validazione incrociata e controllo nullo
Uscita	Quello che si vede a schermo	CSV e rapporto di metodo

Un numero che era falso, e come se n'è accorto il banco. Il pannello «Pharma Pro» del laboratorio confrontava la molecola con otto farmaci di riferimento e mostrava una percentuale di similarità. Quella percentuale non veniva da un fingerprint: veniva da **otto bit di descrittori a soglia** — «ha anelli aromatici», «HBA > 4», «peso fra 200 e 500» — di cui si calcolava il Tanimoto. Misurato: **caffeina contro metformina dava 0,75**, mentre su fingerprint di Morgan vale **0,024**. Due molecole senza frammenti in comune, mostrate al 75 %, su una pagina che si chiama «RDKit Lab» e dove RDKit era già caricato. Accanto a quello, tre delle otto impronte di riferimento erano **scritte a mano** e avevano il bit «aromatico» sbagliato (caffeina, che ha due anelli aromatici, morfina e amoxicillina che ne hanno uno), e lo **SMILES dell'omeprazolo non era omeprazolo**:

C0c1ccc2[nH]c(=S)cc2c1O è una struttura che RDKit rifiuta.

Corretto tutto: il confronto usa il fingerprint di Morgan con il Tanimoto del motore condiviso, le impronte si calcolano invece di essere battute a tastiera, e l'omeprazolo è l'omeprazolo (massa monoisotopica 345,11, tre anelli aromatici — verificate). Le due funzioni della similarità finta sono state **rimosse**, non scavalcate: lasciarle in giro le avrebbe rimesse in uso alla prima modifica, e il banco controlla che non esistano più.

Una sola implementazione di Tanimoto. Il laboratorio ne aveva una propria, che concordava con quella del motore sui casi normali ma rispondeva 0 dove il motore risponde 1 (il caso di due impronte vuote). Ora la pagina carica `bsi-cheminfo.js` e chiama quello: `test_cheminfo` confronta le due strade su tutte e 28 le coppie di riferimento e pretende scarto **esattamente zero**.

4. Costanti fisiche e dati tabulati

La ricerca delle costanti fisiche procede per livelli di specificità decrescente (corrispondenza esatta → simbolo → parole significative → sottostringa di almeno 4 caratteri) e **raccoglie tutte le candidate**: se ne restano più d'una, la richiesta viene rifiutata con l'elenco delle possibilità anziché restituire arbitrariamente la prima. Un valore fisico sbagliato restituito con sicurezza è peggio di una domanda di chiarimento.

Le molecole d'esame (`MOLECOLE_ESAME`) sono tabulate con valori verificati; il riconoscimento dei gruppi da SMILES usa un campo `consuma` , così che ogni gruppo rimuova la porzione di struttura che ha spiegato e non si producano conteggi sovrapposti.

5. Automazione della verifica

Tutti i controlli descritti sono eseguibili e ripetibili. Al momento della stesura la batteria comprende, fra gli altri:

Banco	Oggetto	Controlli
<code>tools/verifica-farmaci.js</code>	struttura ↔ peso molecolare, duplicati, deviazioni registrate	178 voci
<code>test_spettri</code>	riconoscimento gruppi su molecole di riferimento	36
<code>test_assi /</code> <code>test_assi_canvas</code>	convenzioni degli assi (SVG e canvas)	19
<code>test_costanti</code>	ricerca delle costanti fisiche e rifiuto delle ambiguità	45
<code>audit_dati</code>	coerenza dei dati tabulati	29
<code>verifica_guida</code>	corrispondenza fra ciò che la documentazione promette e ciò che il codice fa	71

L'ultimo banco merita una menzione: verifica che le affermazioni contenute nella documentazione utente corrispondano al comportamento reale del codice. Una promessa non mantenuta dalla documentazione è un difetto al pari di un errore di calcolo, e viene trattata come tale.

6. Dichiarazione di trasparenza

Questo documento descrive controlli **effettivamente implementati ed eseguibili**, con i risultati realmente ottenuti e i limiti dei predittori. Alla versione `bsi-v175` gli errori residui sulla banca dati farmaci sono **zero**: le 21 deviazioni che restano sono voci senza struttura, ciascuna con il proprio motivo registrato, non errori taciuti. Le percentuali di copertura e i conteggi riportati sono prodotti dagli strumenti citati e riproducibili eseguendoli.

Dove un dato non è verificabile con gli strumenti a disposizione, lo si dichiara anziché presentarlo come verificato.

Documento aggiornato alla versione `bsi-v175`.