

Le chiavi API di Spectra — guida passo passo

Spectra non ha un server: parla direttamente con il servizio AI che scegli, usando **la tua** chiave. La chiave resta nel browser, non passa da nessuna parte, e la inserisci **una volta sola** per servizio.

> **La cosa più importante di questa guida:** non fermarti alla prima chiave. > Spectra mette in comune tutte quelle che hai — quando un servizio esaurisce > il limite o non risponde, continua da solo sul successivo, senza che tu > debba fare niente. Tre chiavi gratuite reggono un carico che nessuna delle > tre reggerebbe da sola.

Da dove cominciare — in due minuti

Se leggi solo questo riquadro, fai questo:

- 1. Vai su console.groq.com → accedi con Google → **API Keys** → **Create API Key** → copia
- 2. Apri BioSpecInfo → pulsante **Spectra** → incolla nella casella  → **Salva**
- 3. Scrivi qualcosa. Funziona.

Poi, quando hai altri cinque minuti, aggiungi **Gemini** (\$2): serve per i riassunti di documenti lunghi, e Groq da solo non ci arriva.

L'elenco completo

Undici configurazioni, otto fornitori, **tutti verificati attivi a settembre 2026**. Nessuno è lì per fare numero.

Gratuiti

#	Servizio	Modelli	A cosa serve	Limite
1	Groq	GPT-OSS 120B, Qwen3	Il cavallo da tiro: l'80% del lavoro	~30 richieste/min
2	Google Gemini	Gemini Flash	Documenti lunghi e riassunti (1M di contesto)	Generoso
3	NVIDIA NIM	DeepSeek R1, Qwen3 235B	Ragionamento profondo	Crediti a esaurimento
4	Z.AI GLM	GLM-4.7-Flash	Rincalzo che non scade mai	Limitato al minuto

A pagamento — la frontiera

#	Servizio	Perché	Costo indicativo
5	OpenAI GPT-5.6	94,6% su GPQA Diamond: il primo al mondo sulle domande scientifiche di livello dottorato	~4 \$/M in ingresso
6	Grok 4.6 (xAI)	Primo sul <i>tool calling agentico</i> e minor tasso di allucinazione	~2 \$/M
7	Google Gemini 3 Pro	Oltre 1M di contesto. Stessa chiave del Gemini gratuito	~2 \$/M
8	DeepSeek V4	Ragionamento di fascia alta al prezzo più basso	~0,66 \$/M
9-11	Claude Fable 5.1 · Opus 5 · Sonnet 5	Gli unici con il sandbox Python in Modalità Nucleo. Una chiave per tutti e tre	2-10 \$/M

Parte 1 — i quattro gratuiti

1. Groq — comincia da qui

Tempo: 30 secondi. Nessuna verifica, nessuna carta.

- 1. Apri console.groq.com
- 2. **Sign in** → scegli Google o GitHub
- 3. Nel menu di sinistra clicca **API Keys**
- 4. Pulsante **Create API Key**
- 5. Nel campo *Name* scrivi [spectra](#) → **Submit**
- 6. Clicca l'icona **copia** accanto alla chiave

La chiave comincia con [gsk_](#).

> ⚠ **Si vede una volta sola.** Se chiudi la finestra senza copiarla non c'è > modo di rivederla: creane un'altra, sono gratuite e illimitate.

Perché è il cavallo da tiro: 131.000 token di contesto e circa 30 richieste al minuto. Studiando non lo esaurisci.

2. Google Gemini — per i documenti lunghi

Tempo: 1 minuto.

- 1. Apri aistudio.google.com
- 2. Accedi con il tuo account Google
- 3. In alto a sinistra, pulsante **Get API key**
- 4. **Create API key**

5. Ti chiede un progetto: scegline uno o lascia che ne crei uno nuovo

6. Copia la chiave

La chiave comincia con **AIza**.

> **Quando cambia tutto:** quando alleggi un PDF lungo o chiedi un riassunto. > Arriva a **1 milione di token** — centinaia di pagine in una richiesta sola. > Gli altri gratuiti si fermano molto prima e ti danno il riassunto della > prima parte *senza dirti* che il resto non l'hanno letto.

| 3. NVIDIA NIM — i modelli che ragionano

Tempo: 3 minuti. Nessuna carta di credito.

1. Apri build.nvidia.com
2. **Sign in** in alto a destra → crea un account NVIDIA se non ce l'hai (è il Developer Program, gratuito)
3. Dall'elenco dei modelli aprine uno qualsiasi — per esempio **DeepSeek R1**
4. Nel pannello a destra cerca **Get API Key**
5. **Generate Key** → copia

La chiave comincia con **nvapi-**.

> I crediti gratuiti sono **a esaurimento**, non si rinnovano ogni mese. > Tienilo per quando serve un modello che ragiona a fondo su un problema > lungo, non per il lavoro di tutti i giorni.

| 4. Z.AI GLM — il rincalzo che non scade

Tempo: 2 minuti.

1. Apri z.ai e registrati con la tua email
2. Clicca sul tuo **profilo** in alto a destra
3. **API Keys** → **Create new key**
4. Copia

Perché c'è: è gratuito **senza scadenza** — non crediti che finiscono, non una prova a tempo. GLM-4.7-Flash è forte su ragionamento e codice. È la riserva che troverai ancora lì fra sei mesi, quando i crediti NVIDIA saranno esauriti.

Parte 2 — la frontiera

Questi si pagano a consumo. Ma su un problema di chimica fisica in dieci passaggi la differenza si vede, e una sessione di studio costa centesimi.

| 5. OpenAI GPT-5.6 — il primo sulle domande scientifiche

Tempo: 3 minuti. Serve una carta.

1. Apri platform.openai.com e accedi
2. Menu di sinistra → **API keys**
3. **Create new secret key** → dai un nome → **Create**
4. Copia subito: comincia con **sk-proj-** e non si rivede
5. Vai su **Billing** → **Add payment method** → aggiungi un credito (bastano 5 \$)

È il numero uno su GPQA Diamond: 94,6%. Su domande di chimica, fisica e biologia di livello dottorato — cioè esattamente quello che chiedi tu — oggi non c'è niente di meglio.

> Il modello di punta (*So/*) è ad accesso limitato e la tua chiave potrebbe > non vederlo. Non devi fare niente: Spectra chiede all'API cosa può usare e > scala da solo a *Terra*, poi a *Luna*.

| 6. Grok 4.6 (xAI) — il migliore sugli agenti

Tempo: 3 minuti. Serve una carta.

1. Apri console.x.ai e accedi (serve un account X/xAI)
2. Sezione **API Keys**
3. **Create API Key** → dai un nome → conferma
4. Copia: comincia con **xai-**
5. Aggiungi un credito dalla sezione **Billing**

Uscito il 12 agosto 2026. È **primo su tool calling agentico** — cioè esattamente quello che fa Spectra quando concatena dieci strumenti per risolvere un problema — e ha il **tasso di allucinazione più basso** in circolazione. Circa 2 \$ per milione: meno della metà di GPT-5.6.

Se la 4.6 non è disponibile sulla tua chiave, Spectra scala da sola alle versioni precedenti, che arrivano a 1-2 milioni di token di contesto.

| 7. Google Gemini 3 Pro — la finestra più ampia

Tempo: 2 minuti se hai già fatto il §2.

Usa la stessa chiave del Gemini gratuito. La incolli una volta e vale per entrambi: cambia solo che serve la fatturazione attiva.

1. Apri console.cloud.google.com → **Fatturazione**
2. Collega un account di fatturazione al progetto che hai usato al §2
3. Torna in Spectra e scegli **Google Gemini 3 Pro** dalla tendina — la chiave c'è già

Oltre **1 milione di token** di contesto: una tesi intera in una richiesta.

| 8. DeepSeek V4 — potenza al prezzo più basso

Tempo: 3 minuti.

1. Apri platform.deepseek.com e registrati
2. **API keys** → **Create API key** → dai un nome
3. Copia: comincia con **sk-**
4. **Top up** → ricarica un credito piccolo (bastano 2 \$)

Ragionamento di fascia alta a circa **0,66 \$ per milione** fuori dalle ore di punta: **sei volte meno di GPT-5.6**.

> **Se paghi di tasca tua e vuoi spendere poco, comincia da qui.** È il > miglior rapporto qualità/prezzo dell'intero elenco.

| 9-11. Claude — Fable 5.1, Opus 5, Sonnet 5

Tempo: 3 minuti. Una chiave sola per tutti e tre.

1. Apri console.anthropic.com e accedi
2. **Settings** → **API Keys** → **Create Key**
3. Dai un nome → **Create Key** → copia (comincia con **sk-ant-**)
4. **Plans & Billing** → aggiungi un credito

La incolli su uno qualsiasi dei tre modelli Claude e vale automaticamente per gli altri due.

Sono gli unici che, in ✨ **Modalità Nucleo**, ottengono il **sandbox Python** — sympy, numpy, scipy, matplotlib. Il modello scrive ed esegue codice vero per integrare, diagonalizzare matrici, fare algebra simbolica: cose che i 32 risolutori non coprono perché non si possono prevedere tutte.

> ⚠️ È **separato** dall'abbonamento di claude.ai. Pagare quello non dà > accesso all'API: serve credito su console.anthropic.com.

Parte 3 — usarle

| Inserire una chiave

1. Apri BioSpecInfo → pulsante **Spectra** (il simbolo dell'atomo)
2. Nella tendina in alto scegli il servizio
3. Compare il riquadro 🔑 **Configura** → incolla → **Salva**
4. Il riquadro sparisce: **non te la richiede più**

Ripeti per ogni servizio che hai. Restano salvate in questo browser finché non le togli tu.

> **Chiavi condivise.** I tre modelli Claude usano un solo account Anthropic, > e Gemini Flash e Gemini 3 Pro una sola chiave di AI Studio: incollala su uno > qualsiasi e vale per i gemelli.

Verificare che funzioni davvero

1. Scrivi: «**Calcola il pH di una soluzione di acido acetico 0,1 M**»
2. Devi vedere una nota  **Equilibrio acido-base** comparire sopra la risposta, e il risultato **pH $\approx$ 2,875**

Se vedi la nota dello strumento, tutto funziona: significa che il modello sta **invocando i risolutori** invece di rispondere a memoria. È la differenza fra Spectra e una chat qualunque.

Toglierle o ricominciare

Pulsante  nella barra di Spectra. Ti fa scegliere cosa togliere — chat, chiavi, memoria — prima di cancellare davvero.

Quale usare, in pratica

Se...	Usa
Studio quotidiano, tante domande	Groq (gratis)
Un PDF lungo, o un riassunto	Gemini (gratis)
Un problema scientifico davvero tosto	GPT-5.6
Una catena lunga di strumenti	Grok 4.6
Calcolo simbolico o numerico vero	Claude +  Modalità Nucleo
Potenza spendendo poco	DeepSeek V4

Cosa succede quando qualcosa va storto

Non devi fare niente. Spectra gestisce da sola i quattro casi:

Cosa succede	Cosa fa Spectra
Limite al minuto (429)	Legge quanto deve aspettare, te lo dice, riprova. Fino a 3 volte
Quota finita	Passa a un altro servizio per cui hai una chiave e rifà la domanda da lì
Servizio non raggiungibile	Stessa cosa: cambia fornitore e continua
Modello ritirato dal fornitore	Ne cerca un altro nel catalogo e riprova

Mai a pagamento senza chiedertelo. La riserva automatica usa solo servizi gratuiti: se hai anche una chiave Claude o GPT, quelle le scegli tu.

Se invece è colpa della chiave

Messaggio	Significato	Cosa fare
401 / Invalid API Key	Chiave sbagliata o incollata a metà	Ricrea e reincollala per intero
402 / insufficient credit	Credito finito	Ricarica sul sito del fornitore
Il riquadro 🗝 non sparisce dopo il Salva	La memoria del browser è piena	Usa 🗑 per liberare, oppure esci dalla navigazione in incognito

Perché alcuni servizi non ci sono

Non è una dimenticanza: sono stati valutati e scartati, uno per uno.

- **GitHub Models** — GitHub lo ha **ritirato del tutto il 30 luglio 2026**. Playground, catalogo e API di inferenza spenti per tutti. Qualunque guida che lo consigli ancora è più vecchia di quella data.
- **Claude Haiku 4.5** — non è scaduto, è *dominato*: Sonnet 5 costa il doppio e dà cinque volte il contesto, il ragionamento esteso e la ricerca web, che Haiku non ha.
- **Mistral** — qualità media, e il piano gratuito richiede la verifica del telefono **e il consenso all'uso dei tuoi dati per l'addestramento**. Per materiale di tesi non pubblicato non vale la pena.
- **OpenRouter** — i modelli gratuiti sono piccoli e i loro id cambiano di continuo: inadatti a un agente che concatena dieci chiamate.
- **Cerebras** — da agosto 2026 niente più piano senza carta, e il gratuito limita il contesto a 8K token: Spectra manda 32 definizioni di strumenti oltre alla cronologia, non ci sta.
- **Moonshot Kimi, MiniMax, Qwen** — sono frontiera veri, ma non superano GPT-5.6 su GPQA Diamond (il banco che conta per la chimica) e duplicano capacità già coperte da Gemini 3 Pro e DeepSeek. Aggiungerli allungherebbe la tendina senza darti una scelta migliore.
- **Qwen / Alibaba** (quota diretta) — la parte gratuita è una **prova a tempo** di circa 90 giorni, non un piano permanente. I modelli Qwen restano comunque raggiungibili tramite Groq e NVIDIA.

Una cosa da non fare

Non incollare mai una chiave dentro il codice del sito. GitHub Pages serve file statici: finirebbe visibile a chiunque apra la pagina con `Ctrl+U`, e i bot che scandagliano GitHub la troverebbero in poche ore, facendotela revocare.

Se vuoi che il sito funzioni **per chiunque lo apra**, senza che nessuno debba inserire niente, la strada c'è ed è un'altra: `proxy/README.md`.

Verifica dei fornitori: settembre 2026. Se leggi questa guida molto più tardi, ricontrolla — i servizi chiudono, e un elenco è vecchio dal giorno dopo che lo scrivi.