

# BioSpecInfo

## Le chiavi API di Spectra — guida passo passo

---

Samuele Pio Provenzano

Versione **bsi-v171** · commit `7a5dad2`

Generato il 2026-09-23

Documento generato automaticamente dal sorgente Markdown versionato nel repository. La versione e il commit stampati in ogni piè di pagina identificano esattamente lo stato del software descritto.

# Le chiavi API di Spectra — guida passo passo

Spectra non ha un server: parla direttamente con il servizio AI che scegli, usando **la tua** chiave. La chiave resta nel browser, non passa da nessuna parte, e la inserisci **una volta sola** per servizio.

**La cosa più importante di questa guida:** non fermarti alla prima chiave. Spectra mette in comune tutte quelle che hai — quando un servizio esaurisce il limite o non risponde, continua da solo sul successivo, senza che tu debba fare niente. Tre chiavi gratuite reggono un carico che nessuna delle tre reggerebbe da sola.

## Da dove cominciare — in due minuti

Se leggi solo questo riquadro, fai questo:

1. Vai su `console.groq.com` → accedi con Google → **API Keys** →

**Create API Key** → copia

1. Apri BioSpecInfo → pulsante **Spectra** → incolla nella casella  → **Salva**

2. Scrivi qualcosa. Funziona.

Poi, quando hai altri cinque minuti, aggiungi **Gemini** (\$2): serve per i riassunti di documenti lunghi, e Groq da solo non ci arriva.

## L'elenco completo

Dieci configurazioni, sette fornitori, **tutti verificati attivi a settembre 2026 e raggiungibili dal browser**. Nessuno è lì per fare numero.

### Gratuiti

| # | Servizio             | Modelli             | A cosa serve                                         | Limite                                    |
|---|----------------------|---------------------|------------------------------------------------------|-------------------------------------------|
| 1 | <b>Groq</b>          | GPT-OSS 120B, Qwen3 | Il cavallo da tiro: l'80% del lavoro                 | ~30 richieste/min, <b>8.000 token/min</b> |
| 2 | <b>Google Gemini</b> | Gemini Flash        | Documenti lunghi e <b>riassunti</b> (1M di contesto) | Generoso                                  |
| 3 | <b>Z.AI GLM</b>      | GLM-4.7-Flash       | Rincalzo che non scade mai                           | Limitato al minuto                        |

## A pagamento — la frontiera

| #    | Servizio                                    | Perché                                                                                           | Costo indicativo    |
|------|---------------------------------------------|--------------------------------------------------------------------------------------------------|---------------------|
| 4    | <b>OpenAI GPT-5.6</b>                       | <b>94,6% su GPQA Diamond</b> : il primo al mondo sulle domande scientifiche di livello dottorato | ~4 \$/M in ingresso |
| 5    | <b>Grok 4.6</b> (xAI)                       | Primo sul <i>tool calling agentico</i> e minor tasso di allucinazione                            | ~2 \$/M             |
| 6    | <b>Google Gemini 3 Pro</b>                  | Oltre 1M di contesto. <b>Stessa chiave</b> del Gemini gratuito                                   | ~2 \$/M             |
| 7    | <b>DeepSeek V4</b>                          | Ragionamento di fascia alta al prezzo più basso                                                  | ~0,66 \$/M          |
| 8-10 | <b>Claude</b> Fable 5.1 · Opus 5 · Sonnet 5 | Gli unici con il <b>sandbox Python</b> in Modalità Nucleo. <b>Una chiave per tutti e tre</b>     | 2-10 \$/M           |

## Parte 1 — i tre gratuiti

### 1. Groq — comincia da qui

**Tempo: 30 secondi. Nessuna verifica, nessuna carta.**

1. Apri `console.groq.com`
2. **Sign in** → scegli Google o GitHub
3. Nel menu di sinistra clicca **API Keys**
4. Pulsante **Create API Key**
5. Nel campo *Name* scrivi `spectra` → **Submit**
6. Clicca l'icona **copia** accanto alla chiave

La chiave comincia con `gsk_`.

 **Si vede una volta sola.** Se chiudi la finestra senza copiarla non c'è modo di rivederla: creane un'altra, sono gratuite e illimitate.

**Perché è il cavallo da tiro:** 131.000 token di contesto e circa 30 richieste al minuto. Studiando non lo esaurisci.

**Attenzione a due numeri diversi.** I 131.000 token sono la *finestra di contesto*; il piano gratuito però lascia passare **8.000 token al minuto** (TPM), ed è quello il limite che incontri per primo. Spectra se ne accorge da sola: alla prima richiesta troppo grande legge il tetto dal messaggio di Groq, se lo ricorda e da lì in poi manda solo gli strumenti pertinenti alla domanda invece di tutti e 35. Vedi la nota  in chat quando succede.

## 2. Google Gemini — per i documenti lunghi

---

**Tempo: 1 minuto.**

1. Apri [aistudio.google.com](https://aistudio.google.com)
2. Accedi con il tuo account Google
3. In alto a sinistra, pulsante **Get API key**
4. **Create API key**
5. Ti chiede un progetto: scegline uno o lascia che ne crei uno nuovo
6. Copia la chiave

La chiave comincia con **AIza**.

**Quando cambia tutto:** quando alleggi un PDF lungo o chiedi un riassunto. Arriva a **1 milione di token** — centinaia di pagine in una richiesta sola. Gli altri gratuiti si fermano molto prima e ti danno il riassunto della prima parte *senza dirti* che il resto non l'hanno letto.

## 3. Z.AI GLM — il ricalzo che non scade

---

**Tempo: 2 minuti.**

1. Apri [z.ai](https://z.ai) e registrati con la tua email
2. Clicca sul tuo **profilo** in alto a destra
3. **API Keys** → **Create new key**
4. Copia

**Perché c'è:** è gratuito **senza scadenza** — non crediti che finiscono, non una prova a tempo. GLM-4.7-Flash è forte su ragionamento e codice. È la riserva che troverai ancora lì fra sei mesi, quando le prove a tempo degli altri saranno scadute.

## Parte 2 — la frontiera

---

Questi si pagano a consumo. Ma su un problema di chimica fisica in dieci passaggi la differenza si vede, e una sessione di studio costa centesimi.

## 4. OpenAI GPT-5.6 — il primo sulle domande scientifiche

---

**Tempo: 3 minuti. Serve una carta.**

1. Apri [platform.openai.com](https://platform.openai.com) e accedi
2. Menu di sinistra → **API keys**
3. **Create new secret key** → dai un nome → **Create**
4. Copia subito: comincia con **sk-proj-** e non si rivede

5. Vai su **Billing** → **Add payment method** → aggiungi un credito

(bastano 5 \$)

**È il numero uno su GPQA Diamond: 94,6%.** Su domande di chimica, fisica e biologia di livello dottorato — cioè esattamente quello che chiedi tu — oggi non c'è niente di meglio.

Il modello di punta (*Sol*) è ad accesso limitato e la tua chiave potrebbe non vederlo. Non devi fare niente: Spectra chiede all'API cosa può usare e scala da solo a *Terra*, poi a *Luna*.

## 5. Grok 4.6 (xAI) — il migliore sugli agenti

**Tempo: 3 minuti. Serve una carta.**

1. Apri `console.x.ai` e accedi (serve un account X/xAI)
2. Sezione **API Keys**
3. **Create API Key** → dai un nome → conferma
4. Copia: comincia con `xai-`
5. Aggiungi un credito dalla sezione **Billing**

Uscito il 12 agosto 2026. È **primo su tool calling agentico** — cioè esattamente quello che fa Spectra quando concatena dieci strumenti per risolvere un problema — e ha il **tasso di allucinazione più basso** in circolazione. Circa 2 \$ per milione: meno della metà di GPT-5.6.

Se la 4.6 non è disponibile sulla tua chiave, Spectra scala da sola alle versioni precedenti, che arrivano a 1-2 milioni di token di contesto.

## 6. Google Gemini 3 Pro — la finestra più ampia

**Tempo: 2 minuti se hai già fatto il §2.**

**Usa la stessa chiave del Gemini gratuito.** La incolli una volta e vale per entrambi: cambia solo che serve la fatturazione attiva.

1. Apri `console.cloud.google.com` → **Fatturazione**
2. Collega un account di fatturazione al progetto che hai usato al §2
3. Torna in Spectra e scegli **Google Gemini 3 Pro** dalla tendina — la chiave c'è già

Oltre **1 milione di token** di contesto: una tesi intera in una richiesta.

## 7. DeepSeek V4 — potenza al prezzo più basso

**Tempo: 3 minuti.**

1. Apri `platform.deepseek.com` e registrati

2. **API keys** → **Create API key** → dai un nome
3. Copia: comincia con **sk-**
4. **Top up** → ricarica un credito piccolo (bastano 2 \$)

Ragionamento di fascia alta a circa **0,66 \$ per milione** fuori dalle ore di punta: **sei volte meno di GPT-5.6**.

**Se paghi di tasca tua e vuoi spendere poco, comincia da qui.** È il miglior rapporto qualità/prezzo dell'intero elenco.

## 8-10. Claude — Fable 5.1, Opus 5, Sonnet 5

**Tempo: 3 minuti. Una chiave sola per tutti e tre.**

1. Apri **console.anthropic.com** e accedi
2. **Settings** → **API Keys** → **Create Key**
3. Dai un nome → **Create Key** → copia (comincia con **sk-ant-**)
4. **Plans & Billing** → aggiungi un credito

**La incolli su uno qualsiasi dei tre modelli Claude e vale automaticamente per gli altri due.**

Sono gli unici che, in ✳ **Modalità Nucleo**, ottengono il **sandbox Python** — sympy, numpy, scipy, matplotlib. Il modello scrive ed esegue codice vero per integrare, diagonalizzare matrici, fare algebra simbolica: cose che i 32 risolutori non coprono perché non si possono prevedere tutte.

⚠ È **separato** dall'abbonamento di claude.ai. Pagare quello non dà accesso all'API: serve credito su **console.anthropic.com**.

**Non devi scegliere fra le versioni.** Se un giorno Opus 5 non fosse disponibile sulla tua chiave, Spectra passa da sola a Opus 4.8 e poi a 4.7 — costano uguale e sono la stessa fascia. Per questo non li trovi in tendina: sceglierli a mano non darebbe mai un vantaggio.

## Parte 3 — usarle

### Inserire una chiave

1. Apri BioSpecInfo → pulsante **Spectra** (il simbolo dell'atomo)
2. Nella tendina in alto scegli il servizio
3. Compare il riquadro 🔑 **Configura** → incolla → **Salva**
4. Il riquadro sparisce: **non te la richiede più**

Ripeti per ogni servizio che hai. Restano salvate in questo browser finché non le togli tu.

**Chiavi condivise.** I tre modelli Claude usano un solo account Anthropic, e Gemini Flash e Gemini 3 Pro una sola chiave di AI Studio: incollala su uno qualsiasi e vale per i gemelli.

## Verificare che funzioni davvero

1. Scrivi: «**Calcola il pH di una soluzione di acido acetico 0,1 M**»
2. Devi vedere una nota  **Equilibrio acido-base** comparire sopra la

risposta, e il risultato **pH ≈ 2,875**

Se vedi la nota dello strumento, tutto funziona: significa che il modello sta **invocando i risolutori** invece di rispondere a memoria. È la differenza fra Spectra e una chat qualunque.

## Farne a meno del tutto — il proxy

Se non vuoi inserire nessuna chiave, la strada c'è ed è definitiva: un piccolo programma su Cloudflare tiene le chiavi **sul server**. La pagina non ne contiene nessuna, chi apre il sito usa Spectra e basta, e cade anche il vincolo CORS — quindi tornano utilizzabili anche i fornitori che dal browser non rispondono.

Tre comandi, account Cloudflare gratuito, niente carta né dominio:

```
cd proxy
npx wrangler login
npx wrangler deploy
```

Poi in Spectra apri la riga  **Senza chiavi: collega un proxy**, incolla l'indirizzo che `wrangler` ha stampato e premi **Collega**. Spectra lo contatta subito: se non risponde **non lo salva** e te lo dice, invece di lasciarti con l'app muta e la convinzione di aver fatto la cosa giusta.

Dettagli e come mettere le chiavi sul server: `proxy/README.md`.

## Toglierle o ricominciare

Pulsante  nella barra di Spectra. Ti fa scegliere cosa togliere — chat, chiavi, memoria — prima di cancellare davvero.

## Quale usare, in pratica

| Se...                            | Usa                    |
|----------------------------------|------------------------|
| Studio quotidiano, tante domande | <b>Groq</b> (gratis)   |
| Un PDF lungo, o un riassunto     | <b>Gemini</b> (gratis) |

| Se...                                 | Usa                               |
|---------------------------------------|-----------------------------------|
| Un problema scientifico davvero tosto | <b>GPT-5.6</b>                    |
| Una catena lunga di strumenti         | <b>Grok 4.6</b>                   |
| Calcolo simbolico o numerico vero     | <b>Claude</b> + ✳ Modalità Nucleo |
| Potenza spendendo poco                | <b>DeepSeek V4</b>                |

### Per i lavori grossi

«Grosso» non vuol dire una cosa sola, e i fornitori migliori sono diversi a seconda di quale delle tre cose intendi.

| Il lavoro è grosso perché...                                 | Gratis                                                                                     | A pagamento                                                                                             |
|--------------------------------------------------------------|--------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------|
| <b>Il testo è lungo</b> — dispense, PDF, tesi da riassumere  | <b>Gemini Flash</b> , 1M di token: centinaia di pagine in una richiesta                    | <b>Gemini 3 Pro</b> , stessa finestra ma di frontiera                                                   |
| <b>Le domande sono tante</b> — una sessione di studio intera | <b>Groq</b> , ~30 richieste/min, e le altre due chiavi lo coprono quando finisce il minuto | <b>DeepSeek V4</b> , ~0,66 \$/M: il volume costa poco                                                   |
| <b>Il problema è difficile</b> — dieci passaggi concatenati  | <b>Z.AI GLM</b> + ✳ Modalità Nucleo                                                        | <b>Claude Opus 5</b> , il più capace a incatenare strumenti. <b>Grok 4.6</b> se conta più la precisione |

**Sui gratuiti la risposta vera non è "quale", è "tutte e tre".** Nessuna delle tre regge da sola un carico grosso: hanno tutte un tetto al minuto. Ma Spectra le mette in comune — quando Groq esaurisce il minuto la domanda riparte su Gemini, e da lì su Z.AI. Tre chiavi messe insieme reggono quello che nessuna delle tre reggerebbe, e non devi fare niente perché succeda: basta averle salvate tutte e tre.

**Un avvertimento onesto sui documenti lunghi.** Solo Gemini arriva davvero a centinaia di pagine. Gli altri gratuiti tagliano quello che non ci sta e ti danno il riassunto della prima parte — Spectra te lo dice con la nota 🚩, ma la nota si legge, il riassunto monco no. Per le dispense usa Gemini.

### Cosa succede quando qualcosa va storto

**Non devi fare niente.** Spectra gestisce da sola i quattro casi:

| Cosa succede                                                 | Cosa fa Spectra                                                                                                      |
|--------------------------------------------------------------|----------------------------------------------------------------------------------------------------------------------|
| Limite al minuto ( 429 )                                     | Legge quanto deve aspettare, te lo dice, riprova. Fino a 4 volte                                                     |
| <b>Servizio sovraccarico</b> ( 503 , 500 , 502 , 504 , 529 ) | Non è la tua chiave: è il fornitore sotto pressione. Aspetta e riprova fino a 4 volte, poi passa a un altro servizio |

| Cosa succede                                     | Cosa fa Spectra                                                                             |
|--------------------------------------------------|---------------------------------------------------------------------------------------------|
| Quota finita                                     | Passa a un altro servizio per cui hai una chiave e <b>rifà la domanda da lì</b>             |
| Servizio non raggiungibile                       | Stessa cosa: cambia fornitore e continua — <b>e se lo segna</b> , vedi qui sotto            |
| Modello ritirato dal fornitore                   | Lo boccia, <b>legge il sostituto dal messaggio del fornitore</b> e rifà la domanda          |
| Il fornitore rifiuta il <i>formato</i> del turno | Tre tentativi di recupero prima di arrendersi, l'ultimo senza strumenti — e te lo dice      |
| Richiesta troppo grande ( 413 )                  | <b>Legge il tetto dal messaggio</b> , se lo ricorda e rimanda la domanda con meno strumenti |
| Il modello sta ragionando e non risponde         | Aspetta fino a 3 minuti (5 in * Modalità Nucleo) invece di 45 s, e ti dice che sta pensando |

**Mai a pagamento senza chiedertelo.** La riserva automatica usa solo servizi gratuiti: se hai anche una chiave Claude o GPT, quelle le scegli tu.

## Se Gemini si ferma al secondo strumento

C'era un guasto con una firma inconfondibile: il primo strumento partiva, vedevi la nota verde «Ho eseguito...», e subito dopo

```
HTTP 400 – Function call is missing a thought_signature in functionCall parts
```

I modelli Gemini che ragionano allegano a ogni pezzo della loro risposta una **firma** — una stringa opaca — e pretendono di riaverla identica quando la conversazione torna indietro per il secondo giro. Spectra la buttava via.

Per questo il primo giro riusciva e il secondo no: il modo più confondente di fallire, perché sembra che il problema sia lo strumento appena eseguito.

**Ora la firma viene conservata e rimandata indietro**, ed è risolto. Se un giorno un fornitore rifiutasse comunque il formato del turno, Spectra prova tre strade in ordine prima di arrendersi — l'ultima è rifare la domanda **senza strumenti**, e in quel caso te lo scrive in chat: una risposta senza risolutori è una risposta diversa, non la stessa un po' peggio.

## Se il servizio è sovraccarico

Nelle ore di punta capita di leggere questo:

```
HTTP 503 – This model is currently experiencing high demand. Spikes in demand are usually temporary. Please try again later.
```

**Non è la tua chiave, e non è il tuo modello.** È il fornitore sotto pressione, e la stessa identica domanda fra qualche secondo passa. Spectra aspetta e riprova fino a quattro volte, con pause crescenti — e se il fornitore dice *quanto* aspettare ( `Retry-After` ), rispetta quello invece di tirare a indovinare.

Se dopo i quattro tentativi è ancora giù, **passa a un altro servizio per cui hai una chiave** e rifà la domanda da lì. È il caso in cui la seconda chiave gratuita si ripaga da sola: con una sola chiave non c'è dove andare, e devi solo aspettare qualche minuto.

## Se un modello viene ritirato

Succede, e più spesso di quanto sembri. A settembre 2026 Google ha risposto così a una chiave perfettamente valida:

```
HTTP 404 – This model models/gemini-2.5-flash is no longer available to new users.  
Please update your code to use models/gemini-3.6-flash
```

Il modello **esisteva ancora** nel catalogo, e i controlli sui metadati lo trovavano: solo la chiamata vera diceva che non si poteva usare. «Esiste» e «lo puoi usare tu, con la tua chiave» sono due cose diverse.

**Non devi fare niente**, e in particolare non devi cambiare chiave:

1. Spectra si annota che quel modello ha fallito, così non lo riproverà;
2. **legge il nome del sostituto dal messaggio del fornitore** — è la fonte

più attendibile che esista, perché arriva da lui ed è aggiornata al momento in cui parla;

1. se il fornitore non lo dice, ricerca nel catalogo *escludendo* quello

bocciato — così ogni tentativo è per forza diverso dal precedente;

1. rifà la domanda e te lo dice in chat con la nota .

Dopo sette giorni i modelli bocciati vengono riprovati: uno può tornare disponibile, ed escluderlo per sempre sarebbe peggio.

## Se un servizio non risponde *dal browser*

C'è un guasto che non dipende né da te né dalla chiave, e vale la pena capirlo perché è l'unico che una guida non può risolvarti in anticipo.

BioSpecInfo è una pagina web. Quando Spectra chiama un fornitore, la chiamata parte **dal tuo browser**, e il browser la lascia partire solo se il fornitore risponde «sì, accetto chiamate da altri siti» (si chiama CORS). Alcuni fornitori lo fanno apposta, altri no, e la scelta può cambiare da un mese all'altro senza che nessuno lo annunci.

Peggior: quando la chiamata viene bloccata, **il browser non dice perché**. Per non dare informazioni a chi sonda la rete, rete assente, CORS negato e servizio spento arrivano tutti come lo stesso identico errore. Nemmeno il codice dell'app può distinguerli.

Per questo l'elenco «funziona / non funziona» non è scritto qui: sarebbe una fotografia sbagliata il mese dopo, e comunque dipende anche dalla tua rete e dalle estensioni installate nel tuo browser.

### Il pulsante Prova — la risposta in cinque secondi

Non c'è bisogno di scoprirlo sbagliando. Nella barra in alto di Spectra, il pulsante  **Prova** chiama tutti e undici i fornitori dal tuo browser e ti dice in pochi secondi quali risponde:

|                                                                                   |                                                                  |       |
|-----------------------------------------------------------------------------------|------------------------------------------------------------------|-------|
|  | Groq · risponde                                                  | 14 ms |
|  | Google Gemini Flash · risponde                                   | 13 ms |
|  | Un fornitore qualsiasi · il tuo browser non riesce a contattarlo |       |
|  | Z.AI GLM-4.7-Flash · risponde                                    | 16 ms |

**Non serve avere una chiave.** La domanda «il mio browser riesce a contattare questo server?» ha risposta *sì* anche quando il server rifiuta la chiave: se la chiamata si conclude in qualunque modo, il vincolo CORS è passato. Quindi puoi sapere **prima** di aprire un account se quel fornitore ti servirà a qualcosa.

La prova usa lo stesso indirizzo e le stesse intestazioni della chiamata vera (proxy compreso, se lo hai configurato), ma un corpo minimo: su una chiave valida costa un token, non la tua quota.

In fondo trovi la conclusione, che dice cosa fare adesso — quale scegliere, oppure che il problema è la tua rete e non i fornitori.

### Cosa fa da sola, senza che tu chieda niente

|                               |                                                                                                                                                                                                                                         |
|-------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Un fornitore non risponde     | Viene annotato e spostato in fondo alla tendina, nel gruppo  <b>Non hanno risposto da questo dispositivo</b> , con l'etichetta · <i>non risponde</i> |
| Lo hai selezionato lo stesso  | Un avviso ti dice quante volte è successo e ti propone un'alternativa <b>fra quelle che da qui hanno già risposto</b>                                                                                                                   |
| Serve una risposta subito     | Nella riserva automatica i marcati passano in fondo: non ti fanno più aspettare                                                                                                                                                         |
| Era solo la rete di ieri sera | Dopo 24 ore il fornitore viene ritentato da solo, senza che tu faccia niente                                                                                                                                                            |
| Torna a rispondere            | L'annotazione sparisce alla prima risposta ricevuta — anche un <code>401</code> basta, perché dimostra che al server ci si arriva                                                                                                       |

L'annotazione sta solo nel tuo browser e si cancella col pulsante  (gruppo *Chiavi API e provider*).

**Se un fornitore ti serve e da qui non risponde**, la soluzione definitiva è il proxy: la chiamata parte da un server invece che dal browser, e il vincolo CORS non esiste più. Sta in `proxy/README.md`.

Una nota di merito: **Claude è l'unico dei tre grandi che ha una modalità browser dichiarata** (l'header `anthropic-dangerous-direct-browser-access`, che Spectra manda già). Sugli altri la risposta va scoperta provando — ed è esattamente quello che l'app fa per te.

# Se invece è colpa della chiave

| Messaggio                                                                                                                | Significato                         | Cosa fare                                                                                                                                      |
|--------------------------------------------------------------------------------------------------------------------------|-------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------|
| 401 / Invalid API Key                                                                                                    | Chiave sbagliata o incollata a metà | Ricreala e reincollala <b>per intero</b>                                                                                                       |
| 402 / insufficient credit                                                                                                | Credito finito                      | Ricarica sul sito del fornitore                                                                                                                |
| Il riquadro  non sparisce dopo il Salva | La memoria del browser è piena      | Usa  per liberare, oppure esci dalla navigazione in incognito |

## Perché alcuni servizi non ci sono

Non è una dimenticanza: sono stati valutati e scartati, uno per uno.

- **NVIDIA NIM** — tolto a settembre 2026, ed è il caso più istruttivo: **\*\*non** è scaduto e non è peggiorato. **Il servizio è vivo, il piano gratuito pure, DeepSeek R1 e Qwen3 235B sono ottimi modelli. Semplicemente** non manda gli header CORS: **dentro una pagina web la chiamata non parte proprio, e non c'è nessuna correzione lato app che possa cambiarlo — lo decide il server di NVIDIA. Restava in tendina solo per far perdere 45 secondi a chi lo sceglieva.** Con il proxy tornerebbe utilizzabile\*\* (lì la chiamata parte da un server, non dal browser): la rotta nel Worker è rimasta apposta, basta rimettere la voce in PROVIDERS.

- **GitHub Models** — GitHub lo ha **ritirato del tutto il 30 luglio 2026.**

Playground, catalogo e API di inferenza spenti per tutti. Qualunque guida che lo consigli ancora è più vecchia di quella data.

- **Claude Haiku 4.5** — non è scaduto, è *dominato*: Sonnet 5 costa il doppio e dà cinque volte il contesto, il ragionamento esteso e la ricerca web, che Haiku non ha.

- **Mistral** — qualità media, e il piano gratuito richiede la verifica del telefono **e il consenso all'uso dei tuoi dati per l'addestramento.** Per materiale di tesi non pubblicato non vale la pena.

- **OpenRouter** — i modelli gratuiti sono piccoli e i loro id cambiano di continuo: inadatti a un agente che concatena dieci chiamate.

- **Cerebras** — da agosto 2026 niente più piano senza carta, e il gratuito limita il contesto a 8K token: Spectra manda 32 definizioni di strumenti oltre alla cronologia, non ci sta.

- **Moonshot Kimi, MiniMax, Qwen** — sono frontiera veri, ma non superano GPT-5.6 su GPQA Diamond (il banco che conta per la chimica) e duplicano capacità già coperte da Gemini 3 Pro e DeepSeek. Aggiungerli allungherebbe la tendina senza darti una scelta migliore.

- **Qwen / Alibaba** (quota diretta) — la parte gratuita è una **\*\*prova a**

tempo\*\* di circa 90 giorni, non un piano permanente. I modelli Qwen restano comunque raggiungibili tramite Groq.

---

## Una cosa da non fare

---

**Non incollare mai una chiave dentro il codice del sito.** GitHub Pages serve file statici: finirebbe visibile a chiunque apra la pagina con `Ctrl+U`, e i bot che scandagliano GitHub la troverebbero in poche ore, facendotela revocare.

Se vuoi che il sito funzioni **per chiunque lo apra**, senza che nessuno debba inserire niente, la strada c'è ed è un'altra: `proxy/README.md`.

---

*Verifica dei fornitori: settembre 2026. Se leggi questa guida molto più tardi, ricontrolla — i servizi chiudono, e un elenco è vecchio dal giorno dopo che lo scrivi.*