

Le chiavi API di Spectra — guida pratica

Spectra non ha un server: parla direttamente con il servizio AI che scegli, usando **la tua** chiave. La chiave resta nel browser, non passa da nessuna parte, e la inserisci **una volta sola** per servizio.

> **La cosa più importante di questa guida:** non fermarti alla prima chiave. > Spectra mette in comune tutte quelle che hai — quando un servizio esaurisce > il limite, continua da solo sul successivo, senza che tu debba fare niente. > Tre chiavi gratuite reggono un carico che nessuna delle tre reggerebbe da > sola.

Due livelli: i gratuiti e la frontiera

Spectra ha **quattro servizi gratuiti** e **sette configurazioni a pagamento**. Ogni fornitore in questo elenco è stato verificato attivo a **settembre 2026**: nessuno è lì per fare numero, e nessuno è scaduto. I gratuiti bastano per studiare; i secondi servono quando un problema è davvero difficile.

Il banco che conta per quest'app si chiama **GPQA Diamond**: domande di livello dottorato in fisica, chimica e biologia. Non è il benchmark del marketing, è esattamente ciò che le chiedi tu.

I quattro servizi gratuiti, e a cosa serve ciascuno

Sono stati scelti uno per uno. Nessuno è lì per fare numero: i servizi gratuiti che davano modelli piccoli o cataloghi imprevedibili sono stati **tolti**, perché su un problema di chimica in dieci passaggi non reggono e peggiorano la risposta invece di migliorarla.

Servizio	Modelli	A cosa serve davvero	Limite
Groq	GPT-OSS 120B, Qwen3	Il cavallo da tiro. 131K di contesto, ~30 richieste/minuto: è quello che userai per l'80% del lavoro	Generoso
Google Gemini	Gemini Flash	I documenti enormi. Fino a 1 milione di token di contesto: PDF interi, dispense, tesi	Generoso
NVIDIA NIM	DeepSeek R1, Qwen3 235B	Il ragionamento profondo. Modelli enormi che pensano prima di rispondere	Crediti a esaurimento
Z.AI GLM	GLM-4.7-Flash	Il ricalzo che non scade. Gratuito senza limite di tempo, forte su ragionamento e codice	Limitato al minuto

Se ne fai solo due

Groq + Gemini. Due minuti in tutto, e coprono il grosso: Groq per il volume quotidiano, Gemini per i documenti lunghi. NVIDIA e Z.AI aggiungili dopo, come riserva.

Per i riassunti di documenti lunghi: Gemini

È la domanda che riceve più spesso una risposta sbagliata. Un riassunto di una dispensa o di un capitolo non richiede il modello *più intelligente*: richiede quello che **ci sta dentro**. Gemini arriva a 1 milione di token di contesto — centinaia di pagine in una sola richiesta. Gli altri gratuiti si fermano molto prima e ti restituiscono un riassunto della prima parte, senza dirti che il resto non l'hanno letto.

| 1. Groq — comincia da qui

30 secondi, nessuna verifica.

1. Vai su console.groq.com
2. Accedi con Google o GitHub
3. Menu a sinistra → **API Keys**
4. **Create API Key** → dai un nome qualsiasi (es. *spectra*) → **Submit**
5. Copia la chiave: comincia con *gsk_*

> ⚠ La chiave si vede **una volta sola**. Se chiudi la finestra senza > copiarla, creane un'altra — sono gratuite.

Perché è il cavallo da tiro: 131.000 token di contesto e circa 30 richieste al minuto. Non lo esaurisci studiando.

| 2. Google Gemini — per i documenti enormi

1 minuto.

1. Vai su aistudio.google.com
2. Accedi col tuo account Google
3. In alto a sinistra → **Get API key**
4. **Create API key** → scegli un progetto (o lascia che ne crei uno)
5. Copia la chiave: comincia con *AIza*

Quando cambia tutto: quando alleggi un PDF lungo. Arriva a **1 milione di token** di contesto — una tesi intera in una sola richiesta. Nessuno degli altri ci si avvicina.

| 3. NVIDIA NIM — i modelli che ragionano

3 minuti, senza carta di credito.

1. Vai su build.nvidia.com
2. **Sign in** → crea un account NVIDIA se non ce l'hai (Developer Program, gratuito)
3. Apri un modello qualsiasi dall'elenco (per esempio *DeepSeek R1*)
4. Nel pannello a destra → **Get API Key** → **Generate Key**

5. Copia la chiave: comincia con **nvapi-**

> I crediti gratuiti sono **a esaurimento**: non si rinnovano ogni mese. > Tienilo per quando serve un modello che ragiona a fondo su un problema > lungo.

| 4. Z.AI GLM — il rincalzo che non scade

2 minuti.

1. Vai su **z.ai** e registrati con l'email
2. Apri il menu del **profilo** → **API Keys**
3. **Create new key** → copia la chiave

Perché c'è: è gratuito **senza scadenza** — non crediti a esaurimento, non una prova a tempo. GLM-4.7-Flash è forte su ragionamento e codice. È la riserva che trovi ancora lì fra sei mesi, quando i crediti NVIDIA saranno finiti.

La frontiera — quando serve il massimo

Questi si pagano a consumo, e non poco. Ma sono un'altra categoria: su un problema di chimica fisica in dieci passaggi la differenza si vede.

| GPT-5.6 — il più forte sulle domande scientifiche

È il numero uno su GPQA Diamond: 94,6%. Sul banco che misura esattamente il tipo di domande che fai tu, oggi non c'è niente di meglio.

1. Vai su **platform.openai.com** → accedi
2. **API keys** → **Create new secret key**
3. Copia la chiave: comincia con **sk-proj-**
4. Serve credito sul conto (**Billing** → aggiungi un importo, anche 5 \$)

Circa **4 \$ per milione di token** in ingresso. Una conversazione di studio costa centesimi.

> Il modello di punta (*SoI*) è ad accesso limitato e la tua chiave potrebbe > non vederlo. Non è un problema: Spectra chiede all'API cosa può usare e > scala da solo a *Terra* e poi a *Luna*, senza che tu debba saperlo.

| Gemini 3 Pro — la finestra più ampia

Stessa chiave del Gemini gratuito: la incolli una volta e vale per entrambi. Cambia solo che serve la fatturazione attiva sul progetto Google.

1. **aistudio.google.com** → la chiave che hai già
2. Attiva la fatturazione sul progetto (Google Cloud → Billing)

Oltre **1 milione di token** di contesto: una tesi intera in una sola richiesta. Circa 2 \$ per milione in ingresso.

| DeepSeek V4 — il miglior rapporto qualità/prezzo

Ragionamento di fascia alta a **una frazione** del costo: circa **0,66 \$ per milione** di token in ingresso fuori dalle ore di punta — sei volte meno di GPT-5.6.

1. platform.deepseek.com → registrati
2. **API keys** → **Create API key** → copia (comincia con `sk-`)
3. Ricarica un piccolo credito

Se paghi di tasca tua e vuoi spendere poco, comincia da qui.

| Grok 4.6 — il migliore sugli agenti

Uscito il 12 agosto 2026. È il primo su **tool calling agentico** — cioè esattamente quello che fa Spectra quando concatena dieci strumenti — e ha il tasso di allucinazione più basso in circolazione. Circa **2 \$ per milione** di token in ingresso: meno della metà di GPT-5.6.

1. console.x.ai → **API Keys** → crea (comincia con `xai-`)

Le versioni precedenti restano raggiungibili e arrivano a 1–2 milioni di token di contesto: se la 4.6 non è disponibile sulla tua chiave, Spectra scala da sola.

| Claude — Fable 5.1, Opus 5, Sonnet 5

1. console.anthropic.com → **API Keys** → **Create Key**
2. Copia (comincia con `sk-ant-`) e aggiungi credito

Una chiave sola per tutti e tre: la incolli su uno qualsiasi dei modelli Claude e vale automaticamente per gli altri due.

Sono gli unici che, in Modalità Nucleo, ottengono il **sandbox Python** (sympy, numpy, scipy, matplotlib) per fare calcolo vero invece di ricordarselo.

> È separato dall'abbonamento di claude.ai: quello non dà accesso all'API.

Quale scegliere, in pratica

Se...	Usa
Studio quotidiano, tante domande	Groq (gratis)
Un PDF lungo da leggere, o un riassunto	Gemini (gratis) o Gemini 3 Pro
Un problema scientifico davvero tosto	GPT-5.6
Una catena lunga di strumenti	Grok 4.6
Calcolo simbolico o numerico vero	Claude + ⚙️ Modalità Nucleo
Vuoi potenza ma spendere poco	DeepSeek V4

Come inserirle in Spectra

1. Apri BioSpecInfo → pulsante **Spectra** (il simbolo dell'atomo)
2. Nella tendina in alto scegli il servizio
3. Compare il riquadro 🔑 **Configura** → incolla la chiave → **Salva**
4. Ripeti per ogni servizio che hai

La chiave sparisce dalla vista e **non te la richiede più**: resta salvata in questo browser finché non la togli tu.

> **Le chiavi condivise.** I quattro modelli Claude usano un solo account > Anthropic, e Gemini Flash e Gemini 3 Pro una sola chiave di AI Studio: > incollala su uno qualsiasi e vale per i gemelli. Non devi ripeterla.

Toglierle o ricominciare da capo

Pulsante 🗑️ **Cancella tutto** nella barra di Spectra. Ti fa scegliere cosa togliere — chat, chiavi, memoria — prima di cancellare davvero.

Cosa succede quando finisci una quota

Niente di drammatico, e soprattutto: **non devi fare niente**.

- **Limite al minuto:** Spectra legge quanto deve aspettare, te lo dice — «⌚ ha raggiunto il limite al minuto: aspetto 7s» — e riprova da solo. Fino a tre volte.
- **Quota finita davvero:** passa a un altro servizio per cui hai una chiave e **rifà la domanda da lì**, dicendotelo — «🔄 Groq ha esaurito la quota: continuo su Google Gemini».
- **Richiesta troppo grande** per il servizio scelto: riduce gli strumenti a quelli pertinenti e accorcia la cronologia più vecchia, invece di farsi rifiutare — «⚠️ uso i 19 strumenti più adatti invece di tutti e 32».
- **Mai a pagamento senza chiedertelo.** La riserva automatica usa solo servizi gratuiti. Se hai messo anche una chiave Claude o Grok, Spectra non ci passa da solo: quelli li scegli tu.

Ecco perché conviene metterne più di una: da sole hanno limiti bassi, insieme diventano una riserva sola.

Se qualcosa non va

Messaggio	Cosa significa	Cosa fare
401 / Invalid API Key	Chiave sbagliata o incollata a metà	Ricreala e reincollala per intero
«Impossibile contattare...»	Rete assente, oppure quel servizio non accetta chiamate dirette dal browser	Non fare niente: Spectra passa da sola a un altro servizio per cui hai una chiave
429	Limite al minuto	Non fare niente: Spectra aspetta e riprova da solo
404 model not found	Il servizio ha ritirato quel modello	Non fare niente: Spectra ne trova un altro da solo
Spectra non risponde	Spesso è la chiave non salvata	Controlla che il riquadro  sia sparito dopo il Salva

Perché alcuni servizi non ci sono

Non è una dimenticanza: sono stati provati e scartati.

- **GitHub Models** — c'era, ed è stato tolto: GitHub lo ha **ritirato del tutto il 30 luglio 2026**. Playground, catalogo, API di inferenza: tutto spento, per tutti. Qualunque guida che lo consigli ancora è più vecchia di quella data.
- **Claude Haiku 4.5** — c'era fra i modelli Claude. Non è scaduto, ma è *dominato*: Sonnet 5 costa il doppio e in cambio dà cinque volte il contesto, il ragionamento esteso e la ricerca web, che Haiku non ha. Quando un'opzione è peggiore di un'altra su tutto tranne il prezzo, e ci sono già quattro servizi gratuiti per chi non vuole spendere, tenerla è solo una voce in più da leggere.
- **Mistral** — qualità media, e il piano gratuito richiede la verifica del telefono **e il consenso all'uso dei tuoi dati per l'addestramento**. Per materiale di tesi non pubblicato è un prezzo che non vale la pena pagare quando esistono cinque alternative senza quella clausola.
- **OpenRouter** — i modelli gratuiti sono piccoli e i loro nomi cambiano di continuo. Come rincalzo occasionale andava; per un agente che deve concatenare dieci chiamate a strumenti, no.
- **Cerebras** — sarebbe stato il candidato ovvio per velocità, ma da agosto 2026 il piano senza carta non esiste più e il gratuito limita il contesto a **8K token**: Spectra manda 32 definizioni di strumenti oltre alla cronologia, non ci sta.
- **Qwen / Alibaba** — la quota gratuita è una **prova a tempo** (circa 90 giorni), non un piano permanente.

| Una cosa da non fare

Non incollare mai una chiave dentro il codice del sito. GitHub Pages serve file statici: finirebbe visibile a chiunque apra la pagina, e i bot che scandagliano GitHub la troverebbero in poche ore, facendotela revocare.

Se vuoi che il sito funzioni **per chiunque lo apra**, senza che nessuno debba inserire niente, la strada c'è ed è un'altra: [proxy/README.md](#).