

Le chiavi API di Spectra — guida pratica

Spectra non ha un server: parla direttamente con il servizio AI che scegli, usando **la tua** chiave. La chiave resta nel browser, non passa da nessuna parte, e la inserisci **una volta sola** per servizio.

> **La cosa più importante di questa guida:** non fermarti alla prima chiave. > Spectra mette in comune tutte quelle che hai — quando un servizio esaurisce > il limite, continua da solo sul successivo, senza che tu debba fare niente. > Tre chiavi gratuite reggono un carico che nessuna delle tre reggerebbe da > sola.

Due livelli: i gratuiti e la frontiera

Spectra ha **cinque servizi gratuiti** e **cinque a pagamento**. I gratuiti bastano per studiare; i secondi servono quando un problema è davvero difficile.

Il banco che conta per quest'app si chiama **GPQA Diamond**: domande di livello dottorato in fisica, chimica e biologia. Non è il benchmark del marketing, è esattamente ciò che le chiedi tu.

I cinque servizi gratuiti, e a cosa serve ciascuno

Sono stati scelti uno per uno. Nessuno è lì per fare numero: i servizi gratuiti che davano modelli piccoli o cataloghi imprevedibili sono stati **tolti**, perché su un problema di chimica in dieci passaggi non reggono e peggiorano la risposta invece di migliorarla.

Servizio	Modelli	A cosa serve davvero	Limite
Groq	GPT-OSS 120B, Qwen3	Il cavallo da tiro. 131K di contesto, ~30 richieste/minuto: è quello che userai per l'80% del lavoro	Generoso
Google Gemini	Gemini Flash	I documenti enormi. Fino a 1 milione di token di contesto: PDF interi, dispense, tesi	Generoso
GitHub Models	GPT-4.1, o4-mini, DeepSeek	La lama affilata. La qualità più alta che puoi avere gratis. Tienilo per i problemi difficili	10/min, 50/giorno
NVIDIA NIM	DeepSeek R1, Qwen3 235B	Il ragionamento profondo. Modelli enormi che pensano prima di rispondere	Crediti a esaurimento
Z.AI GLM	GLM-4.7-Flash	Il ricalzo che non scade. Gratuito senza limite di tempo, forte su ragionamento e codice	Limitato al minuto

Se ne fai solo tre

Groq + Gemini + GitHub Models. Dieci minuti in tutto, e coprono tutto: volume, documenti lunghi, qualità sui casi difficili. Gli altri due aggiungili dopo, come riserva.

| 1. Groq — comincia da qui

30 secondi, nessuna verifica.

1. Vai su console.groq.com
2. Accedi con Google o GitHub
3. Menu a sinistra → **API Keys**
4. **Create API Key** → dai un nome qualsiasi (es. *spectra*) → **Submit**
5. Copia la chiave: comincia con *gsk_*

> ⚠ La chiave si vede **una volta sola**. Se chiudi la finestra senza > copiarla, creane un'altra — sono gratuite.

Perché è il cavallo da tiro: 131.000 token di contesto e circa 30 richieste al minuto. Non lo esaurisci studiando.

| 2. Google Gemini — per i documenti enormi

1 minuto.

1. Vai su aistudio.google.com
2. Accedi col tuo account Google
3. In alto a sinistra → **Get API key**
4. **Create API key** → scegli un progetto (o lascia che ne crei uno)
5. Copia la chiave: comincia con *AIza*

Quando cambia tutto: quando alleggi un PDF lungo. Arriva a **1 milione di token** di contesto — una tesi intera in una sola richiesta. Nessuno degli altri ci si avvicina.

| 3. GitHub Models — la qualità più alta

2 minuti. Non serve creare nessun account: usi quello di GitHub.

1. Vai su github.com e accedi
2. Clicca la tua **foto profilo** in alto a destra → **Settings**
3. Scorri il menu di sinistra fino in fondo → **Developer settings**
4. **Personal access tokens** → **Fine-grained tokens**
5. **Generate new token**
6. Compila:
7. *Token name:* *spectra*
8. *Expiration:* la scadenza che preferisci (un anno va bene)
9. Scendi a **Account permissions** — non a *Repository permissions* — e cerca la voce **Models**: mettila su **Read-only**
10. In fondo → **Generate token**

11. Copia il token: comincia con `github_pat_`

> Il permesso da dare è **Models: Read-only** e sta fra i permessi > dell'*account*, non del repository. È il passaggio dove è facile sbagliare.

Il compromesso, detto chiaro: 10 richieste al minuto, 50 al giorno, e accetta al massimo 8.000 token per richiesta. Sono i limiti più stretti di tutti — ma sono le risposte migliori che puoi avere gratis. Spectra lo sa e si adatta da solo: su questo servizio manda gli strumenti pertinenti alla domanda invece di tutti e 32, così la richiesta ci sta. **Usalo per i problemi difficili, non per il lavoro di volume.**

| 4. NVIDIA NIM — i modelli che ragionano

3 minuti, senza carta di credito.

1. Vai su `build.nvidia.com`
2. **Sign in** → crea un account NVIDIA se non ce l'hai (Developer Program, gratuito)
3. Apri un modello qualsiasi dall'elenco (per esempio *DeepSeek R1*)
4. Nel pannello a destra → **Get API Key** → **Generate Key**
5. Copia la chiave: comincia con `nvapi-`

> I crediti gratuiti sono **a esaurimento**: non si rinnovano ogni mese. > Tienilo per quando serve un modello che ragiona a fondo su un problema > lungo.

| 5. Z.AI GLM — il rincalzo che non scade

2 minuti.

1. Vai su `z.ai` e registrati con l'email
2. Apri il menu del **profilo** → **API Keys**
3. **Create new key** → copia la chiave

Perché c'è: è gratuito **senza scadenza** — non crediti a esaurimento, non una prova a tempo. GLM-4.7-Flash è forte su ragionamento e codice. È la riserva che trovi ancora lì fra sei mesi, quando i crediti NVIDIA saranno finiti.

La frontiera — quando serve il massimo

Questi si pagano a consumo, e non poco. Ma sono un'altra categoria: su un problema di chimica fisica in dieci passaggi la differenza si vede.

| GPT-5.6 — il più forte sulle domande scientifiche

È il numero uno su GPQA Diamond: 94,6%. Sul banco che misura esattamente il tipo di domande che fai tu, oggi non c'è niente di meglio.

1. Vai su platform.openai.com → accedi
2. **API keys** → **Create new secret key**
3. Copia la chiave: comincia con **sk-proj-**
4. Serve credito sul conto (**Billing** → aggiungi un importo, anche 5 \$)

Circa **4 \$ per milione di token** in ingresso. Una conversazione di studio costa centesimi.

> Il modello di punta (*SoI*) è ad accesso limitato e la tua chiave potrebbe > non vederlo. Non è un problema: Spectra chiede all'API cosa può usare e > scala da solo a *Terra* e poi a *Luna*, senza che tu debba saperlo.

| Gemini 3 Pro — la finestra più ampia

Stessa chiave del Gemini gratuito: la incolli una volta e vale per entrambi. Cambia solo che serve la fatturazione attiva sul progetto Google.

1. aistudio.google.com → la chiave che hai già
2. Attiva la fatturazione sul progetto (Google Cloud → Billing)

Oltre **1 milione di token** di contesto: una tesi intera in una sola richiesta. Circa 2 \$ per milione in ingresso.

| DeepSeek V4 — il miglior rapporto qualità/prezzo

Ragionamento di fascia alta a **una frazione** del costo: circa **0,66 \$ per milione** di token in ingresso fuori dalle ore di punta — sei volte meno di GPT-5.6.

1. platform.deepseek.com → registrati
2. **API keys** → **Create API key** → copia (comincia con **sk-**)
3. Ricarica un piccolo credito

Se paghi di tasca tua e vuoi spendere poco, comincia da qui.

| Grok 4 — 2 milioni di token

La finestra più ampia in circolazione e un ottimo rapporto prezzo/GPQA.

1. console.x.ai → **API Keys** → crea (comincia con **xai-**)

| Claude — Fable 5.1, Opus 5, Sonnet 5, Haiku 4.5

1. console.anthropic.com → **API Keys** → **Create Key**
2. Copia (comincia con **sk-ant-**) e aggiungi credito

Una chiave sola per tutti e quattro: la incolli su uno qualsiasi dei modelli Claude e vale automaticamente per gli altri tre.

> È separato dall'abbonamento di claude.ai: quello non dà accesso all'API.

Quale scegliere, in pratica

Se...	Usa
Studio quotidiano, tante domande	Groq (gratis)
Un PDF lungo da leggere	Gemini (gratis) o Gemini 3 Pro
Una domanda difficile, poche volte al giorno	GitHub Models (gratis)
Un problema scientifico davvero tosto	GPT-5.6
Vuoi potenza ma spendere poco	DeepSeek V4

Come inserirle in Spectra

1. Apri BioSpecInfo → pulsante **Spectra** (il simbolo dell'atomo)
2. Nella tendina in alto scegli il servizio
3. Compare il riquadro  **Configura** → incolla la chiave → **Salva**
4. Ripeti per ogni servizio che hai

La chiave sparisce dalla vista e **non te la richiede più**: resta salvata in questo browser finché non la togli tu.

> **Le chiavi condivise.** I quattro modelli Claude usano un solo account > Anthropic, e Gemini Flash e Gemini 3 Pro una sola chiave di AI Studio: > incollala su uno qualsiasi e vale per i gemelli. Non devi ripeterla.

Toglierle o ricominciare da capo

Pulsante  **Cancella tutto** nella barra di Spectra. Ti fa scegliere cosa togliere — chat, chiavi, memoria — prima di cancellare davvero.

Cosa succede quando finisci una quota

Niente di drammatico, e soprattutto: **non devi fare niente**.

- **Limite al minuto** (capita con GitHub Models): Spectra legge quanto deve aspettare, te lo dice — « ha raggiunto il limite al minuto: aspetto 7s» — e riprova da solo. Fino a tre volte.
- **Quota finita davvero**: passa a un altro servizio per cui hai una chiave e **rifà la domanda da lì**, dicendotelo — « Groq ha esaurito la quota: continuo su Google Gemini».
- **Richiesta troppo grande** per il servizio scelto: riduce gli strumenti a quelli pertinenti e accorcia la cronologia più vecchia, invece di farsi rifiutare — « uso i 19 strumenti più adatti invece di tutti e 32».
- **Mai a pagamento senza chiedertelo.** La riserva automatica usa solo servizi gratuiti. Se hai messo anche una chiave Claude o Grok, Spectra non ci passa da solo: quelli li scegli tu.

Ecco perché conviene metterne più di una: da sole hanno limiti bassi, insieme diventano una riserva sola.

Se qualcosa non va

Messaggio	Cosa significa	Cosa fare
401 / Invalid API Key	Chiave sbagliata o incollata a metà	Ricrea e reincollala per intero
403 con Models	Token GitHub senza il permesso giusto	Rifallo con Models: Read-only fra i permessi <i>account</i>
429	Limite al minuto	Non fare niente: Spectra aspetta e riprova da solo
404 model not found	Il servizio ha ritirato quel modello	Non fare niente: Spectra ne trova un altro da solo
Spectra non risponde	Spesso è la chiave non salvata	Controlla che il riquadro  sia sparito dopo il Salva

Perché alcuni servizi non ci sono

Non è una dimenticanza: sono stati provati e scartati.

- **Mistral** — qualità media, e il piano gratuito richiede la verifica del telefono **e il consenso all'uso dei tuoi dati per l'addestramento**. Per materiale di tesi non pubblicato è un prezzo che non vale la pena pagare quando esistono cinque alternative senza quella clausola.
- **OpenRouter** — i modelli gratuiti sono piccoli e i loro nomi cambiano di continuo. Come rincalzo occasionale andava; per un agente che deve concatenare dieci chiamate a strumenti, no.
- **Cerebras** — sarebbe stato il candidato ovvio per velocità, ma da agosto 2026 il piano senza carta non esiste più e il gratuito limita il contesto a **8K token**: Spectra manda 32 definizioni di strumenti oltre alla cronologia, non ci sta.
- **Qwen / Alibaba** — la quota gratuita è una **prova a tempo** (circa 90 giorni), non un piano permanente.

Una cosa da non fare

Non incollare mai una chiave dentro il codice del sito. GitHub Pages serve file statici: finirebbe visibile a chiunque apra la pagina, e i bot che scandagliano GitHub la troverebbero in poche ore, facendotela revocare.

Se vuoi che il sito funzioni **per chiunque lo apra**, senza che nessuno debba inserire niente, la strada c'è ed è un'altra: [proxy/README.md](#).