

# BioSpecInfo



Guida Data Science — dai tuoi corsi al lavoro

---

Samuele Pio Provenzano

Versione **bsi-v174** · commit `de935fb`

Generato il 2026-09-25

Documento generato automaticamente dal sorgente Markdown versionato nel repository. La versione e il commit stampati in ogni piè di pagina identificano esattamente lo stato del software descritto.



# Guida Data Science — dai tuoi corsi al lavoro

---

**Per: chi parte dalla chimica e vuole diventare data scientist (obiettivo: CERN / CNR).**

Questa guida accompagna la sezione *Data Science* dell'app BioSpecInfo. Qui trovi **l'ordine con cui affrontare i tuoi corsi Udeemy** e le **tracce dei progetti** (oltre a quella “Solubilità”, che è guidata dentro l'app).

---

## 1) In che ordine fare i tuoi corsi

---

L'idea: prima le **fondamenta** (Python + analisi dati), poi il **machine learning**, poi l'**AI**, e in parallelo la tua **marcia in più** (chimica + dati). L'inglese sempre.

### Fase A — Fondamenta (1-2 mesi)

#### 1. Python da Zero: Fondamenti, OOP e Data Analysis con Pandas

→ sintassi, funzioni, OOP, e soprattutto **pandas**. È la base di tutto.

#### 1. Python for Data Science & ML Bootcamp (Jose Portilla)

→ NumPy, pandas, Matplotlib/Seaborn, prime pipeline **scikit-learn**.

#### 1. The Complete SQL Bootcamp: Go from Zero to Hero (Jose Portilla)

→ **SQL**: SELECT, WHERE, JOIN, GROUP BY, aggregazioni, subquery. Interrogare i database è un'abilità richiestissima. (*Provalo subito nel **Playground SQL** dentro l'app!*) *Obiettivo di fase*: saper caricare un CSV, pulirlo, interrogarlo con SQL, fare un grafico e un primo modello.

### Fase B — Data Science & Machine Learning (2-3 mesi)

#### 1. The Data Science Course: Complete Bootcamp 2026 (365 Careers)

→ statistica e probabilità (fondamentali!), regressione, cluster analysis, ML, DL con TensorFlow.

#### 1. Python Data Visualization: Matplotlib & Seaborn Masterclass (Maven Analytics)

→ grafici efficaci: distribuzioni, correlazioni, heatmap, personalizzazione. Il **data storytelling** che convince i selezionatori.

#### 1. Machine Learning A-Z [2026] (Eremenko, de Ponteves)

→ regressione, classificazione, clustering, riduzione di dimensionalità, XGBoost.

#### 1. Data Science con Python e IA: dai dati grezzi agli insight (Sorrentino)

→ la **pipeline completa**, molto pratica.

#### 1. Data Science A-Z: Hands-On Exercises

→ preparazione dati, visualizzazione e **data storytelling** applicato. *Obiettivo di fase*: costruire e valutare regressione + classificazione + clustering da solo, e presentarli con grafici chiari.

## Fase C — Deep Learning & AI (1-2 mesi)

### 1. Complete Data Science, ML, DL, NLP Bootcamp (Krish Naik)

→ deep learning, NLP e **deployment** (mettere un modello online).

### 1. The AI Engineer Course 2026 (365 Careers)

→ LLM, IA generativa, API di AI, AI engineering.

## Fase D — Il tuo asso: Chimica + Dati (in parallelo dalla Fase B)

1. **RDKit: Cheminformatics & Drug Discovery in Python** → manipolare molecole, descrittori, fingerprint, similarità.

2. **Machine Learning in Drug Discovery and Cheminformatics** → QSAR, screening virtuale, ML sui farmaci.

3. **Data Science in Chemistry** → applicare tutto a dati chimici reali.

4. **Computational Chemistry: Concepts, Theories & Applications** → DFT, metodi quantomeccanici (la teoria dietro i dati).

## Sempre, in parallelo

- **English Intermediate (B2)+** → al CERN e nella ricerca internazionale l'inglese è la lingua di lavoro. 20 minuti al giorno.

💡 Regola d'oro: **non finire un corso prima di iniziare a costruire**. Dopo la Fase A parti già col progetto “Solubilità” (guidato nell'app).

## 2) Le tracce dei progetti (portfolio GitHub)

Ogni progetto = un repository su GitHub con: `README.md`, `requirements.txt`, un notebook/script, la cartella `data/`. Il **Toolkit GitHub** nell'app ti genera i file di partenza.

Il progetto **#2 “Regressione: solubilità”** ha la **traccia guidata completa dentro l'app** (con tutto il codice). Qui sotto trovi gli **altri**.

### #1 — EDA con pandas (*il primo, facile e formativo*)

- **Obiettivo:** esplorare e capire un dataset di molecole.
- **Passi:** carica un CSV (es. proprietà molecolari) → `df.head()`, `df.describe()`, `df.info()` →

valori mancanti → istogrammi e scatter (Matplotlib/Seaborn) → 3 osservazioni scritte nel README.

- **Impari:** pandas, visualizzazione, il 60% del vero lavoro (capire i dati).

## Extra — Interroga un database con SQL

- **Obiettivo:** rispondere a domande sui dati usando **SQL** (la skill del tuo nuovo corso).
- **Passi:** carica un CSV in SQLite ( `sqlite3` / `pandas.to_sql` ) → scrivi query con **WHERE**,

**ORDER BY**, **GROUP BY**, funzioni di aggregazione (**COUNT**/**AVG**/**SUM**) e un **JOIN** → esporta i risultati. (Puoi allenarti subito nel **Playground SQL** dentro l'app.)

- **Impari:** SQL applicato, il linguaggio con cui si estraggono i dati ovunque.

## #3 — Classificazione: attività di un composto

- **Obiettivo:** prevedere se una molecola è **attiva/inattiva** (o tossica/non tossica).
- **Dati:** un bioassay da **ChEMBL** o un dataset MoleculeNet (es. BBBP, Tox21).
- **Passi:** SMILES → descrittori/fingerprint RDKit → `train_test_split` →

`RandomForestClassifier` → metriche **accuratezza**, **precision**, **recall**, **ROC-AUC** → matrice di confusione.

- **Impari:** classificazione, metriche, sbilanciamento delle classi.

## #4 — Clustering molecolare (non supervisionato)

- **Obiettivo:** raggruppare molecole simili in “famiglie”.
- **Passi:** SMILES → **Morgan fingerprint** (RDKit) → matrice di **similarità di Tanimoto** →

`KMeans` o clustering gerarchico → visualizza con **PCA/t-SNE** in 2D.

- **Impari:** apprendimento non supervisionato, similarità molecolare (concetto centrale in cheminformatica).

## #5 — Visualizzazione / dashboard

- **Obiettivo:** comunicare i dati con grafici curati.
- **Passi:** scegli un dataset (o uno spettro) → grafici con **Matplotlib/Plotly** →

opzionale: dashboard interattiva con **Streamlit**.

- **Impari:** data storytelling — ciò che convince un selezionatore.

## #6 — Mini-QSAR (struttura → attività)

- **Obiettivo:** modello che collega la **struttura** molecolare a una **proprietà/attività**.
- **Passi:** dataset con SMILES + valore target → descrittori RDKit (decine) →

selezione feature → modello (RandomForest/Gradient Boosting) → interpretazione (feature importance).

- **Impari:** il cuore della cheminformatica applicata.

## #7 — Intro al Deep Learning

- **Obiettivo:** una prima **rete neurale**.
- **Passi:** dataset semplice (anche non chimico) → **Keras/PyTorch** → rete a pochi strati →

confronta con un modello classico. Bonus: una piccola **CNN** su spettri/immagini.

- **Impari:** basi del deep learning, quando (non) serve.

## #8 — Submission su Kaggle

- **Obiettivo:** un progetto “vero”, valutato.
- **Passi:** scegli una competizione **beginner-friendly** → EDA → modello → **submission** →

itera per migliorare lo score. Metti il notebook su GitHub.

- **Impari:** l'intero flusso, e ottieni un risultato mostrabile.

## #9 — Repository riproducibile (*qualità professionale*)

- **Obiettivo:** un repo che chiunque può eseguire.
- **Passi:** struttura chiara → `README.md` (obiettivo, dati, come eseguire, risultati) →

`requirements.txt` → `.gitignore` → un notebook ordinato → risultati/figure salvati.

- **Impari:** ciò che distingue un portfolio amatoriale da uno professionale.

## #10 — CERN Open Data (*bonus, per il sogno*)

- **Obiettivo:** toccare i dati della fisica delle particelle.
- **Dati:** portale **CERN Open Data** ([opendata.cern.ch](https://opendata.cern.ch)).
- **Passi:** scarica un dataset → esploralo (magari con **uproot/scikit-HEP**) →

un semplice istogramma o classificazione segnale/fondo.

- **Impari:** lo stack e il tipo di dati del CERN.

---

## 3) Consigli finali

- **Un progetto alla volta, finito e pubblicato** vale più di dieci a metà.
- **README curato:** obiettivo, dati, metodo, risultati, come eseguire. È il tuo biglietto da visita.
- **Commit frequenti** con messaggi chiari: mostrano come lavori.
- **LinkedIn + GitHub** aggiornati; collega i progetti.
- **Per il CERN:** punta a **Summer/Technical Student** durante la magistrale; cura l'inglese.
- **Per il CNR:** tieni d'occhio i **bandi** (assegna, dottorati) su [cnr.it](https://www.cnr.it) e sui siti degli istituti (SCITEC, ICCOM).

Hai già i corsi giusti. Ora la parola chiave è **fare**: ogni progetto è un mattone. Un passo alla volta, ci arrivi. 🚀

*Documento generato per BioSpecInfo · sezione Data Science.*